



Universidad Internacional de La Rioja
Escuela Superior de Ingeniería y
Tecnología

Máster Universitario en Inteligencia Artificial

**Modelado predictivo y detección de
anomalías en sistemas de generación
eléctrica**

Trabajo fin de estudio presentado por:	Iñigo Garaboa Cotelo, Pablo Carcia García y Daniel Clavijo Gil
Tipo de trabajo:	Comparativa de soluciones
Director/a:	Joaquín Gaspar Medina Arco
Fecha:	15-07-2026

Resumen

El trabajo aborda un estudio comparativo de modelos para la detección de anomalías en sistemas de generación eléctrica fotovoltaica.

El objetivo principal es analizar el comportamiento normal de una instalación a partir de datos históricos de operación y detectar desviaciones significativas que pueden estar asociadas a fallos de pérdida de producción o comportamientos anómalos. Para ello, se han empleado variables eléctricas y ambientales como potencia, tensión, corriente, irradiancia, temperatura, entre otros, las cuales han sido tratadas como series temporales en un desarrollo que ha incluido preprocesado, modelado, evaluación y comparación de resultados.

La metodología desarrollada compara distintos enfoques de detección de anomalías, incluyendo modelos estadísticos y predictivos, un enfoque semisupervisado basado en potencia esperada y modelos de *deep learning* mediante *autoencoders*.

Por un lado, los resultados muestran que una parte relevante de las anomalías detectadas se relaciona con situaciones de subproducción, en las que la potencia real generada es inferior a la esperada bajo determinadas condiciones de irradiancia y operación. En particular, el Random Forest optimizado con variables ambientales ofrece una interpretación física clara mediante el análisis de residuos.

Por otro lado, el *autoencoder* permite caracterizar patrones anómalos desde una perspectiva multivariante, ya que no analiza cada variable de forma aislada, sino que aprende las relaciones conjuntas entre las variables eléctricas, térmicas y ambientales del sistema. Además, el análisis posterior mediante *K-Means* facilita la agrupación de las anomalías en distintos perfiles, permitiendo interpretar qué variables contribuyen en mayor medida al error de reconstrucción.

Como conclusión, los modelos evaluados aportan información adicional y complementaria sobre el comportamiento anómalo del sistema. Los resultados son coherentes e interpretables a pesar de no contar con etiquetas reales de fallo. Este estudio avanza hacia sistemas de monitorización predictiva más interpretables y robustos.

Palabras clave: Detección de anomalías, Energía Solar Fotovoltaica, Modelado Predictivo, *Autoencoder*, Inteligencia Artificial

Abstract

The work presents a comparative study of models for anomaly detection in photovoltaic power generation systems.

The main objective is to analyse the normal behaviour of a photovoltaic installation using historical operational data and to detect significant deviations that may be associated with production losses or abnormal operating conditions. For this purpose, electrical and environmental variables such as power, voltage, current, irradiance and temperature, among others, were used as time series within a process that included preprocessing, modelling, evaluation and comparison of results.

The methodology compares different anomaly detection approaches, including statistical and predictive models, a semi-supervised approach based on expected power, and deep learning models using autoencoders.

On the one hand, the results show that a relevant part of the detected anomalies is related to underproduction events, in which the actual generated power is lower than expected under specific irradiance and operating conditions. In particular, the optimized Random Forest model with environmental variables provides a clear physical interpretation through residual analysis.

On the other hand, the autoencoder makes it possible to characterize anomalous patterns from a multivariate perspective, since it does not analyse each variable separately, but learns the joint relationships between the electrical, thermal and environmental variables of the system. In addition, the subsequent K-Means analysis enables the grouping of anomalies into different profiles, helping to identify which variables contribute most to the reconstruction error.

In conclusion, the evaluated models provide additional and complementary information about the anomalous behaviour of the system. The results are coherent and interpretable despite the absence of real fault labels. This study contributes to the development of more interpretable and robust predictive monitoring systems.

Keywords: Anomaly Detection, Photovoltaic Solar Energy, Predictive Modelling, Autoencoder, Artificial Intelligence

Índice de contenidos

1. Introducción.....	1
1.1. Motivación.....	1
1.2. Planteamiento del trabajo.....	2
1.3. Estructura del trabajo.....	3
2. Contexto y estado del arte.....	5
2.1. Contexto del problema	5
2.1.1. Sistemas de generación eléctrica.....	5
2.1.2. Modelado predictivo y supervisión del sistema.....	5
2.1.3. Anomalías en los sistemas eléctricos.....	6
2.1.4. Indicadores de anomalías en la red eléctrica.....	7
2.1.5. Redes Eléctricas Inteligentes: <i>SmartGrids</i>	13
2.2. Estado del arte	14
2.2.1. Marco General de la Detección de Anomalías en Sistemas Energéticos.....	14
2.2.2. Contexto Aplicado a la Generación de Energía Solar Fotovoltaica.....	15
2.2.3. Tipología de Anomalías y Fallos.....	16
2.2.4. Fuentes de Datos para la Detección de Anomalías.....	18
2.2.5. Métodos de Detección y Diagnóstico de Anomalías	22
2.2.6. Limitaciones y Retos Abiertos.....	29
2.3. Conclusiones.....	30
3. Objetivos concretos y metodología de trabajo.....	31
3.1. Objetivo general.....	31
3.2. Objetivos específicos	31
3.3. Metodología del trabajo	32
4. Planteamiento de la comparativa	37
4.1. Introducción al Dataset.....	37
4.2. Justificación del Dataset.....	37
4.3. Configuración del Dataset	38
4.4. Enfoques del Proyecto	39
5. Desarrollo de la comparativa.....	40

5.1. Métodos Estadísticos	40
5.1.1. Preparación del dataset.....	40
5.1.2. Estrategia del conjunto de datos.....	41
5.1.3. Modelos analizados y selección de variables.....	41
5.1.4. Aprendizaje del comportamiento normal para Isolation Forest.....	42
5.1.5. Aprendizaje del comportamiento normal para los modelos Random Forest Regressor ...	42
5.1.6. Definición del modelo, métricas, residuos y umbrales	43
5.1.6.2. Modelos con Random Forest Regressor	45
5.2. Entrenamiento Semisupervisado	45
5.2.1. Justificación de este enfoque	45
5.2.2. Preparación de integración del conjunto de datos	46
5.2.3. Depuración y control de calidad	46
5.2.4. Selección de variables y sistema analizado	47
5.2.5. Aprendizaje del comportamiento normal	48
5.2.6. Cálculo de residuos y generación de pseudoetiquetas.....	48
5.2.7. Detección complementaria de patrones atípicos.....	49
5.2.8. Criterios de evaluación del entrenamiento	49
5.2.9. Síntesis del procedimiento experimental.....	49
5.3. Diseño e Implementación de un Autoencoder.....	50
5.3.1. Preprocesado del Dataset.....	50
5.3.2. División en conjuntos de Train, Validation y Test.....	52
5.3.3. Procesado de los conjuntos de datos	53
5.3.4. Construcción y entrenamiento del modelo.....	53
5.3.5. Detección de las anomalías.....	55
5.3.6. Clasificación de anomalías	56
6. Discusión y análisis de resultados	58
6.1 Resultados de los modelos estadísticos	58
6.1.1. Isolation Forest.....	58
6.1.2. Random Forest Regressor modelo base.....	61
6.1.3. Random Forest Regressor modelo optimizado con variables ambientales.....	65
6.2. Resultados del aprendizaje semisupervisado	69
6.2.1. Métricas del modelo de potencia esperada	69
6.2.2. Resultados de detección de anomalías	71
6.2.3. Relación entre potencia esperada, potencia real y residuo	72
6.2.4. Concentración temporal de los candidatos	73
6.3. Resultados del autoencoder	75
6.3.1. Entrenamiento de los modelos	75

6.3.2.	Error de Reconstrucción.....	77
6.3.3.	Detección de Anomalías sobre el Conjunto	79
6.3.4.	Caracterización de anomalías mediante K-Means	82
6.4	Discusión de los resultados.....	94
7.	<i>Conclusiones y trabajo futuro</i>	<i>100</i>
7.1.	<i>Conclusiones.....</i>	<i>100</i>
7.2.	<i>Líneas de trabajo futuro</i>	<i>101</i>
	<i>Anexo A: Descripción de los campos del conjunto de datos</i>	<i>107</i>
	<i>Anexo B: Uso responsable de la Inteligencia Artificial.....</i>	<i>112</i>
	<i>Anexo C: Referencia al repositorio del proyecto.....</i>	<i>113</i>

Índice de figuras

Figura 1. Principales fenómenos que causan perturbaciones electromagnéticas, según la clasificación de la IEC.	8
Figura 2. Categorías y características típicas de los fenómenos electromagnéticos en sistemas eléctricos de potencia.....	9
Figura 3. Ejemplo de un hueco de tensión.	10
Figura 4. Esquema de generación y propagación de armónicos en redes de distribución eléctrica	11
Figura 5. Comparación entre el sistema eléctrico tradicional y el sistema eléctrico de próxima generación con generación distribuida	14
Figura 6. Desglose de la metodología empleada.....	33
Figura 7. Arquitectura final del autoencoder construido sin variables ambientales	54
Figura 8. Distribución del score de anomalía por el modelo Isolation Forest.....	58
Figura 9. Relación irradiancia-potencia por el modelo Isolation Forest	59
Figura 10. Potencia por irradiancia por el modelo Isolation Forest.....	59
Figura 11. Score de anomalía frente a irradiancia en Isolation Forest	60
Figura 12. Modelo base. Error absoluto frente a potencia esperada	62
Figura 13. Modelo base. Relación irradiancia-potencia	63
Figura 14. Modelo base. Distribución de residuos del modelo	63
Figura 15. Modelo base. Distribución del residuo frente a la potencia esperada	64
Figura 16. Modelo base. Importancia de las variables del modelo Random Forest Regressor	65
Figura 17. Modelo optimizado. Relación irradiancia-potencia	66
Figura 18. Modelo optimizado. Error absoluto frente a potencia esperada.....	67
Figura 19. Modelo optimizado. Distribución de residuos del modelo	67
Figura 20. Modelo optimizado. Distribución del residuo frente a la potencia esperada	68

Figura 21. Modelo optimizado. Importancia de las variables del modelo Random Forest Regressor	69
Figura 22. Tasa de detección por criterio sobre los registros diurnos	72
Figura 23. Relación entre potencia esperada y potencia real en el enfoque semisupervisado	73
Figura 24. Residuo frente a potencia esperada y umbral de baja generación.....	73
Figura 25. Evolución diaria de la tasa de candidatos a baja generación	74
Figura 26. Evolución del entrenamiento del autoencoder en modelo sin variables ambientales	76
Figura 27. Evolución del entrenamiento del autoencoder en modelo con variables ambientales	77
Figura 28. Distribución del error de reconstrucción en modelo sin variables ambientales	78
Figura 29. Distribución del error de reconstrucción en modelo con variables ambientales ...	79
Figura 30. Detección de anomalías en modelo sin ambientales mediante autoencoder - Train + Val. (sin Outliers) + Test.....	79
Figura 31. Detección de anomalías en modelo sin ambientales mediante autoencoder - Train + Val. (con Outliers) + Test.....	80
Figura 32. Detección de anomalías en modelo con ambientales mediante autoencoder - Train + Val. (sin Outliers) + Test.....	81
Figura 33. Detección de anomalías en modelo con ambientales mediante autoencoder - Train + Val. (con Outliers) + Test.....	82
Figura 34. Detección de anomalías con umbral ajustado al percentil 95	82
Figura 35. Método del codo sobre modelo sin variables ambientales	83
Figura 36. Clusterización de anomalías en modelo sin ambientales aplicado sobre dataset de train.....	85
Figura 37. Clusterización de anomalías en modelo sin ambientales aplicado sobre dataset de validación + test.....	86

Figura 38. Relación entre potencia generada y valor medio de las variables térmicas (modelo sin variables ambientales)	87
Figura 39. Relación entre potencia generada y error medio de reconstrucción térmica (modelo sin variables ambientales)	87
Figura 40. Relación entre potencia generada y valor de las variables MODT09 y MODT10 (modelo sin variables ambientales).....	88
Figura 41. Método del codo sobre modelo con variables ambientales	89
Figura 42. Clusterización de anomalías en modelo con ambientales aplicado sobre dataset de train.....	92
Figura 43. Clusterización de anomalías en modelo con ambientales aplicado sobre dataset de validación + test.....	92
Figura 44. Relación entre potencia generada y valor medio de variables térmicas y ambientales por separado.....	93
Figura 45. Relación entre potencia generada y valor medio de variables térmicas y ambientales en conjunto.....	94

Índice de tablas

Tabla 1. Organización del trabajo en grupo	11
Tabla 2. Métricas para obtener un conjunto de entrenamiento normal en Isolation Forest..	42
Tabla 3. Métricas para obtener un conjunto de entrenamiento normal en Random Forest Regressor base.....	43
Tabla 4. Métricas y umbrales utilizados para el modelo Isolation Forest.....	44
Tabla 5. Límites de variables para descartar lecturas erróneas	47
Tabla 6. Rangos considerados como válidos en la detección de outliers	52
Tabla 7. Conjuntos de entrenamiento, validación y test	53
Tabla 8. Resultados por tipo de anomalía del modelo Isolation Forest con reglas físicas.....	60
Tabla 9. Métricas del modelo semisupervisado de potencia esperada	70
Tabla 10. Distribución del modelo semisupervisado.....	71
Tabla 11. Resultados de detección del aprendizaje semisupervisado	71
Tabla 12. Días con mayor tasa de candidatos a baja generación.....	74
Tabla 13. Variables con mayor porcentaje de información no utilizable.....	75
Tabla 14. Clúster 0 de modelo sin variables ambientales	83
Tabla 15. Clúster 1 de modelo sin variables ambientales	84
Tabla 16. Clúster 2 de modelo sin variables ambientales	84
Tabla 17. Clúster 3 de modelo sin variables ambientales	84
Tabla 18. Clúster 0 de modelo con variables ambientales.....	90
Tabla 19. Clúster 1 de modelo con variables ambientales.....	90
Tabla 20. Clúster 2 de modelo con variables ambientales.....	90
Tabla 21. Clúster 3 de modelo con variables ambientales.....	91
Tabla 22. Tabla comparativa de los modelos construidos	95
Tabla 23. Comparación cualitativa de anomalías detectadas y uso recomendado	98

Organización del trabajo en grupo

En este apartado se comentan y detalla las partes en las que se ha dividido el trabajo entre los componentes del grupo. Además, se abordan los objetivos que se han fijado y la coordinación entre los integrantes.

Distribución y estructura de la memoria

La elaboración del proyecto se ha llevado a cabo mediante una distribución equilibrada de las tareas entre los integrantes del grupo, combinando responsabilidades individuales y apartados desarrollados de forma conjunta. Dicho reparto ha sido resumido en la *Tabla 1*.

Tabla 1. Organización del trabajo en grupo

Organización del trabajo en grupo - Desarrollo de la memoria	
Apartado de la memoria	Responsables
Introducción	Pablo e Iñigo
Contexto y estado del arte	Pablo, Iñigo y Daniel
Objetivos y metodología de trabajo	Pablo, Iñigo y Daniel
Marco normativo	Pablo, Iñigo y Daniel
Desarrollo específico de la contribución de modelos estadísticos	Pablo
Desarrollo específico de la contribución semisupervisada	Daniel
Desarrollo específico de la contribución con autoencoders	Iñigo
Conclusiones	Pablo, Iñigo y Daniel

Fuente: Elaboración propia.

Respecto al desarrollo técnico, cada integrante se responsabilizó de uno de los tres enfoques objetivo: modelos estadísticos, metodología semisupervisada y *autoencoders*. Finalmente, las conclusiones se redactaron y revisaron de manera conjunta para integrar los resultados y garantizar la coherencia global de la memoria.

Objetivo del TFE desde el punto de vista de la adquisición de conocimientos

El objetivo del TFE ha sido investigar e indagar respecto a la detección de anomalías. El tema en concreto ha sido focalizado en la generación eléctrica fotovoltaica.

A lo largo del proyecto nuestro objetivo ha sido realizar una comparativa de modelos para realizar dicha detección, conociendo y explorando técnicas y modelos para observar discrepancias. Para ello el proceso de investigación inicial ha sido un punto clave.

Además, otro objetivo concreto ha sido aplicar un estudio exploratorio analítico y detallado sobre el conjunto de datos seleccionado. Proporcionando una base sólida sobre la cual se han aplicado los distintos modelos conociendo sus puntos fuertes y limitaciones.

Mecanismos de coordinación empleados

En cuanto a los mecanismos de coordinación empleados, estos han sido reuniones periódicas y constantes respecto al avance del proyecto. El proceso ha sido iterativo, explorando y poniendo en común los avances y problemas encontrados. Las reuniones principales han sido previas y posteriores a las 3 entregas para planear las estrategias, dudas e inconsistencias observadas.

Como herramienta de coordinación se ha utilizado WhatsApp en donde se ha realizado una comunicación más informal y de organización de reuniones, así como puntualizaciones para tener en cuenta. Por otro lado, en cuanto a las reuniones, estas las hemos desarrollado en Google Meet pudiendo compartir los avances y detalles de forma más cómoda.

1. Introducción

1.1. MOTIVACIÓN

En el contexto actual de la Cuarta Revolución Industrial, caracterizado por la integración de tecnologías digitales, sistemas inteligentes y fuentes de energía renovables, surge la necesidad de desarrollar soluciones avanzadas que permitan gestionar de forma eficiente infraestructuras críticas como los sistemas eléctricos. En este escenario, la convergencia entre la inteligencia artificial y la generación energética renovable, especialmente la fotovoltaica, representa una oportunidad clave para mejorar la monitorización, predicción y fiabilidad de estos sistemas.

El problema que se aborda en este trabajo es la detección de anomalías y la predicción del comportamiento en sistemas de generación eléctrica basados en paneles fotovoltaicos, utilizando técnicas de inteligencia artificial aplicadas a datos reales. Este problema cobra especial relevancia debido a la naturaleza intermitente de la energía solar y a la complejidad inherente de los sistemas eléctricos modernos, donde múltiples variables interactúan.

Las causas de este problema son diversas. Por un lado, la dependencia de condiciones ambientales como la irradiancia o la temperatura introduce incertidumbre en la producción energética. Por otro lado, factores técnicos como la degradación de los módulos, fallos en inversores o problemas en la red eléctrica pueden generar comportamientos anómalos difíciles de identificar mediante métodos tradicionales. Además, la creciente digitalización del sector energético ha provocado una generación masiva de datos que requiere herramientas avanzadas para su análisis e interpretación.

La relevancia de este problema se ha puesto de manifiesto con eventos recientes, como el apagón ocurrido el 28 de abril de 2025 en la península ibérica, que dejó sin suministro eléctrico a más de 50 millones de personas (Sánchez & Castelló Llantada, 2025). Este suceso no solo tuvo un impacto significativo a nivel económico y social, sino que también generó un debate en torno a la estabilidad del sistema eléctrico y el papel de las energías renovables en él. En este contexto, el desarrollo de modelos inteligentes capaces de detectar anomalías de forma temprana puede contribuir a mejorar la resiliencia del sistema y reforzar la confianza en estas tecnologías.

Desde el punto de vista científico, la detección de anomalías en sistemas fotovoltaicos constituye un área de investigación activa, donde el uso de técnicas de aprendizaje automático y *deep learning* ha demostrado ser prometedor. Sin embargo, todavía existen retos importantes como la escasez de datos etiquetados, la dificultad de generalizar modelos entre distintas instalaciones y la necesidad de mejorar la interpretabilidad de los resultados.

Más allá de su relevancia técnica, este trabajo también responde a una motivación académica y formativa. El desarrollo del proyecto implica una transversalidad de conocimientos, integrando disciplinas como la inteligencia artificial, el análisis de datos, la ingeniería eléctrica y el desarrollo de software. Asimismo, fomenta la adquisición de competencias clave como la capacidad de análisis, la resolución de problemas complejos, el trabajo en equipo y la aplicación práctica de conocimientos en un entorno realista que combina software e industria.

En definitiva, este trabajo se justifica tanto por su impacto potencial en la mejora de los sistemas energéticos como por su valor en el desarrollo de habilidades técnicas y académicas, contribuyendo a la formación de perfiles capaces de afrontar los retos tecnológicos de la transición energética.

1.2. PLANTEAMIENTO DEL TRABAJO

Partiendo de la problemática descrita, en este trabajo se plantea como objetivo general el desarrollo de una solución basada en inteligencia artificial que permita mejorar la predicción y detección de anomalías en sistemas de generación fotovoltaica.

La propuesta consiste en diseñar e implementar distintos modelos capaces de aprender el comportamiento normal del sistema a partir de datos históricos y detectar desviaciones significativas que puedan indicar fallos o situaciones anómalas. Para ello, se utilizarán datos procedentes de paneles fotovoltaicos, incluyendo variables eléctricas (potencia, tensión, corriente) y variables meteorológicas (irradiancia, temperatura, etc.), tratadas como series temporales.

Desde el punto de vista de la ingeniería de software, el trabajo implica la construcción de un sistema que abarque distintas fases: adquisición de datos, preprocesado, modelado mediante algoritmos de *machine learning* o *deep learning* y evaluación de resultados. Este enfoque se

alinea con las tendencias actuales de sistemas inteligentes en entornos industriales, donde el uso de datos permite pasar de estrategias reactivas a modelos predictivos y preventivos.

De forma general, el trabajo propone:

- El desarrollo de varios modelos predictivos del comportamiento energético en sistemas fotovoltaicos.
- La implementación de sistemas de detección de anomalías basados en desviaciones respecto al comportamiento esperado.
- El análisis del impacto de variables meteorológicas en la producción eléctrica.
- La comparación de diferentes técnicas de inteligencia artificial para determinar su idoneidad en este contexto.

En conjunto, este trabajo busca aportar una solución tecnológica que contribuya a mejorar la eficiencia, la seguridad y la fiabilidad de los sistemas fotovoltaicos, reforzando su papel dentro del sistema energético actual y futuro.

1.3. ESTRUCTURA DEL TRABAJO

La presente memoria se organiza en siete capítulos principales, además del apartado de referencias bibliográficas y varios anexos con información extra.

El **Capítulo 1**, en el que se encuadra este apartado, introduce el tema objeto de estudio. En él se presenta la motivación del trabajo, se expone su planteamiento general y se describe la estructura seguida a lo largo del documento.

El **Capítulo 2** recoge el contexto y el estado del arte. En él se sitúa el problema dentro del ámbito de la generación de energía solar fotovoltaica y se revisan los principales enfoques, métodos, fuentes de datos, limitaciones y retos identificados en la literatura científica. El capítulo finaliza con una síntesis de las principales conclusiones extraídas de la revisión.

En el **Capítulo 3** se definen los objetivos del trabajo y la metodología prevista para su desarrollo. Se formula el objetivo general, se detallan los objetivos específicos. Además, se describe el procedimiento metodológico que se seguirá para abordar el problema, incluyendo las fases de preparación del dato, modelado y evaluación.

El **Capítulo 4** se dedica al planteamiento de la comparativa. En este capítulo se justifica la elección de los distintos enfoques de detección de anomalías considerados y se establece el

marco común que permite comparar su comportamiento de forma coherente. Asimismo, se definen los criterios de comparación y las condiciones generales bajo las que se desarrollan los experimentos.

El **Capítulo 5** recoge el desarrollo de dicha comparativa. En él se describe de forma detallada el procedimiento seguido para obtener los resultados de cada uno de los enfoques analizados, incluyendo el tratamiento de los datos y la implementación de los modelos.

El **Capítulo 6** presenta la discusión y el análisis de los resultados obtenidos. En este capítulo se exponen los resultados de los modelos evaluados, analizando su comportamiento en relación con la detección de anomalías en el sistema fotovoltaico estudiado. Además, se comparan las prestaciones de los distintos enfoques, valorando sus ventajas y limitaciones.

Por último, el **Capítulo 7** recoge las conclusiones y el trabajo futuro. En él se sintetizan las principales aportaciones del proyecto, se valora el grado de cumplimiento de los objetivos planteados y se proponen posibles líneas de mejora o continuación para investigaciones posteriores.

Finalmente, se incluyen las **referencias bibliográficas**, que recogen las fuentes utilizadas a lo largo del trabajo, y varios **anexos** con los datos analizados, el acceso al repositorio con el código fuente y una declaración sobre el uso responsable de la Inteligencia Artificial.

2. Contexto y estado del arte

2.1.CONTEXTO DEL PROBLEMA

2.1.1. Sistemas de generación eléctrica

Los sistemas de generación eléctrica constituyen la base del funcionamiento de las sociedades modernas, permitiendo el suministro continuo de energía a nivel industrial, comercial y doméstico. Tradicionalmente, la generación de electricidad ha estado dominada por fuentes convencionales como las centrales térmicas (carbón, gas natural, nuclear, etc.), caracterizadas por su capacidad de proporcionar generación controlable y estable. Sin embargo, en las últimas décadas se ha producido una transición progresiva hacia fuentes de energía renovables, como la eólica y la solar fotovoltaica, impulsada por la necesidad de reducir las emisiones de gases de efecto invernadero y avanzar hacia un modelo energético más sostenible.

Este cambio en el *mix* de generación ha introducido nuevos retos en la operación de los sistemas eléctricos, especialmente debido a la naturaleza variable e intermitente de las energías renovables. A diferencia de las fuentes convencionales, estas tecnologías dependen de condiciones ambientales, lo que puede generar fluctuaciones en la producción y afectar al equilibrio entre generación y demanda. En este contexto, resulta fundamental analizar el comportamiento de los sistemas eléctricos ante perturbaciones y anomalías, así como desarrollar mecanismos que garanticen su estabilidad, seguridad y resiliencia. (Terzija, y otros, 2011)

2.1.2. Modelado predictivo y supervisión del sistema

En este escenario, el modelado predictivo ha adquirido un papel fundamental en la gestión y operación de los sistemas eléctricos, especialmente en entornos caracterizados por una elevada complejidad y dinamismo. A través del análisis de datos históricos y señales en tiempo real, estas técnicas permiten anticipar el comportamiento de variables clave como la demanda energética, la generación o los flujos de potencia en la red. El uso de metodologías basadas en aprendizaje automático, redes neuronales y modelos estadísticos avanzados ha mejorado significativamente la capacidad de predicción frente a enfoques tradicionales, permitiendo a

los operadores del sistema tomar decisiones más informadas y reducir la incertidumbre asociada a la planificación energética (Ullah, y otros, 2024).

Más allá de la predicción de variables operativas, el modelado predictivo también se ha convertido en una herramienta clave para la supervisión del estado del sistema y la identificación temprana de comportamientos anómalos. La capacidad de detectar desviaciones respecto a patrones normales de funcionamiento permite anticipar fallos potenciales y mejorar la resiliencia de la red ante perturbaciones. En este sentido, la integración de modelos predictivos dentro de los sistemas de control y monitorización facilita una gestión más proactiva, contribuyendo a optimizar el rendimiento global del sistema eléctrico y a minimizar el impacto de eventos inesperados sobre la continuidad del suministro.

2.1.3. Anomalías en los sistemas eléctricos

En términos generales, las anomalías en los sistemas de generación eléctrica son eventos, fallas o comportamientos inusuales que desvían el funcionamiento de la red de sus parámetros nominales de diseño, afectando la estabilidad, seguridad y calidad del suministro. Estas situaciones pueden ir desde fluctuaciones menores de voltaje hasta apagones a gran escala.

Las desviaciones de pequeña escala son representativas en afectaciones a zonas de pequeño tamaño o con una implicación de población de menor cantidad, considerándose implicaciones de baja índole. En función de las posibles afectaciones y dónde se generen, por ejemplo, en la península ibérica, la Red Eléctrica Española puede absorber esas fluctuaciones ofreciendo servicios sin mayor problema alguno.

Estas situaciones no siempre surgen así y por ello puede conllevar a apagones de gran tamaño como el ocurrido el 28 de abril de 2025 afectando a los territorios peninsulares de España, Portugal, Andorra y el sur de Francia. (Red Eléctrica, 2025).

Acontecimientos como este han llevado al creciente interés por el estudio de las distintas formas de generación de energía provenientes de fuentes más modernas como las renovables y sus implicaciones sobre las redes eléctricas. Todo conlleva a un mayor estudio de seguridad de uso de las propias infraestructuras de las redes eléctricas y cómo inciden nuevas plantas de generación eléctrica con innovaciones más sostenibles poniendo en ruta a una agenda donde prima el respeto al medio ambiente.

Entre estas nuevas rutas de generación de energía, la fotovoltaica ha experimentado una incorporación masiva y, en algunos casos, repentina, pudiendo desestabilizar la frecuencia de la red y poner en riesgo la estabilidad del sistema eléctrico (Saha, Saleem, & Roy, 2023).

Por otro lado, la sobregeneración renovable, ha influido al precio de la electricidad pudiendo alcanzar esta el cero o negativo, lo que representa también en cierto modo una anomalía económica y de gestión de la generación, conllevando a una inestabilidad contextual en empresas del sector (Hirth, 2018).

2.1.4. Indicadores de anomalías en la red eléctrica

Para identificar y caracterizar este tipo de perturbaciones, resulta necesario observar determinados indicadores asociados a la calidad de la energía eléctrica.

La potencia eléctrica, según la RAE, se define como “la cantidad de energía producida o consumida por unidad de tiempo” (Real Academia Española, s. f.), es decir, el voltaje y la corriente en un determinado momento y lugar.

Por otro lado, según el IEEE (Instituto de Ingenieros Eléctricos y Electrónicos) se define la calidad de potencia como “el concepto de alimentar y poner a tierra equipos electrónicos sensibles de una manera adecuada para dichos equipos” (Sedaghati, y otros, 2013).

En este ámbito, la potencia eléctrica y la calidad de potencia constituyen conceptos fundamentales, ya que permiten evaluar si el sistema funciona dentro de condiciones admisibles y si la alimentación suministrada resulta adecuada para los equipos conectados.

Con la finalidad de estandarizar y consolidar una trazabilidad y monitoreo de la señal de potencia en la red eléctrica el organismo IEEE, y según el IEC (*International Electrotechnical Commission*), han desarrollado una serie de recomendaciones a seguir para fomentar la comunicación entre equipos y sectores afines sobre los umbrales y las discrepancias observadas en las mediciones de la potencia eléctrica. La norma concreta es "*IEEE Std 1159-2009 IEEE Recommended Practice for Monitoring Electric Power Quality*" (IEEE, 2009). En esta se recoge la relación entre el fenómeno electromagnético y las causas del mismo. A continuación, se puede observar una tabla que recoge dichas casuísticas.

Figura 1. Principales fenómenos que causan perturbaciones electromagnéticas, según la clasificación de la IEC.

Conducted low-frequency phenomena	Harmonics, interharmonics
	Signal systems (power line carrier)
	Voltage fluctuations
	Voltage dips and interruptions
	Voltage imbalance
	Power-frequency variations
	Induced low-frequency voltages
	DC in ac networks
Radiated low-frequency phenomena	Magnetic fields
	Electric fields
Conducted high-frequency phenomena	Induced continuous wave voltages or currents
	Unidirectional transients
	Oscillatory transients
Radiated high-frequency phenomena	Magnetic fields
	Electric fields
	Electromagnetic fields
	Continuous waves
	Transients
Electrostatic discharge phenomena	—
Nuclear electromagnetic pulse	—

Fuente: IEEE, IEEE Std 1159-2009, IEEE Recommended Practice for Monitoring Electric Power Quality (2009).

Es de vital importancia entender la implicación de dichas características. Dependiendo del momento en el cual se recogen los datos unos atributos pueden ser más útiles que otros a la hora de identificar perturbaciones electromagnéticas.

Es decir, si se trata de un estudio en un periodo estacionario, la norma recoge los atributos: amplitud, frecuencia, espectro, modulación, impedancia de la fuente, profundidad de muesca y el área de la muesca. Por otro lado, si se abarca un periodo no estacionario, los indicadores de interés son: tasa de subida, amplitud, duración, espectro, frecuencia, tasa de ocurrencia, potencial energético e impedancia de la fuente (IEEE, 2009). El ser capaces de identificar estos factores explica o, mejor dicho, se relaciona directamente con mermas o puntos de fallos en la generación de potencia eléctrica.

Por lo tanto, por medio de la monitorización, se es capaz de detectar anomalías en la red eléctrica mediante la observación de fenómenos de calidad de energía. Estas pueden ser las variaciones de RMS (valor eficaz) de tensión, interrupciones, desequilibrio, distorsión en

forma de onda, interarmónicos, fluctuaciones de tensión, *flicker* y transitorios. Es decir, con estos indicadores se puede entender y comprender el funcionamiento normal de la fuente y/o convertidores, y observar discrepancias o desviaciones que se salen de lo común.

A continuación, se observa una tabla con las categorías y características típicas de los fenómenos electromagnéticos en los sistemas eléctricos.

Figura 2. Categorías y características típicas de los fenómenos electromagnéticos en sistemas eléctricos de potencia

Categories	Typical spectral content	Typical duration	Typical voltage magnitude
1.0 Transients			
1.1 Impulsive			
1.1.1 Nanosecond	5 ns rise	< 50 ns	
1.1.2 Microsecond	1 μ s rise	50 ns–1 ms	
1.1.3 Millisecond	0.1 ms rise	> 1 ms	
1.2 Oscillatory			
1.2.1 Low frequency	< 5 kHz	0.3–50 ms	0–4 pu
1.2.2 Medium frequency	5–500 kHz	20 μ s	0–8 pu
1.2.3 High frequency	0.5–5 MHz	5 μ s	0–4 pu
2.0 Short duration variations			
2.1 Instantaneous			
2.1.1 Sag		0.5–30 cycles	0.1–0.9 pu
2.1.2 Swell		0.5–30 cycles	1.1–1.8 pu
2.2 Momentary			
2.2.1 Interruption		0.5 cycles–3 s	< 0.1 pu
2.2.2 Sag		30 cycles–3 s	0.1–0.9 pu
2.2.3 Swell		30 cycles–3 s	1.1–1.4 pu
2.3 Temporary			
2.3.1 Interruption		3 s–1 min	< 0.1 pu
2.3.2 Sag		3 s–1 min	0.1–0.9 pu
2.3.3 Swell		3 s–1 min	1.1–1.2 pu
3.0 Long duration variations			
3.1 Interruption, sustained		> 1 min	0.0 pu
3.2 Undervoltages		> 1 min	0.8–0.9 pu
3.3 Overvoltages		> 1 min	1.1–1.2 pu
4.0 Voltage imbalance		steady state	0.5–2%
5.0 Waveform distortion			
5.1 DC offset		steady state	0–0.1%
5.2 Harmonics	0–100th H	steady state	0–20%
5.3 Interharmonics	0–6 kHz	steady state	0–2%
5.4 Notching		steady state	
5.5 Noise	broad-band	steady state	0–1%
6.0 Voltage fluctuations	< 25 Hz	intermittent	0.1–7%
7.0 Power frequency variations		< 10 s	


Fuente: IEEE, IEEE Std 1159-2009, IEEE Recommended Practice for Monitoring Electric Power Quality (2009).

Según dichos fenómenos, se puede distinguir distintos indicadores por ámbito.

- **Indicadores de magnitud: sag, swell, interrupción, sobretensión y subtenensión**

Adentrándonos en estos conceptos, se observa que son distintos entre ellos. En primer lugar, una subtenensión se entiende cuando tiene lugar una disminución de la tensión eficaz (RMS) a menos del 90% de la tensión nominal. Por otro lado, la sobretensión se da cuando se experimenta un aumento de dicha tensión eficaz a más del 110 % de la tensión nominal (Sedaghati, y otros, 2013). En muchas ocasiones estos sucesos pueden ser notorios en el impacto del negocio, sin embargo, otro fenómeno como el “sag” o “hueco de tensión” pueden pasar desapercibidos en un momento dado. Estos se caracterizan por una reducción repentina de la tensión en un punto del sistema eléctrico, seguida de la recuperación en un breve intervalo de tiempo. Concretamente, desde medio ciclo hasta unos pocos segundos (Sedaghati, y otros, 2013).

Figura 3. Ejemplo de un hueco de tensión.



Fuente: Adaptado de la figura “An example of voltage sag”, en *International Journal of Scientific Research and Management*.

Bien es cierto que de acuerdo con la norma *IEEE Std 1159* se considera que “un hueco de tensión es una variación de la tensión eficaz de duración superior a $\frac{1}{2}$ ciclo e inferior a 1 minuto, con una tensión remanente comprendida entre el 10 % y el 90 % de la tensión nominal” (IEEE, 2009). Es decir, toda aquella subtenensión (y sobretensión) sostenida en el tiempo puede producir una interrupción.

En cambio, también puede experimentarse un *swell*, el cual es una sobretensión temporal de corta duración por encima del valor nominal. Normalmente entre 1,1 y 1,8 p.u., durante 0,5 ciclos a 1 minuto.

- **Indicadores espectrales: armónicos, interarmónicos y distorsión en forma de onda**

En condiciones ideales, la tensión y la corriente en una red eléctrica deberían presentar formas de onda perfectamente sinusoidales y oscilar únicamente a la frecuencia fundamental del

sistema. Sin embargo, en redes reales aparecen componentes espectrales adicionales que alteran dicha forma de onda. Entre ellas destacan los armónicos, definidos como componentes cuya frecuencia es un múltiplo entero de la frecuencia fundamental (Arcila, s. f.).


La presencia de armónicos está asociada principalmente al funcionamiento de cargas no lineales, es decir, equipos cuya corriente absorbida no varía de forma proporcional con la tensión aplicada (Diego García, 2006). En estos casos, aunque la tensión de alimentación sea aproximadamente sinusoidal, la corriente demandada presenta una forma no sinusoidal, normalmente con pulsos o variaciones irregulares. Como consecuencia, esta corriente contiene componentes armónicos.

Cuando estas corrientes armónicas circulan a través de la impedancia de la red, producen caídas de tensión también armónicas, lo que provoca la deformación de la onda de tensión en el punto de suministro. Por tanto, la distorsión no solo afecta a la corriente consumida por la carga no lineal, sino también a la calidad de la tensión que recibe el resto de los equipos conectados a la red.

Junto con los armónicos, también pueden aparecer interarmónicos, que son componentes de frecuencia que no son un múltiplo entero de la fundamental. Más en detalle, se pueden dar especialmente en frecuencias discretas o con un alto espectro.

Tanto armónicos como interarmónicos constituyen indicadores espectrales relevantes para la detección de anomalías en la red, ya que permiten identificar perturbaciones asociadas al uso de electrónica de potencia, convertidores e interacciones no ideales entre generación, carga y red.

Figura 4. Esquema de generación y propagación de armónicos en redes de distribución eléctrica



Fuente: (Diego García, 2006).

- **Indicadores de simetría: desequilibrio de tensión/corriente**

Otro aspecto de especial relevancia en el análisis de la calidad de la energía eléctrica es la simetría de las magnitudes de tensión y corriente. En los dispositivos de electrónica de potencia, la corriente se transfiere de una fase a otra mediante procesos de conmutación. Durante dicho proceso, puede originarse un cortocircuito transitorio entre fases, fenómeno especialmente significativo en convertidores trifásicos.

En este contexto, la severidad de la perturbación depende fundamentalmente de la inductancia de la fuente y de la inductancia de aislamiento existente entre el convertidor y el punto en el que se efectúa la medición. De este modo, la evaluación del desequilibrio de tensión y corriente en un generador, tanto en condiciones de funcionamiento en vacío como ante condiciones equivalentes a cortocircuito, permite verificar si se mantiene dentro de márgenes admisibles y, al mismo tiempo, detectar posibles anomalías asociadas al comportamiento del propio generador, de los convertidores o de su interacción con la red. Tal y como se remite en el proyecto de investigación (Iglesias, 2019) “según el estándar IEEE 1159-20144, el desbalance de voltaje permisible para un generador es del 3% y el desbalance de corriente permisible es del 5%”.

- **Indicadores dinámicos: transitorios, fluctuaciones de tensión**

Además de las perturbaciones de carácter estacionario o espectral, en una red eléctrica existen fenómenos de naturaleza temporal cuya evolución cambia rápidamente con el tiempo. Estos fenómenos constituyen los llamados indicadores dinámicos, ya que describen alteraciones transitorias o variaciones del sistema vinculadas a maniobras, cambios bruscos de carga, fallos o desequilibrios entre generación y demanda.

Los transitorios son perturbaciones de corta duración que se manifiestan como cambios súbitos en la tensión, la corriente o ambas. Por otro lado, las fluctuaciones de tensión son variaciones repetitivas o intermitentes del valor eficaz de la tensión, normalmente alrededor de su valor nominal. A diferencia de los transitorios, no se caracterizan por un cambio abrupto, sino por oscilaciones de amplitud relativamente pequeña que se producen de forma continua o recurrente.

2.1.5. Redes Eléctricas Inteligentes: *SmartGrids*

La complejidad creciente de los sistemas eléctricos actuales ha favorecido el desarrollo de las denominadas redes eléctricas inteligentes o *smart grids*.


El concepto de red inteligente se entiende como “una red de electricidad que puede integrar de una forma costo-eficiente el comportamiento y acciones de todos los usuarios conectados a ella, incluyendo generadores, consumidores y aquellos agentes que consumen y generan al tiempo, para asegurar un sistema de potencia sustentable y eficiente con pérdidas y altos niveles de calidad, seguridad y suministro de energía” (Atencia De la Ossa, 2021).

Por otro lado, según la FNMT, “una red inteligente es un sistema de red eléctrica evolucionada, capaz de gestionar la demanda de electricidad de una manera sostenible, fiable y económica. Las redes inteligentes parten del uso de una infraestructura avanzada, enfocada a facilitar la integración de todos los actores involucrados” (Moneda, 2026).

El aspecto más característico de una *smart grid* es la bidireccionalidad en los flujos de energía e información. Esta arquitectura surge con el propósito de integrar de manera eficiente la generación distribuida y los sistemas de almacenamiento, permitiendo una operación más flexible, descentralizada e inteligente de la red eléctrica. Para ello, se apoya en mecanismos avanzados de control, comunicación y monitorización, gracias a los cuales los usuarios dejan de ser únicamente consumidores y pasan a desempeñar también un papel activo como generadores, almacenadores e inyectores de energía a la red (Díaz Andrade & Hernández, 2011).

El auge de nuevas tecnologías y la optimización en la medición de procesos, es decir, la digitalización de los sistemas eléctricos mediante la incorporación de sensores, sistemas de comunicación y herramientas cada vez más avanzadas de monitorización, ha favorecido una gran disponibilidad de grandes volúmenes de datos. Esto supone un punto de inflexión ya que ese análisis masivo de datos, especialmente en un proyecto de Inteligencia Artificial, ayuda en gran medida al uso de técnicas de análisis predictivo y la detección de anomalías con el fin de mejorar la supervisión y mantenimiento de los sistemas de generación eléctrica.

Figura 5. Comparación entre el sistema eléctrico tradicional y el sistema eléctrico de próxima generación con generación distribuida



Fuente: (Díaz Andrade & Hernández, 2011).

2.2. ESTADO DEL ARTE

2.2.1. Marco General de la Detección de Anomalías en Sistemas Energéticos

En términos generales, una anomalía puede entenderse como un patrón de datos que se desvía del comportamiento esperado del sistema, poniendo de manifiesto un evento no habitual (Valls, Ramírez, Delgado, & Romeral, 2025).

En el ámbito energético, las anomalías pueden tener su origen en múltiples causas, entre ellas fallos de equipos, errores humanos, degradación de componentes, eventos meteorológicos, perturbaciones operativas o amenazas de ciberseguridad (Aghazadeh Ardebili, y otros, 2024).

La identificación temprana de estas anomalías resulta especialmente importante, ya que permite anticipar problemas que afectan a la fiabilidad, la continuidad del suministro, la seguridad y la eficiencia de los sistemas (Aghazadeh Ardebili, y otros, 2024). Por ello, en los últimos años, el desarrollo de herramientas capaces de detectar patrones anómalos en infraestructuras energéticas se ha consolidado como una línea de investigación de creciente relevancia. Esto se ha visto impulsado por la digitalización progresiva de las infraestructuras energéticas y el incremento de datos operativos disponibles en tiempo real (Aghazadeh Ardebili, y otros, 2024) (Valls, Ramírez, Delgado, & Romeral, 2025), tal y como se ha comentado anteriormente.

En este nuevo escenario, las redes eléctricas, los sistemas de generación y otros activos energéticos están generando grandes volúmenes de información procedente de sensores y plataformas de monitorización. Esta disponibilidad de datos ha favorecido el desarrollo de estrategias basadas en datos, capaces de complementar o sustituir enfoques tradicionales de supervisión, menos flexibles ante condiciones de operación cambiantes (Valls, Ramírez, Delgado, & Romeral, 2025).

Por consiguiente, las tendencias más recientes reflejan un desplazamiento desde enfoques exclusivamente basados en reglas hacia soluciones basadas en datos, especialmente en aplicaciones donde la complejidad del sistema y la variabilidad de las condiciones de operación dificultan una modelización exacta (Valls, Ramírez, Delgado, & Romeral, 2025). Este marco general resulta especialmente relevante en el caso de los sistemas fotovoltaicos, donde la detección temprana de anomalías y fallos desempeña un papel clave en la mejora del rendimiento, la seguridad y la fiabilidad de las instalaciones (Liu, y otros, 2025).

2.2.2. Contexto Aplicado a la Generación de Energía Solar Fotovoltaica

Dentro del conjunto de aplicaciones energéticas en las que se ha desarrollado la detección de anomalías, la generación de energía solar fotovoltaica ocupa un lugar cada vez más relevante. La rápida evolución de las tecnologías fotovoltaicas y la expansión de este tipo de instalaciones han incrementado la necesidad de estrategias de monitorización más eficientes, capaces de garantizar una operación fiable y un rendimiento energético óptimo (Liu, y otros, 2025).

En la misma línea, (Valls, Ramírez, Delgado, & Romeral, 2025) señala que la energía solar fotovoltaica se ha convertido en una tecnología ampliamente extendida, favorecida tanto por la reducción del coste de sus componentes como por el impulso regulatorio hacia la implantación de soluciones renovables en edificios residenciales, comerciales e industriales.

Todo este contexto convierte a los sistemas fotovoltaicos en un caso de especial interés dentro de la detección de anomalías, ya que su funcionamiento depende de una combinación compleja de factores eléctricos, meteorológicos y operativos.

A diferencia de otros sistemas energéticos con condiciones de operación relativamente estables, la generación fotovoltaica está fuertemente condicionada por variables ambientales como la irradiancia, la temperatura, el viento o la nubosidad (Liu, y otros, 2025). El comportamiento del sistema también depende de parámetros propios de la instalación, como

la orientación, la inclinación, los inversores y otros elementos del sistema. Esta combinación de dependencia ambiental y complejidad técnica hace que la supervisión del comportamiento fotovoltaico precise metodologías específicas.

Desde una perspectiva aplicada, la detección temprana de anomalías y fallos en instalaciones fotovoltaicas permite reducir pérdidas de producción, minimizar tiempos de inactividad, optimizar las tareas de operación y mantenimiento y prevenir riesgos de seguridad (Liu, y otros, 2025). Del mismo modo, contribuye a una implantación más sostenible de esta tecnología y a la reducción de los costes energéticos para el usuario final (Aghazadeh Ardebili, y otros, 2024).

2.2.3. Tipología de Anomalías y Fallos

El estudio de la generación fotovoltaica no puede limitarse a una consideración general de las anomalías, sino que requiere identificar con precisión qué tipos de fallos pueden aparecer, cómo se manifiestan y qué impacto tienen sobre el funcionamiento del sistema. La literatura revisada muestra que las desviaciones del comportamiento esperado pueden responder a fenómenos muy diversos, asociados tanto a la propia conversión fotovoltaica como a los componentes eléctricos y a las condiciones de operación de la instalación (Liu, y otros, 2025) (Rashed, 2022).

Por este motivo, antes de abordar los métodos de detección y diagnóstico, resulta necesario establecer una clasificación clara de los principales fallos y anomalías presentes en sistemas fotovoltaicos, ya que dicha tipología constituye la base para comprender su detección, interpretación y tratamiento posterior.

Desde un punto de vista conceptual, la bibliografía consultada distingue entre anomalías puntuales, contextuales y colectivas (Valls, Ramírez, Delgado, & Romeral, 2025):

- **Anomalías puntuales:** Observaciones individuales claramente anómalas respecto al comportamiento esperado del sistema. En el caso que nos ocupa, pueden corresponder, por ejemplo, a una medida instantánea de corriente, tensión o potencia que se aparta bruscamente del patrón normal.
- **Anomalías contextuales:** Desviaciones que solo pueden considerarse anómalas si se interpretan dentro de su contexto operativo o ambiental. En fotovoltaica, una misma

potencia puede ser normal o anómala, por ejemplo, según la temperatura o la hora del día.

- Anomalías colectivas: Conjuntos de datos que, analizados en bloque, revelan un comportamiento anormal, aunque cada punto por separado no parezca extremo. En sistemas fotovoltaicos son útiles para detectar degradaciones progresivas o patrones anómalos sostenidos de producción.

Más allá de la clasificación conceptual de las anomalías, en el ámbito fotovoltaico resulta útil organizar los fallos y anomalías según distintos criterios técnicos, entre ellos su localización dentro de la instalación, su severidad y su origen funcional (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025), (Taghezouit, Harrou, Sun, & Merrouche, 2024).

1. Según su localización en la instalación (Liu, y otros, 2025).

1.1. Fallos en el lado DC

Son aquellos asociados a los módulos fotovoltaicos, cableado, conectores y demás elementos previos al inversor. Dentro de esta categoría se incluyen:

- Fallos eléctricos: Cortocircuitos, fallos de circuito abierto o fallos a tierra.
- Fallos de conexión: Por ejemplo, daños en conductores y problemas en conexiones o empalmes.
- Fallos a nivel de módulo: Degradación, suciedad, corrosión, grietas, sombreado parcial y fallo de diodos, entre otras causas.

1.2. Fallos en el lado AC

Son los asociados al inversor, la conversión DC/AC y la interacción con la red eléctrica. Entre ellos se encuentran:

- Fallos de inversor: Pérdida de eficiencia, apagados súbitos, ausencia de salida en corriente alterna o fallos internos del equipo.
- Problemas de operación: *clipping* y otras limitaciones asociadas a la capacidad del inversor.
- Problemas de red: desequilibrios de fase, restricciones de red, desconexiones y apagones.

2. Según su severidad (Liu, y otros, 2025).

2.1. *Soft faults*

Son fallos no críticos que no provocan una parada inmediata del sistema, pero sí reducen su rendimiento. En esta categoría se incluyen principalmente el sombreado parcial, la suciedad, la degradación y la corrosión en fases iniciales.

2.2. *Hard faults*

Son fallos críticos que producen una pérdida importante de funcionalidad, parada del sistema o riesgo para la seguridad. Entre ellos destacan los fallos de circuito abierto, cortocircuitos, fallos a tierra o fallos severos en el inversor.

3. Según su origen funcional

3.1. Anomalías ambientales y de operación (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025)

Son las relacionadas con condiciones externas o de funcionamiento de la instalación, como el sombreado, la suciedad, la temperatura elevada y desajustes operativos.

3.2. Anomalías asociadas al envejecimiento o deterioro físico (Aghazadeh Ardebili, y otros, 2024), (Liu, y otros, 2025)

Incluyen procesos de degradación progresiva de componentes, tales como la degradación de módulos, microgrietas, corrosión o delaminación.

3.3. Anomalías eléctricas (Liu, y otros, 2025)

Son las vinculadas al comportamiento anormal de magnitudes eléctricas o a fallos de los circuitos, como los circuitos abiertos, cortocircuitos, fallos a tierra o arcos eléctricos

3.4. Anomalías en electrónica de potencia y red (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025)

Agrupan problemas relacionados con inversores, convertidores, *clipping*, o una interacción anómala con la red.

2.2.4. Fuentes de Datos para la Detección de Anomalías

Una vez establecida la clasificación de los principales fallos y anomalías que pueden afectar a los sistemas fotovoltaicos, resulta necesario analizar qué información puede utilizarse para identificarlos en la práctica. La detección y el diagnóstico de estas desviaciones dependen en

gran medida de la disponibilidad, calidad y naturaleza de los datos registrados durante la operación de la instalación, ya que no todos los tipos de fallo se manifiestan del mismo modo ni requieren las mismas variables para su detección (Liu, y otros, 2025).

Por ello, este subapartado se centra en las principales fuentes de datos disponibles para la detección de anomalías en sistemas fotovoltaicos, prestando especial atención a aquellas que permiten desarrollar estrategias de monitorización eficaces (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025).

La literatura reciente pone de manifiesto que la evaluación de la fiabilidad fotovoltaica puede apoyarse en datos ambientales, datos de operación, curvas I-V, imágenes de inspección y datos de materiales, cada uno de ellos vinculado a tareas concretas de diagnóstico, predicción y mantenimiento (Chen, y otros, 2025). De forma general, los datos empleados en el ámbito de la energía solar fotovoltaica pueden agruparse en varias categorías.

- Datos eléctricos.

Constituyen la fuente de información más utilizada para la detección de fallos y anomalías en sistemas fotovoltaicos. Entre las variables más frecuentes se encuentran la corriente, la tensión y la potencia generadas a distintos niveles de la instalación, como el módulo o el inversor. Estos datos permiten detectar tanto desviaciones globales de rendimiento como fallos eléctricos concretos, entre ellos circuitos abiertos, cortocircuitos, fallos de inversor o anomalías relacionadas con el sombreado y la degradación (Liu, y otros, 2025).

Dentro de este grupo, también tienen especial relevancia las curvas I-V, ya que proporcionan una representación más detallada del comportamiento eléctrico del sistema (Liu, y otros, 2025). Éstas permiten identificar pérdidas de rendimiento, desviaciones respecto al comportamiento esperado y posibles problemas de sombreado o desajuste entre células o módulos (Chen, y otros, 2025). No obstante, su utilización suele exigir información técnica adicional sobre el módulo y condiciones de medida más controladas, por lo que no siempre son la opción más sencilla en entornos reales de operación continua.

- Datos meteorológicos.

Los datos meteorológicos son esenciales para interpretar correctamente el comportamiento de una instalación fotovoltaica. Variables como la irradiación, la temperatura ambiente, la temperatura del módulo o la nubosidad permiten contextualizar

la producción eléctrica y distinguir entre una baja generación normal y una anomalía real (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025).

La literatura revisada destaca que muchos métodos de detección necesitan combinar datos eléctricos y meteorológicos para estimar el comportamiento esperado del sistema. Esto permite calcular indicadores de rendimiento, modelar la producción teórica o comparar la respuesta observada con la prevista bajo determinadas condiciones de irradiación y temperatura (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025). Además, este tipo de variables no solo condiciona la producción instantánea, sino que también influye en los procesos de degradación (Chen, y otros, 2025).

Como ejemplo de aplicación práctica, (Syamsuddin, Adhi, Kusumawardhani, Prahasto, & Widodo, 2024) emplean con éxito datos SCADA reales de una planta fotovoltaica de 3.5 MWp, incluyendo irradiancia, temperatura ambiente, humedad, velocidad y dirección del viento, así como potencia activa AC, poniendo en manifiesto su importancia (Syamsuddin, Adhi, Kusumawardhani, Prahasto, & Widodo, 2024).

- Información de configuración del sistema.

Además de los datos medidos en operación, diversos trabajos subrayan la importancia de disponer de información estructural y de diseño de la instalación. En este grupo se incluyen variables como la potencia nominal, la localización geográfica, la orientación, la inclinación, el tipo de módulo, las características del inversor y otros parámetros de diseño.

Esta información resulta necesaria para modelar el comportamiento esperado del sistema y para interpretar adecuadamente las diferencias entre distintas instalaciones. La ausencia de algunos de estos parámetros puede limitar considerablemente la aplicabilidad de ciertos métodos de predicción (Liu, y otros, 2025).

- Registros de operación y mantenimiento.

Otra fuente de información relevante la constituyen los registros de operación y mantenimiento. Estos datos pueden incluir incidencias, reparaciones, sustitución de componentes, inspecciones previas o histórico de fallos.

Aunque no siempre están disponibles de manera estructurada, su valor es especialmente alto para validar algoritmos e interpretar si una anomalía detectada corresponde realmente a un fallo físico conocido.

En este sentido, uno de los problemas señalados por la literatura es que muchos trabajos se desarrollan con datos simulados o de laboratorio y no siempre cuentan con un historial real de mantenimiento asociado (Liu, y otros, 2025). Esto dificulta la validación en escenarios reales y limita la disponibilidad de datos etiquetados de alta calidad.

- Códigos de fallo e información del inversor.

En algunas instalaciones, los inversores proporcionan códigos de error o registros de eventos que pueden servir como apoyo para la detección de anomalías. Estos códigos resultan útiles para identificar incidencias relacionadas con el propio inversor o con la interacción con la red. Sin embargo, su utilidad es limitada, ya que no están estandarizados entre fabricantes (Liu, y otros, 2025).

- Datos de imagen.

Los datos de imagen, obtenidos mediante inspección visual, cámaras térmicas o técnicas específicas de caracterización, también se emplean en algunas estrategias de diagnóstico de sistemas fotovoltaicos. Este tipo de información resulta especialmente útil para identificar defectos físicos concretos, como *hot spots*, grietas, delaminación, corrosión o fallos visibles en módulos (Liu, y otros, 2025), (Jalal, Khalil, & Ul-Haq, 2024).

En el diagnóstico visual de estos defectos, las fuentes de imagen más utilizadas son la termografía infrarroja, la electroluminiscencia y la fotoluminiscencia, ya que permiten revelar anomalías que no siempre resultan evidentes en una inspección convencional (Jalal, Khalil, & Ul-Haq, 2024).

Sin embargo, la revisión de (Liu, y otros, 2025) subraya que la captura, el almacenamiento y el procesamiento de este tipo de datos implican un coste elevado, lo que dificulta su implementación generalizada en sistemas distribuidos pequeños y medianos. Por esta razón, aunque las técnicas basadas en imagen pueden ofrecer un alto nivel de detalle para el diagnóstico, en muchos casos las estrategias más viables siguen siendo aquellas basadas en datos de bajo coste, como las series temporales eléctricas y meteorológicas (Liu, y otros, 2025).

Tras lo expuesto, se evidencia que la disponibilidad de *datasets* públicos constituye otro aspecto clave en este ámbito. La literatura reciente recoge diversos conjuntos de datos de series temporales aplicables a la detección y diagnóstico de fallos en sistemas fotovoltaicos,

incluyendo ejemplos como *PVDAQ*, *NIST*, *DKASC* o *UNISOLAR*, entre otros (Liu, y otros, 2025). Estos *datasets* difieren en número de variables, resolución temporal, número de sistemas monitorizados y presencia o no de fallos etiquetados (Liu, y otros, 2025), (Chen, y otros, 2025) (Ziya, Smart Meter Electricity Consumption Dataset, 2023).

Aun cumpliendo todos los requisitos anteriormente citados, es evaluable a descartarse *datasets* porque se precisa que estos tengan una explicación de variables de manera interpretable para que se haga un uso adecuado de las mismas. Por otro lado, si tienen las etiquetas que representen un fallo de un tipo, para dicha anomalía también debe de ser argumentado el cómo se ha llegado a la conclusión aportada (PythonAfroz, s. f.).

Por tanto, aunque hay repositorios web que permiten localizar conjuntos de datos relacionados con energía, redes inteligentes y sistemas fotovoltaicos, su utilización en estudios de detección de anomalías requiere una evaluación crítica previa. La ausencia de documentación técnica suficiente, la falta de trazabilidad sobre el origen de los datos, el uso de simulaciones no justificadas, el reducido volumen de registros o la escasa interpretabilidad de las etiquetas pueden limitar su validez para entrenar, validar y comparar modelos de diagnóstico de fallos en contextos reales.

A su vez, la literatura coincide en señalar que sigue existiendo una escasez notable de *datasets* públicos de calidad con fallos correctamente etiquetados. Este problema constituye una limitación importante para el desarrollo y comparación de métodos avanzados, especialmente aquellos basados en aprendizaje supervisado (Liu, y otros, 2025). Además, la heterogeneidad y fragmentación de los distintos *datasets*, junto con la ausencia de metadatos completos y las dificultades de acceso, complican la comparación entre estudios. Por otro lado, reducen también su reproducibilidad y dificultan la transferencia de modelos a contextos reales distintos de aquellos en los que fueron entrenados (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025), (Chen, y otros, 2025).

2.2.5. Métodos de Detección y Diagnóstico de Anomalías

Una vez identificadas las principales fuentes de datos disponibles para la monitorización de sistemas fotovoltaicos, el siguiente paso consiste en analizar cómo puede aprovecharse esta información para detectar y diagnosticar fallos y anomalías.

La literatura revisada muestra que la elección del método depende en gran medida del tipo de datos accesibles, del nivel de detalle requerido y de la naturaleza del problema que se pretende identificar (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025). Por ello, a continuación, se presentan los principales métodos de detección y diagnóstico de fallos y anomalías en sistemas fotovoltaicos.

- **Métodos estadísticos y basados en modelos**

Los métodos estadísticos y basados en modelos constituyen una de las aproximaciones más tradicionales en la detección de anomalías y fallos en sistemas fotovoltaicos. Su funcionamiento se basa, en general, en comparar el comportamiento real de la instalación con un comportamiento esperado obtenido a partir de modelos físicos, simulaciones o indicadores de rendimiento, de modo que las desviaciones respecto a ese patrón de referencia se interpretan como posibles anomalías (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025).

Aunque estos métodos suelen ser relativamente simples, interpretables y adecuados cuando se dispone de conocimiento del sistema y de variables meteorológicas, su precisión puede verse limitada cuando las condiciones de operación son muy variables o cuando faltan datos de configuración detallados (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025).

Desde una perspectiva más general, se ha señalado que este tipo de métodos requiere una validación y calibración cuidadosas del modelo de referencia, ya que la precisión del diagnóstico depende en gran medida de la calidad de las medidas disponibles y de la capacidad del modelo para reproducir el comportamiento normal del sistema (Taghezouit, Harrou, Sun, & Merrouche, 2024).

Como ejemplo de aplicación online de este tipo de enfoques, en Lazzaretti et al. (2020) se propone un método de detección de fallos basado en un modelo dinámico lineal ARX. Este modelo estima la potencia generada a partir de su histórico y de una variable de entrada externa, en este caso la irradiancia. Posteriormente, las anomalías se detectan a través del análisis de residuos y el uso de un umbral adaptativo.

- **Métodos basados en curvas I-V**

Los métodos basados en curvas I-V se centran en el análisis de la relación entre corriente y tensión para caracterizar el comportamiento eléctrico de los elementos de la instalación

fotovoltaica. Estas curvas permiten identificar alteraciones asociadas a anomalías como las causadas por sombreado, suciedad, degradación o circuitos abiertos, entre otros (Liu, y otros, 2025).

Sin embargo, su aplicación suele requerir información técnica específica sobre los módulos y condiciones de medida más controladas, por lo que, aunque son muy útiles para diagnóstico, no siempre resultan la opción más sencilla para una monitorización continua en instalaciones distribuidas (Liu, y otros, 2025).

- **Métodos de *machine learning* clásico**
 - **No supervisados**

Los métodos de *machine learning* no supervisados se emplean cuando no se dispone de datos etiquetados, lo que los hace especialmente atractivos en fotovoltaica, donde, tal y como se ha comentado previamente, los registros de fallos reales correctamente etiquetados suelen ser escasos (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025).

Estos enfoques buscan identificar patrones anómalos a partir de la estructura interna de los datos, sin necesidad de conocer de antemano qué observaciones corresponden a condiciones sanas o defectuosas.

Dentro de esta categoría, la literatura recoge algoritmos como:

- *K-means*: Es uno de los algoritmos de aprendizaje no supervisado más utilizados para realizar tareas de *clustering* o agrupamiento. Su objetivo es dividir un conjunto de datos en un número predeterminado de grupos (*k clusters*), de forma que las observaciones pertenecientes a un mismo grupo sean lo más similares posible entre sí y, al mismo tiempo, lo más diferentes posible de las observaciones de otros grupos (Van Der Post & Smith, 2023).

El número de clústeres es necesario imponerlo al algoritmo, el cual representa cada grupo mediante un centroide, que corresponde al promedio de todas las observaciones asignadas a dicho grupo (habrá *k* centroides), cada dato se designa al centroide más cercano (normalmente mínima distancia euclídea). Cuando todos los datos están asignados se recalculan los centroides y se realiza el mismo procedimiento hasta que los centroides dejan de cambiar significativamente o se alcanza un número máximo de iteraciones.

- *Hierarchical clustering*: El *clustering* jerárquico es una técnica de aprendizaje no supervisado utilizada para agrupar observaciones según su similitud. No hay que especificar el número de clústeres, sino que construye una estructura jerárquica de agrupamientos que puede representarse gráficamente mediante un dendrograma (Van Der Post & Smith, 2023).

La idea principal consiste en organizar los datos en una jerarquía de grupos, donde los clústeres más similares se combinan progresivamente hasta formar un único grupo que contiene todos los datos, o bien, partir de un único grupo y dividirlo sucesivamente en grupos más pequeños.

- *DBSCAN*: Este es un algoritmo de aprendizaje no supervisado que se basa en la densidad. Es decir, identifica grupos de datos a partir de regiones donde existe una alta concentración de puntos, separadas por zonas de menor densidad (Deng, 2020). Cabe destacar que utiliza el *epsilon* que define el radio de vecindad alrededor de cada punto y el *minpts* que establece el número mínimo de puntos necesarios para considerarse una región. Por lo tanto, se agrupan o “descubren” los clústeres sin necesidad de especificar previamente el número de grupos. Además, los puntos situados en regiones de baja densidad pueden ser identificados como ruido o valores atípicos.
- *Fuzzy c-means*: Es un algoritmo de *clustering* difuso donde cada dato puede pertenecer simultáneamente a varios grupos con distintos grados de pertenencia. Proporcionan una representación más flexible de los datos cuando existen fronteras poco definidas entre clústeres (Bezdek, 1981).

Se debe tener en cuenta que hay que definir el número de clústeres previamente. Al pertenecer a varios clústeres su grado de pertenencia se expresa en porcentaje o en un rango de 0 a 1, donde el sumatorio de los distintos grados de pertenencia deben de hacer del total de 1.

- *Spectral clustering*: Es una técnica de aprendizaje no supervisado que utiliza conceptos de la teoría de grafos y del álgebra lineal para agrupar observaciones. Pretende proyectar los datos a un espacio donde los clústeres puedan separarse más fácilmente, aunque provengan de estructuras complejas.

La idea fundamental de este algoritmo consiste en representar el conjunto de datos en un grafo en el cual cada dato es un nodo, las aristas representan la similitud entre los datos y cuanto mayor es la similitud entre dos datos, mayor es el peso de la conexión entre ellas (Ng, Jordan, & Weiss, 2002).

Una vez construido el grafo, el algoritmo analiza su estructura utilizando los autovalores y autovectores de una matriz denominada *Laplaciana* del grafo. Estos autovectores permiten proyectar los datos a un nuevo espacio donde los clústeres son más fáciles de separar, por ejemplo, con *K-means*.

- *Isolation Forest*: Es un método no supervisado de detección de anomalías que se basa en que estas anomalías son escasas, presentan valores de atributos diferentes al resto de los datos y son más fáciles de aislar. De esta forma, el algoritmo construye un conjunto de árboles de aislamiento mediante particiones aleatorias de las variables y sus valores (Liu, Ting, & Zhou, 2008).

Este enfoque es eficiente en tiempo y memoria ya que a la hora de modelar no utiliza medidas de distancia o densidad, lo cual es muy interesante para conjuntos de datos grandes o de alta dimensionalidad.

Estas técnicas son utilizadas tanto para detectar desviaciones en variables eléctricas y meteorológicas, como para agrupar comportamientos anómalos (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025).

Su principal fortaleza es que los modelos resultantes permiten trabajar en escenarios con poca supervisión. Sin embargo, su capacidad de diagnóstico suele ser más limitada y la interpretación de los resultados depende en gran medida del preprocesado y de la elección adecuada de variables.

○ **Semisupervisados**

Los métodos semisupervisados tratan de resolver una situación intermedia, en la que existe una pequeña cantidad de datos etiquetados junto con un volumen mayor de datos no etiquetados (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025).

En sistemas fotovoltaicos, esta aproximación permite aprovechar el conocimiento disponible sobre algunos fallos sin renunciar a la gran cantidad de datos operativos no etiquetados registrados en condiciones reales.

Estos métodos pueden combinar técnicas de *clustering* para generar etiquetas iniciales, modelos autoentrenados, arquitecturas de aprendizaje autosupervisado por medio de *encoder-decoder* o estrategias de pseudoetiquetado (Liu, y otros, 2025).

Su interés radica en que reducen la dependencia de *datasets* completamente etiquetados, aunque su rendimiento está condicionado por la calidad de las etiquetas iniciales y por la capacidad del modelo para generalizar a situaciones no vistas previamente.

○ **Supervisados**

Los métodos supervisados se apoyan en datos etiquetados, es decir, registros en los que se conoce si el sistema se encontraba en condición normal o presentaba un determinado fallo. Esta información permite entrenar modelos capaces de clasificar nuevas observaciones y, en algunos casos, identificar el tipo concreto de anomalía (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025).

En la literatura revisada destacan algoritmos como *SVM*, *KNN*, *Random Forest*, regresión lineal y diferentes combinaciones de modelos ensamblados. Estos pueden ser aplicados a tareas de detección y diagnóstico de anomalías causadas por sombreado, cortocircuitos, fallos de arco o degradación, entre otros (Liu, y otros, 2025).

Su principal ventaja es que, cuando se dispone de datos etiquetados suficientes y representativos, suelen ofrecer una alta precisión. Sin embargo, tal y como se ha comentado previamente, su aplicabilidad práctica se ve limitada por la escasez de *datasets* públicos con fallos correctamente anotados y por la dificultad de transferir modelos entrenados en laboratorio a instalaciones reales (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025).

● **Métodos de *deep learning***

Los métodos de *deep learning* han adquirido una importancia creciente en la detección de anomalías energéticas por su capacidad para aprender representaciones complejas directamente a partir de los datos, reduciendo la necesidad de ingeniería manual de variables (Aghazadeh Ardebili, y otros, 2024) (Valls, Ramírez, Delgado, & Romeral, 2025).

En el caso fotovoltaico, la literatura revisada recoge el uso de arquitecturas como *CNN*, *LSTM* y *autoencoders*, capaces de trabajar con series temporales o imágenes derivadas de señales eléctricas (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025). Estos enfoques se

aplican tanto a tareas de clasificación binaria como a escenarios más complejos de identificación multicategorica (Jalal, Khalil, & Ul-Haq, 2024).

Estos enfoques son especialmente útiles cuando las anomalías presentan patrones no lineales o dependencias temporales complejas, como ocurre en la generación fotovoltaica bajo condiciones ambientales cambiantes. No obstante, también presentan limitaciones relevantes, entre ellas una mayor demanda computacional, menor interpretabilidad y una fuerte dependencia de la disponibilidad de datos suficientes y bien estructurados para su entrenamiento (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025).

Por ejemplo, en (Syamsuddin, Adhi, Kusumawardhani, Prahasto, & Widodo, 2024) se propone un modelo LSTM aplicado a una planta fotovoltaica real, utilizando datos SCADA para aprender el comportamiento normal del sistema y detectar desviaciones mediante el análisis de residuos (Syamsuddin, Adhi, Kusumawardhani, Prahasto, & Widodo, 2024).

Por otro lado, (Miraftabzadeh, Longo, Leva, & Matera, 2025) presenta un *autoencoder* profundo no supervisado capaz de detectar anomalías en series temporales de potencia fotovoltaica con información insuficiente. Además, incorpora un mecanismo basado en DTW (*Dynamic Time Warping*), una técnica utilizada para alinear y comparar señales temporales, con el fin de localizar segmentos anómalos dentro de la señal (Miraftabzadeh, Longo, Leva, & Matera, 2025).

- **Métodos híbridos**

Los métodos híbridos combinan distintas técnicas con el objetivo de aprovechar las fortalezas de cada una y mejorar el rendimiento de detección y diagnóstico.

Estos enfoques representan una de las tendencias más destacadas de la investigación reciente, ya que permiten abordar mejor la diversidad de fallos y la complejidad de los datos energéticos (Valls, Ramírez, Delgado, & Romeral, 2025). En fotovoltaica, su utilidad resulta especialmente clara cuando se pretende combinar la interpretabilidad de ciertos métodos con la capacidad predictiva de otros (Liu, y otros, 2025).

Sin embargo, su diseño e implementación suelen ser más complejos y exigen una mayor validación en escenarios reales (Liu, y otros, 2025).

2.2.6. Limitaciones y Retos Abiertos

A pesar de la diversidad de métodos desarrollados para la detección y diagnóstico de fallos y anomalías en sistemas fotovoltaicos, la literatura revisada coincide en que todavía persisten limitaciones importantes que dificultan su aplicación generalizada en entornos reales. Por ello, resulta necesario identificar los principales retos abiertos que condicionan el avance de este campo y orientan futuras líneas de investigación (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025).

Tal y como se ha comentado en varias ocasiones, uno de los principales problemas señalados en la literatura es la escasez de *datasets* públicos con fallos etiquetados, especialmente en condiciones reales de operación. Esta limitación afecta de forma directa al desarrollo y validación de métodos supervisados, y obliga en muchos casos a recurrir a datos simulados o de laboratorio (Liu, y otros, 2025).

A ello se suma la baja transferibilidad de muchos modelos cuando se aplican fuera del entorno en el que fueron desarrollados. Los algoritmos entrenados con instalaciones concretas, condiciones controladas o configuraciones muy específicas no siempre mantienen su rendimiento en sistemas reales distintos, lo que reduce su aplicabilidad práctica (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025), (Syamsuddin, Adhi, Kusumawardhani, Prahasto, & Widodo, 2024).

Otro reto relevante es la heterogeneidad de métricas, variables y *datasets*, que dificulta la comparación objetiva entre estudios. Esta falta de homogeneidad complica la evaluación del verdadero rendimiento de los métodos propuestos y limita la posibilidad de establecer referencias comunes dentro del estado del arte (Valls, Ramírez, Delgado, & Romeral, 2025). A ello se añaden otros desafíos prácticos, como la variabilidad ambiental, la calidad desigual de los datos, la fragmentación de las bases disponibles, la ausencia de metadatos completos, las dificultades de acceso y la complejidad de identificar el origen real de ciertas pérdidas de rendimiento (Taghezouit, Harrou, Sun, & Merrouche, 2024), (Chen, y otros, 2025).

Finalmente, la literatura también subraya la limitada interpretabilidad de algunos modelos avanzados, especialmente en enfoques de *deep learning* o híbridos complejos. Aunque estos métodos pueden ofrecer buenos resultados, su uso en aplicaciones reales requiere no solo precisión, sino también robustez, trazabilidad y capacidad de explicación, aspectos que siguen

constituyendo un reto abierto en el ámbito fotovoltaico (Valls, Ramírez, Delgado, & Romeral, 2025), (Liu, y otros, 2025).

2.3. CONCLUSIONES

La revisión realizada pone de manifiesto que la detección de anomalías en sistemas de generación eléctrica es un problema de gran relevancia en el entorno actual. Más en especial en el entorno de energías renovables en donde se introducen nuevas fuentes de variabilidad e incertidumbre. Esto requiere de un control exhaustivo de supervisión, predicción y diagnóstico temprano de problemas.

En la literatura se ha visto que este problema se puede abordar desde varios puntos de vista, desde métodos estadísticos y basados en modelos hasta técnicas de *machine learning* y *deep learning*. Cada enfoque presenta unas características distintas en términos de necesidad de datos etiquetados, capacidad de generalizar y coste computacional, entre otros. Por tanto, cabe destacar que una comparativa de soluciones es interesante.

En este contexto, desarrollar un pipeline reproducible para modelar el comportamiento normal del sistema y detectar fallos, comparando distintos enfoques según la disponibilidad de los datos, supone una justificación clara de la documentación investigada. Un punto clave de esta forma de realizar el trabajo sería el aportar un valor metodológico al analizar de forma crítica qué soluciones son más adecuadas para la detección de anomalías en sistemas de generación eléctrica.

3. Objetivos concretos y metodología de trabajo

3.1.OBJETIVO GENERAL

El objetivo principal de este trabajo se centra en el estudio y comparación de varios modelos predictivos basados en inteligencia artificial. Se pretende trabajar bajo una fuente de datos sobre el contexto de la generación de energía eléctrica.

Asimismo, los modelos resultantes desarrollados y analizados no sólo pretenden ser predictivos, sino que se enfocan en la detección de las anomalías surgidas en los sistemas de generación eléctrica provenientes de paneles solares fotovoltaicos. Se pretende investigar y comprender la aplicabilidad de dichos modelos.

3.2.OBJETIVOS ESPECÍFICOS

Para el desarrollo del objetivo principal, se plantean varios subobjetivos concretos.

En primer lugar, se pretende evaluar la viabilidad de distintas fuentes de datos para el desarrollo de modelos predictivos de producción energética y de detección de anomalías en instalaciones fotovoltaicas. Asimismo, se busca comparar el rendimiento de diferentes modelos estadísticos y de inteligencia artificial, con el fin de determinar cuáles resultan más adecuados para identificar y anticipar comportamientos anómalos.

Por otra parte, se analizará la producción energética esperada de los paneles fotovoltaicos en condiciones ideales de funcionamiento, de manera que pueda establecerse un comportamiento de referencia con el que comparar los datos reales de la instalación. También se evaluará la influencia de las variables meteorológicas sobre la producción eléctrica y sobre la posible aparición de anomalías. Para ello, los datos adquiridos se estructurarán como series temporales claramente definidas, considerando aspectos como la periodicidad de los registros.

Finalmente, se identificarán los factores asociados a un mayor riesgo de aparición de anomalías, con el propósito de mejorar la interpretación de los modelos predictivos y comprender las posibles causas de las desviaciones detectadas. Estos factores podrán variar en función del enfoque metodológico y del modelo implementado.

3.3. METODOLOGÍA DEL TRABAJO

La metodología del presente trabajo se orienta al desarrollo y evaluación de modelos capaces de detectar anomalías y, en su caso, anticipar o diagnosticar fallos en sistemas fotovoltaicos a partir de series temporales multivariantes. El planteamiento general se basa en la idea de que el sistema, en condiciones normales de operación, sigue patrones temporales relativamente consistentes, mientras que la aparición de desviaciones respecto a dichos patrones puede asociarse a eventos anómalos, degradación progresiva o fallos incipientes.

Respecto a las herramientas utilizadas, el desarrollo se realizará íntegramente en *Python*:

- Para el tratamiento y análisis de datos se emplearán principalmente NumPy y Pandas.
- Para el modelado clásico, *scikit-learn* y, en la aplicación de modelos de *deep learning*, *TensorFlow/Keras*.
- El trabajo experimental se organizará mediante cuadernos *Jupyter* para facilitar la trazabilidad del proceso.

Por otro lado, el trabajo se estructura en varias fases encadenadas: Selección del conjunto de datos, preparación y preprocesado, extracción de características, modelado, validación y análisis de resultados.


Antes de describir en detalle cada fase, resulta conveniente presentar una visión sintética del pipeline que se va a seguir durante el desarrollo del trabajo:

1. Seleccionar un conjunto de datos público y representativo de un sistema fotovoltaico monitorizado, atendiendo a la disponibilidad de variables relevantes, la resolución temporal y la calidad de la información registrada.
2. Realizar análisis exploratorio inicial con el objetivo de caracterizar la estructura del conjunto de datos, identificar las variables disponibles y evaluar posibles limitaciones asociadas a la presencia de valores ausentes, registros inconsistentes o discontinuidades temporales. Abordar tareas de limpieza para depurar y mejorar la calidad del *dataset*.
3. Construir variables derivadas, orientadas a capturar de forma adecuada la dinámica temporal y operativa del sistema fotovoltaico.
4. Desarrollar modelos con distintos enfoques orientados a la detección de anomalías. Las técnicas se adaptarán al *dataset* que haya sido finalmente seleccionado.

5. Evaluar y comparar los modelos resultantes, con objeto de identificar sus ventajas y limitaciones.
6. Seleccionar la alternativa más adecuada valorando su aplicabilidad en un contexto de monitorización y detección temprana de anomalías en sistemas fotovoltaicos.

Figura 6. Desglose de la metodología empleada.

Detección Inteligente de Anomalías en Sistemas Fotovoltaicos



Fuente: elaboración propia mediante la herramienta NotebookLM.

A continuación, se detalla cada uno de los pasos comentados:

1. Selección del conjunto de datos

El proyecto se desarrollará sobre *datasets* públicos de series temporales multivariantes aplicadas a sistemas fotovoltaicos. La selección del conjunto de datos sobre el que trabajar se realizará atendiendo a criterios como:

- La disponibilidad de variables eléctricas y meteorológicas.
- La resolución temporal.
- La duración de la monitorización.
- La existencia o no de eventos anómalos etiquetados.
- La calidad general de la información disponible.

Para ello, se hará un análisis exploratorio de los datos aplicado al grupo de candidatos más prometedores.

En la decisión final, se priorizarán conjuntos de datos que incluyan variables representativas del comportamiento del sistema, como potencia, corriente, tensión, irradiancia, temperatura ambiente y, si están disponibles y se consideran que son factores determinantes, temperatura de módulo, humedad, velocidad del viento o registros de operación.

La elección de *datasets* públicos responde a dos motivos principales:

- Asegurar la trazabilidad y reproducibilidad del trabajo.
- Facilitar la comparación de resultados con estudios previos.

2. Preparación y preprocesado del dato

La primera fase técnica del trabajo consistirá en la preparación del dato, al considerarse una etapa crítica para la fiabilidad del modelado posterior. En esta fase se abordará la limpieza de datos faltantes, la corrección o eliminación de valores anómalos y la homogeneización temporal de las señales.

En concreto, en caso de haberlas, se aplicarán técnicas de imputación o descarte según el tipo y proporción de valores perdidos, así como filtros para reducir ruido en las señales cuando sea necesario. También se revisarán posibles desfases temporales entre variables y se realizará un proceso de sincronización y *resampling* para alinear todas las series a una frecuencia común de trabajo. Además, se corregirán o excluirán registros claramente inconsistentes, como *outliers*, medidas duplicadas o periodos de parada que no representen el funcionamiento habitual del sistema.

El objetivo de esta etapa es obtener una base de datos coherente, limpia y comparable, sobre la que puedan aplicarse modelos sin introducir sesgos derivados de errores de adquisición o problemas de integración entre señales.

3. Extracción y construcción de variables

Una vez preparado el dato, se llevará a cabo una fase de extracción de características orientada a representar mejor la dinámica temporal del sistema.

En el dominio temporal, se podrán extraer características como media, desviación estándar, pendiente, rango, máximos, mínimos o variaciones entre instantes consecutivos. En paralelo, se explorará la obtención de características en el dominio de la frecuencia mediante transformadas o descomposiciones espectrales, con el fin de capturar patrones periódicos,

oscilaciones anómalas o cambios en la estructura de la señal que puedan no ser evidentes en el dominio temporal.

Esta fase permitirá comparar el rendimiento de modelos entrenados directamente con la serie original frente a otros alimentados con variables derivadas más informativas.

4. Estrategia de modelado

El conjunto de estrategias de modelado dependerá de la disponibilidad de etiquetas fiables en los *datasets* seleccionados. En caso de que no existan etiquetas de anomalías o fallos, o estas sean insuficientes, se priorizarán enfoques no supervisados o semisupervisados. En este caso, el objetivo será modelar el comportamiento normal del sistema y detectar desviaciones significativas respecto a dicho patrón. Para ello, se planteará el uso de modelos base de referencia y su comparación con enfoques más avanzados, como *autoencoders* aplicados a series temporales.

Si el conjunto de datos seleccionado incluye etiquetas de fallo, registros de eventos o *logs* suficientemente consistentes, se incorporará una rama supervisada orientada a la clasificación y diagnóstico. En este caso se evaluarán algoritmos clásicos como *Random Forest*, *XGBoost* o *SVM*, así como modelos secuenciales basados en *deep learning*, especialmente redes *LSTM*. El objetivo será no solo detectar la existencia de un evento anómalo, sino también identificar, si es posible, su tipo o naturaleza.

Además, se valorará un enfoque híbrido en dos etapas. En una primera fase, un modelo de detección de anomalías actuaría como sistema de alerta temprana. En una segunda fase, un clasificador intentaría sugerir el tipo de fallo cuando el evento anómalo haya sido confirmado.

5. Validación y comparación de modelos

Los modelos se entrenarán y validarán con particiones adecuadas de los datos, respetando en lo posible la naturaleza temporal de las series. Se evitarán, por tanto, particiones aleatorias que puedan introducir fuga de información entre entrenamiento y prueba.

La evaluación dependerá del tipo de tarea y enfoque. En ausencia de etiquetas suficientes, la evaluación se complementará con análisis visuales, revisión temporal de las anomalías detectadas y valoración de su coherencia técnica con el funcionamiento del sistema fotovoltaico.

6. Análisis e interpretación de resultados

Una vez entrenados y evaluados los distintos modelos, se procederá a seleccionar la alternativa más adecuada. Esta decisión no se basará únicamente en la métrica predictiva obtenida sobre el conjunto de validación, sino en una valoración conjunta de varios criterios relevantes para un entorno real de uso.

En primer lugar, se tendrá en cuenta la capacidad del modelo para detectar anomalías o fallos de forma fiable, priorizando un equilibrio adecuado entre sensibilidad y robustez. Es decir, se analizará también la estabilidad del comportamiento del modelo ante distintos periodos temporales y condiciones operativas.

En segundo lugar, se valorará la capacidad de generalización del modelo. Un modelo útil para producción no debe limitarse a reproducir bien los datos de entrenamiento, sino mantener un comportamiento consistente ante datos no vistos previamente. Por ello, se analizará su sensibilidad frente a cambios en la distribución temporal de las señales, posibles variaciones meteorológicas y diferencias en la calidad del dato.

Junto con el rendimiento predictivo, se considerarán también aspectos prácticos de implementación. Entre ellos destacan la complejidad computacional, el tiempo de inferencia, la facilidad de reentrenamiento, la necesidad de preprocesado intensivo, la dependencia de un gran número de variables de entrada y el grado de interpretabilidad de las salidas. Estos factores son especialmente relevantes si el objetivo es que el modelo pueda integrarse posteriormente en un sistema automatizado de detección y monitorización.

4. Planteamiento de la comparativa

El conjunto de experimentos desarrollados en este trabajo se plantea como una serie de estudios piloto orientados a la detección de anomalías en una instalación fotovoltaica a partir de series temporales multivariantes. En estos, el sujeto de análisis será una selección de registros temporales de operación del sistema, conformado por variables eléctricas, meteorológicas y térmicas.

4.1. INTRODUCCIÓN AL DATASET

Una vez analizados los repositorios mencionados en el estado de arte, finalmente se optó para el desarrollo por el conjunto de datos público *High-Resolution Floating Solar PV Data*.

A modo de resumen, se trata de un grupo de *datasets* publicados por la Universidad de Florida Central y disponible a través de *Data.gov* y la Oficina de Información Científica y Técnica (*OSTI*) del Departamento de Energía de los Estados Unidos (University of Central Florida - Florida Solar Energy Center, 2022). Este repositorio contiene datos de alta resolución procedentes de varios emplazamientos fotovoltaicos flotantes, así como de dos sistemas fotovoltaicos terrestres ubicados en el *Florida Solar Energy Center*, en Cocoa, Florida. Aunque el estudio original se enmarca en el análisis y comparación de los sistemas flotantes y terrestres, este trabajo se enfocará específicamente en estos últimos. Los campos presentes y su información relevante están referenciada en el Anexo A: Descripción de los campos del conjunto de datos.

El repositorio contiene datos de alta resolución procedentes de varios emplazamientos fotovoltaicos flotantes, así como de dos sistemas fotovoltaicos terrestres ubicados en el *Florida Solar Energy Center*, en Cocoa, Florida. Aunque el estudio original se enmarca en el análisis y comparación de los sistemas flotantes y terrestres, este trabajo se enfocará específicamente en estos últimos. Los campos presentes y su información relevante están referenciadas en el Anexo A: Descripción de los campos del conjunto de datos.

4.2. JUSTIFICACIÓN DEL DATASET

La elección final de este conjunto de datos se justifica por su adecuación a los criterios establecidos previamente en el apartado de *Metodología del trabajo* para la selección del *dataset*.

En primer lugar, se trata de una fuente pública, trazable y documentada, lo que favorece la reproducibilidad del trabajo y permite identificar claramente el origen de los datos. Además, el *dataset* proporciona datos reales de operación de una instalación fotovoltaica monitorizada, incorporando la variabilidad propia de un entorno técnico real, como ruido, cambios en las condiciones ambientales y posibles discontinuidades temporales.

Otro aspecto relevante es la disponibilidad conjunta de variables eléctricas, térmicas y meteorológicas, incluyendo magnitudes como tensión, corriente, potencia, irradiancia, temperatura ambiente, temperatura de módulos, humedad, viento y precipitación. Esta variedad de señales permite analizar la relación entre las condiciones externas de operación y la respuesta eléctrica del sistema fotovoltaico, lo que resulta especialmente adecuado para la detección de desviaciones respecto al comportamiento esperado.

Asimismo, la alta resolución temporal del conjunto de datos permite estudiar la evolución del sistema con un nivel de detalle suficiente para identificar cambios bruscos, patrones anómalos de corta duración y relaciones temporales entre variables.

Por otro lado, aunque el *dataset* no dispone de una anotación de eventos de fallo, esta característica no constituye una limitación crítica para el planteamiento del trabajo, ya que en sistemas fotovoltaicos reales la disponibilidad de etiquetas fiables suele ser reducida. Además, el objetivo del estudio no se centra en una clasificación supervisada estricta, sino en la exploración de distintos enfoques que nos permitan identificar desviaciones respecto al comportamiento esperado del sistema.

4.3. CONFIGURACIÓN DEL DATASET

Para la realización del conjunto de experimentos, se seleccionaron del repositorio los dos ficheros correspondientes a los sistemas terrestres:

- *FSEC_Regional_Test_Ambient_data.csv*, con información ambiental y meteorológica.
- *FSEC_Regional_Test_BaseLine_data.csv*, con variables eléctricas y de operación de los sistemas fotovoltaicos.

Ambos ficheros se integraron mediante las columnas comunes *DAY* y *HOURLY*, permitiendo construir un único *dataset* sincronizado temporalmente.

Para obtener información adicional acerca de los distintos campos que han conformado el *dataset* objeto de estudio, merece la pena recordar que se puede consultar el **Anexo A**, ubicado al final de la memoria.

4.4. ENFOQUES DEL PROYECTO

Para el desarrollo experimental del trabajo se ha decidido experimentar con tres enfoques distintos para la detección de anomalías previamente mencionados en el apartado de *Estado de Arte*:

- Enfoque estadístico
- Enfoque semisupervisado
- Enfoque basado en *deep learning* mediante *autoencoder*

Esta decisión responde a la necesidad de analizar el problema planteado desde distintos niveles de complejidad, partiendo de técnicas simples e interpretables hasta modelos capaces de aprender relaciones no lineales entre variables.

La selección de estos tres enfoques también se justifica por las características del conjunto de datos utilizado. Tal y como se ha comentado, el *dataset* contiene series temporales reales de una instalación fotovoltaica, con variables eléctricas, meteorológicas y térmicas, pero no dispone de etiquetas verificadas de fallo o anomalía. Por ello, no resulta adecuado plantear un enfoque supervisado clásico, ya que no existe un *output* claro contra el que entrenar y validar directamente el modelo.

El enfoque estadístico se plantea como una primera aproximación de referencia. Su objetivo es detectar comportamientos anómalos a partir de reglas simples, umbrales físicos, análisis de valores extremos y desviaciones respecto a rangos esperados.

El enfoque semisupervisado se incluye porque representa una situación intermedia entre los métodos puramente estadísticos y los modelos complejos de aprendizaje profundo. Nos permite aprender del comportamiento habitual del sistema a partir de datos considerados “normales” y, posteriormente, detectar desviaciones.

Finalmente, el enfoque basado en *deep learning* mediante *autoencoder* se ha seleccionado por su capacidad para modelar relaciones complejas y no lineales entre múltiples variables.

5. Desarrollo de la comparativa

Una vez definido el conjunto de datos y establecidos los tres enfoques para la detección de anomalías, el siguiente apartado desarrolla la implementación concreta de la comparativa experimental.

En los siguientes subapartados se describe el proceso seguido para cada enfoque, incluyendo la preparación específica de los datos, los criterios de detección aplicados, la configuración de los modelos y la forma en que se han obtenido las anomalías identificadas.

5.1. MÉTODOS ESTADÍSTICOS

El objetivo de este experimento es construir un modelo capaz de “predecir”, o, mejor dicho, estimar la potencia esperada del sistema fotovoltaico a partir de las variables comentadas anteriormente ambientales, y de los sensores. El objetivo es detectar anomalías analizando el residuo entre la potencia real y la predicha. Este acercamiento se plantea de forma que un modelo aprenda el comportamiento normal de la planta, es decir, observar las desviaciones entre la producción real y la esperada, e interpretar dichas discrepancias como fallos de medida, de rendimiento...

5.1.1. Preparación del dataset

Para este método en concreto se han empleado datos ambientales como la irradiancia, temperatura, humedad, viento y presión. Por otro lado, también se han usado datos eléctricos de los sensores como la potencia activa “S2WACA”.

A la hora de seleccionar y procesar los datos, se han unificado dichos datos de los dos *datasets* diferenciados en base a las columnas temporales con el fin de tener una serie ordenada. Seguidamente se filtraron los registros diurnos por medio de la irradiancia global “GHRADA”. En el experimento, concretamente, se ha usado un umbral de “GHRADA” mayor que 50, para los registros 2018 hasta 2024.

Una vez elegida la estrategia a seguir, se realizó un análisis exploratorio del *dataset*, en donde se ha sustituido valores inválidos, se han eliminado los duplicados, se han creado variables temporales como “hour”, “minute”, “month”. Además, se ha realizado una limpieza en el conjunto de entrenamiento eliminando casos físicamente incoherentes, como una alta irradiancia con una potencia extremadamente baja.

5.1.2. Estrategia del conjunto de datos

En cuanto a la división del conjunto de datos, se ha decidido seguir una estrategia temporal. Es decir, el modelo se entrena con los datos anteriores a 2022, se valida con el año 2022 y se evalúa finalmente con los datos desde 2023 en adelante. Esta separación permite al modelo aprender con datos históricos, calibrarse con un periodo posterior y probarse con datos aún más recientes. Concretamente, el reparto es temporal para evitar fuga de información incluyendo datos de años aleatorios y aproximadamente se ha dividido el conjunto de datos en un 71% para el conjunto de entrenamiento, un 9% para el conjunto de validación y un 20% para realizar pruebas.

Sin embargo, cabe recalcar que se ha realizado una limpieza o, mejor dicho, filtrado de los datos del conjunto de entrenamiento. El objetivo es que el modelo aprenda el comportamiento normal del sistema, no patrones anómalos o físicamente incoherentes.

5.1.3. Modelos analizados y selección de variables

En cuanto al diseño del modelo en sí, se han desarrollado varias implementaciones: un modelo en donde se ha empleado Isolation Forest, y 2 modelos utilizando Random Forest Regressor. Por lo tanto, cabe destacar 3 modelos.

En el caso del modelo Isolation Forest, se ha combinado información de producción, recurso solar, condiciones ambientales y contexto temporal, lo que permite al modelo identificar comportamientos anómalos no solo por valores extremos individuales, sino por combinaciones físicamente incoherentes. Dichas variables son: "S2WACA", "GHRADA", "TMPCAV", "RHPCTA", "WSMEAN", "hour_sin", "hour_cos", "dayofyear_sin", "dayofyear_cos". Además, se han generado variables físicas derivadas con el objetivo de capturar desajustes entre irradiancia disponible y potencia generada. Estas han sido: "power_per_irradiance", "log_power", "log_irradiance", "power_irradiance_gap".

Por otra parte, en el caso de los modelos que emplean Random Forest Regressor, se ha diferenciado entre una primera toma de contacto con las variables esenciales. Es decir, se han empleado como variables predictoras "GHRADA", "DIRRAA", "DIFRAA", "TMPCAV", "RHPCTA", "WSMEAN", "hour", "minute", "dayofyear", "month".

Por otro lado, también se ha realizado otro experimento como el anteriormente mencionado, pero incluyendo más variables predictoras. En este caso, se han añadido variables ambientales

y de sensores con el fin de enriquecer la estimación, es decir, información meteorológica, como presión atmosférica y viento, así como variables relacionadas con la radiación solar y temperaturas de sensores o módulos ("PMBARA", "WDIREA", "WDIRST", "WSMSST", "POAIR1", "LAMBTA", "ICP1JT", "ICP2JT", "ICP5JT", "ICP6JT", "ICP7JT"). En ambos modelos la variable objetivo fue "S2WACA".

5.1.4. Aprendizaje del comportamiento normal para Isolation Forest

Para el modelo con Isolation Forest se han filtrado los registros diurnos, es decir, con una irradiancia global mayor que 80. También se han descartado los registros con irradiancia alta y potencia demasiado baja. Concretamente, aquellos cuya "GHRADA" es mayor que 500 y la "S2WACA" es menor de 300. La intención es evitar observaciones que podrían parecer anómalas sin serlo realmente. Además, para el conjunto de entrenamiento se han mantenido los registros con unas métricas estables definidas en la siguiente tabla.

Tabla 2. Métricas para obtener un conjunto de entrenamiento normal en Isolation Forest

Campo	Descripción	Tipo	Valor Mín.	Valor Máx.
RHPCTA	Relative humidity percent average (RH%)	Ambiental	0 RH	100 RH
TMPCAV	Ambient temperature average (C)	Ambiental	-10º C	70º C
WSMEAN	Wind speed mean (m/sec)	Ambiental	0 m/s	-

Fuente: elaboración propia.

5.1.5. Aprendizaje del comportamiento normal para los modelos Random Forest Regressor

Por otro lado, en el caso de ambos modelos, en primer lugar, se han descartados los registros con irradiancia alta y potencia demasiado baja comentados anteriormente. Seguidamente, se han conservados los registros con: observaciones con irradiancia suficiente, potencia positiva, humedad relativa físicamente válida, temperatura ambiente dentro de un rango razonable y velocidad de viento no negativa. Los criterios concretos empleados han sido los siguientes.

Tabla 3. Métricas para obtener un conjunto de entrenamiento normal en Random Forest Regressor base

Campo	Descripción	Tipo	Valor Mín.	Valor Máx.
GHRADA	Global Horizontal Radiation Avg. (watts/Sq. m)	Electrica DC	100 W	-
S2WACA	System 2 Power AC Average (watts)	Electrica DC	50 W	-
RHPCTA	Relative humidity percent average(RH%)	Ambiental	0 RH	100 RH
TMPCAV	Ambient temperature average (C)	Ambiental	-10º C	60º C
WSMEAN	Wind speed mean (m/sec)	Ambiental	0 m/s	-

Fuente: elaboración propia.

Para el modelo optimizado se han modificado ligeramente algunos rangos y también se ha realizado un recorte suave de los extremos. Estos recortes han sido el cuartil que representa el 5% inferior y superior. El fin de incluir más casuísticas y realizar estos ajustes es el crear un modelo más sensible. Más en detalle estos han sido los valores.

Campo	Descripción	Tipo	Valor Mín.	Valor Máx.
TMPCAV	Ambient temperature average (C)	Ambiental	-10º C	70º C
S2WACA	System 2 Power AC Average (watts)	Electrica DC	0 W	-

Fuente: elaboración propia.

Para el modelo base, esta reducción se ha visto afectada hasta en un 53% reduciendo drásticamente el conjunto de entrenamiento, de 760339 a 420721 registros, proporcionando mayor calidad. Para el modelo optimizado, la reducción ha supuesto un filtrado de registros de 760850 hasta un 612460, es decir, un 80.2% del total se ha conservado.

5.1.6. Definición del modelo, métricas, residuos y umbrales

5.1.6.1. Modelo con Isolation Forest

El modelo se entrena con un pipeline formado por *RobustScaler* e *IsolationForest*. El escalado robusto es adecuado porque las variables presentan distribuciones con valores extremos, e *Isolation Forest* puede verse afectado por diferencias de escala entre variables.

Una vez entrenado, se calcula el *decision_function*, lo que significa que valores más altos indican observaciones más normales, mientras que valores más bajos indican mayor anomalía. Por ello se define un *score* de anomalía como el negativo del *decision_function*: cuanto mayor es dicha puntuación (*iso_anomaly_score*), más anómala es la observación.

El umbral principal del modelo se establece usando el percentil 0.970 del *score* de anomalía en el conjunto de validación. Se puede observar un resumen de las métricas físicas utilizadas para complementar la puntuación del *score*.

Tabla 4. Métricas y umbrales utilizados para el modelo Isolation Forest

Métrica	Descripción	Variable	Umbral
Score de anomalía Isolation Forest	Detectar observaciones multivariantes raras	iso_anomaly_score = - iso_decision_score	Percentil 0.970 de validación
Anomalía Isolation Forest	Primera marca no supervisada de anomalía	anomaly_iso	iso_anomaly_score > threshold_iso
Potencia casi nula con sol suficiente	Detectar fallo claro de producción	GHRADA, S2WACA	GHRADA > 150 y S2WACA < 150
Irradiancia alta y potencia muy baja	Detectar subproducción severa	GHRADA, S2WACA	GHRADA > 600 y S2WACA < 600
Irradiancia media y potencia baja	Detectar pérdidas moderadas candidatas	GHRADA, S2WACA	250 < GHRADA <= 600 y S2WACA < 550
Baja eficiencia relativa	Detectar baja conversión potencia/irradiancia	power_per_irradiance	GHRADA > 300 y power_per_irradiance < 0.70
Irradiancia alta con potencia baja	Detectar pérdidas moderadas en alta irradiancia	GHRADA, S2WACA	GHRADA > 600 y S2WACA < 850
Fallo claro final	Marcar anomalías evidentes sin exigir IF	Reglas físicas severas	Unión de fallos claros
Subproducción moderada	Reducir falsos positivos en casos dudosos	Reglas moderadas + anomaly_iso	Regla física moderada y anomalía IF
Anomalía final	Fallo claro o subproducción moderada confirmada por IF	Etiqueta final del experimento	Fallo claro o subproducción moderada confirmada por IF

Fuente: elaboración propia.

5.1.6.2. Modelos con Random Forest Regressor

El algoritmo utilizado para el modelo base y optimizado ha sido el Random Forest Regressor, ya que gracias a sus múltiples árboles de decisión nos permite capturar relaciones no lineales entre la irradiancia, las condiciones ambientales y la potencia generada.

Una vez entrenado el modelo, las tres métricas que han sido utilizadas para evaluar las predicciones sobre la validación y test han sido el *MAE*, *RMSE* y el R^2 .

Seguidamente, tras predecir la potencia esperada, un punto clave ha sido calcular los residuos. Se ha definido como residuo la diferencia entre la potencia real y la esperada. Además, han sido útiles otras métricas como el valor absoluto del residuo y el error relativo. Por lo tanto, a partir de la valoración se definieron dos umbrales:

1. Un umbral absoluto, que se ubica en el percentil 99.5 del residuo absoluto.
2. Un umbral relativo, que se ubica en el mismo percentil 99.5 pero del residuo relativo.

A partir de estos umbrales se definieron tres criterios de detección. El primero identifica anomalías cuando el residuo absoluto supera el umbral absoluto. El segundo, más restrictivo, exige que se superen simultáneamente el umbral absoluto y el umbral relativo. Por último, el tercero considera anómalo cualquier punto que supere al menos uno de los dos umbrales.

La segunda estrategia es la más sensible ya que permite detectar un mayor número de desviaciones potencialmente relevantes. En cambio, la tercera estrategia es más conservadora y solo marca como anomalías aquellos registros que presentan una desviación elevada en términos absolutos y relativos. Por tanto, esta última supone una detección fuerte de anomalías.

Para el modelo optimizado se ha incluido un umbral de subproducción ya que a través del desarrollo e iteración se ha visto que es en donde se concentran la mayoría de anomalías.

5.2. ENTRENAMIENTO SEMISUPERVISADO

5.2.1. Justificación de este enfoque

Dado que el conjunto de datos utilizado no incorpora etiquetas explícitas que permitan diferenciar de forma directa entre un funcionamiento normal y un comportamiento anómalo, se optó por aplicar un enfoque semisupervisado. Este tipo de planteamiento resulta especialmente útil en entornos reales de operación fotovoltaica, donde es habitual disponer

de grandes volúmenes de datos históricos, pero no de una clasificación manual previa de los fallos o incidencias detectadas.

Por ello, el objetivo principal del entrenamiento no fue predecir una clase binaria de anomalía, sino aprender primero cómo se comporta el sistema en condiciones consideradas normales y, a partir de ahí, utilizar las desviaciones respecto a ese comportamiento esperado como base para la detección de anomalías.

5.2.2. Preparación de integración del conjunto de datos

La fase inicial del experimento se centró en construir un conjunto de observaciones coherente y correctamente sincronizado en el tiempo. Para ello, los ficheros *FSEC_Regional_Test_BaseLine_data.csv* y *FSEC_Regional_Test_Ambient_data.csv* se integraron utilizando las variables comunes *DAY* y *HOURLY*. Además, se eliminaron registros duplicados y se generó una marca temporal unificada que facilitase el tratamiento posterior de la serie temporal.

Posteriormente, el periodo de estudio se limitó al intervalo comprendido entre 2018 y 2023 completos. Esta decisión se tomó atendiendo tanto a criterios de continuidad temporal como a la calidad de los datos disponibles, ya que en ese tramo se observó una mayor estabilidad en las mediciones y una base más adecuada para el entrenamiento y evaluación del experimento.

5.2.3. Depuración y control de calidad

Antes de entrenar cualquier modelo, se aplicó una fase de depuración orientada a separar posibles errores de medición de anomalías operativas reales. En primer lugar, se identificaron y trataron como valores inválidos los códigos característicos de ausencia o error de lectura presentes en el *dataset*, especialmente 32767, 32766 y -32767.

Además, se definieron reglas físicas de plausibilidad para descartar lecturas incompatibles con el dominio del problema, incluso cuando estas no estaban marcadas mediante los códigos anteriores. Entre dichas reglas se incluyeron límites razonables para variables como la humedad relativa, la frecuencia, la irradiancia o las temperaturas registradas. Esta etapa fue especialmente importante para evitar confundir fallos de medición o errores de adquisición de datos con anomalías reales del sistema fotovoltaico.

Tabla 5. Límites de variables para descartar lecturas erróneas

Campo	Descripción	Tipo	Valor Mín.	Valor Máx.
GHRADA	Global Horizontal Radiation Avg. (W/m ²)	Ambiental	0	2200
DIRRAA	Direct Solar Radiation Avg. (W/m ²)	Ambiental	0	1500
DIFRAA	Diffuse Solar Radiation Avg. (W/m ²)	Ambiental	0	1500
REC2IR	Reference cell #2 Irradiance (W/m ²)	Eléctrica DC	0	2200
PMBARA	Atmospheric pressure average (mbar)	Ambiental	850	1100
WSMEAN	Wind speed mean (m/sec)	Ambiental	0	120
WDIREA	Wind direction mean (deg)	Ambiental	0	360
TMPCAV	Ambient temperature average (C)	Ambiental	-20	42
RHPCTA	Relative humidity percent average(RH%)	Ambiental	0	100
PTMPCA	Panel Temperature average (C)	Térmica	-20	90
REC2TE	Reference cell #2 Temperature (C)	Térmica	-20	90
MODT09 - MODT16	Module Temperature 9 Avg. (deg. C) - Module Temperature 16 Avg. (deg. C)	Térmica	-20	90
S2PFAV	System 2 Power Factor Average (PF)	Factor Potencia	-1.05	1.05
S2FRQA	System 2 Frequency Average (Hz)	Frecuencia	55	65
S2VACA	System 2 Volts AC average (Volts)	Eléctrica CA	180	320
SY2VDC	System #2 Voltage DC Avg.(V)	Eléctrica DC	0	1500

Fuente: elaboración propia.

5.2.4. Selección de variables y sistema analizado

Una vez obtenido el conjunto de datos depurado, se seleccionó como objeto principal de análisis el *PV System 2*. Esta elección se apoyó en el análisis exploratorio previo y en la conveniencia de trabajar inicialmente sobre un subconjunto que permitiera seguir de forma clara la evolución de las variables eléctricas más relevantes.

Para modelar la potencia esperada se utilizaron principalmente variables exógenas, es decir, variables que describen el contexto físico de operación sin depender directamente de la salida que se desea explicar. Entre ellas se incluyeron medidas de irradiancia, variables meteorológicas y características temporales cíclicas derivadas de la hora del día y del día del

año. Con ello se buscó representar el entorno de generación de manera realista, evitando introducir una dependencia circular con la propia potencia observada.

5.2.5. Aprendizaje del comportamiento normal

El entrenamiento del modelo de comportamiento normal se realizó únicamente con registros diurnos y con niveles suficientes de irradiancia, ya que la producción nocturna o en condiciones de irradiación muy reducida no resulta representativa para caracterizar el régimen normal de generación fotovoltaica.

Además, se filtraron aquellas observaciones que presentaban incidencias de calidad, potencia nula o relaciones potencia–irradiancia fuera de un intervalo central considerado razonable dentro de la distribución observada.

Sobre esta muestra se entrenó un modelo de regresión encargado de estimar la potencia esperada de salida “S2WACA” a partir del contexto meteorológico y temporal. Desde un punto de vista operativo, este modelo actúa como una aproximación al comportamiento nominal del sistema y sirve posteriormente como referencia para medir el grado de desviación de cada observación analizada.

5.2.6. Cálculo de residuos y generación de pseudoetiquetas

Una vez obtenida la estimación de potencia esperada para cada instante, se calculó el residuo como la diferencia entre la potencia real observada y la potencia pronosticada por el modelo. Este residuo se analizó tanto en términos absolutos como relativos, ya que una misma diferencia puede tener implicaciones distintas dependiendo del nivel de potencia esperado en cada momento.

A partir de la distribución de residuos se generaron pseudoetiquetas de alta confianza. Por un lado, se consideraron observaciones normales seguras aquellas con discrepancias reducidas respecto al comportamiento esperado. Por otro, se marcaron como candidatos a baja generación aquellos instantes en los que la irradiancia era suficiente, el modelo predecía una potencia apreciable y, sin embargo, la potencia real registrada era nula o significativamente inferior a la esperada.

Este criterio permitió localizar episodios potencialmente compatibles con desconexiones, limitaciones de generación o pérdidas persistentes de rendimiento del sistema fotovoltaico.

5.2.7. Detección complementaria de patrones atípicos

Como segundo nivel de análisis, y trabajando sobre el subconjunto de observaciones normales seguras, se aplicó un detector no supervisado basado en Isolation Forest. Su finalidad no fue sustituir al modelo de potencia esperada, sino complementar la detección identificando patrones eléctricos atípicos que no siempre se traducen directamente en una caída extrema de potencia.

Para esta fase se utilizaron, además del residuo, variables relacionadas con la tensión en corriente continua, las corrientes de string, la tensión en alterna, el factor de potencia, la frecuencia y la irradiancia disponible. De esta manera, el procedimiento permitió diferenciar entre episodios de baja generación y comportamientos eléctricos inusuales cuya evidencia sobre la potencia podía resultar menos directa.

5.2.8. Criterios de evaluación del entrenamiento

La evaluación del entrenamiento se abordó desde dos perspectivas diferentes. En la parte regresiva se utilizaron métricas como el error absoluto medio (*MAE*), el error cuadrático medio (*RMSE*) y el coeficiente de determinación (R^2), con el objetivo de comprobar que el modelo era capaz de reproducir adecuadamente el comportamiento normal antes de emplearlo como base para la detección de anomalías.

En la parte relacionada con anomalías, al no existir etiquetas reales de referencia, no se recurrió a métricas clásicas de clasificación como *accuracy*, *precision* o *recall*. En su lugar, la validación se apoyó en la consistencia temporal de los episodios detectados, en la concentración de candidatos dentro de determinados intervalos y en la revisión cualitativa de los eventos más relevantes.

Este enfoque resulta coherente tanto con la naturaleza semisupervisada del problema como con las limitaciones propias del *dataset* disponible.

5.2.9. Síntesis del procedimiento experimental

En conjunto, el experimento puede entenderse como un flujo reproducible compuesto por varias etapas encadenadas: integración de fuentes de datos, depuración y control de calidad, selección de variables relevantes, entrenamiento del comportamiento normal y generación de candidatos a anomalía.

5.3. DISEÑO E IMPLEMENTACIÓN DE UN AUTOENCODER

5.3.1. Preprocesado del Dataset

Partiendo del *dataset* unificado, dentro de este enfoque se ha trabajado con una muestra que abarca los registros desde inicios de 2015 hasta finales de 2023.

El estudio, al igual que en el resto de los enfoques, se ha centrado en el Sistema 2, seleccionando un conjunto de variables representativas del comportamiento eléctrico del sistema, de las condiciones térmicas de los módulos y de la radiación disponible. Además, con el objetivo de evaluar la influencia de la información meteorológica externa en la detección de anomalías, se han construido dos configuraciones de entrada diferenciadas.

1. Modelo sin variables ambientales externas: En este caso, se han utilizado únicamente las variables propias del sistema fotovoltaico, incluyendo variables eléctricas, temperaturas de módulo, irradiancia y variables temporales derivadas.
2. Modelo con variables ambientales externas: La segunda configuración incorpora además de las variables anteriores, variables ambientales, permitiendo evaluar si la inclusión de información meteorológica externa mejora la capacidad de reconstrucción del *autoencoder* o modifica el tipo de anomalías detectadas.

En resumen, se han seleccionado los siguientes campos:

- Variables eléctricas: “SY2VDC”, “S2S1DC”, “S2S2DC”, “S2VACA”, “S2WACA”, “S2PFAV” y “S2FRQA”.
- Temperatura de los módulos: “MODT09”, “MODT10”, “MODT11”, “MODT12”, “MODT14”, “MODT16” y “REC2TE” (“MODT15” ha sido descartado debido a su volumen de *outliers*).
- Irradiancia: “REC2IR”.
- Variables ambientales externas: “GHRADA”, “DIRRAA”, “PMBARA”, “WSMEAN”, “WDIREA”, “TMPCAV” y “RHPCTA”.

En primer lugar, se ha generado una variable temporal *datetime* combinando los campos *DAY* y *HOURL*. Esta transformación es necesaria para convertir el formato original del *dataset*, basado en los campos año-día juliano y hora, en una variable temporal interpretable y ordenable.

A partir de este nuevo valor, se han construido un conjunto de variables temporales cíclicas, concretamente *seno* y *coseno*, que codifican la hora del día y del día del año. Esta estrategia evita introducir estos datos como valores numéricos lineales, ya que en una serie temporal los ciclos diarios y estacionales presentan continuidad circular. Es decir, por ejemplo, las 23:00 y las 00:00 son momentos próximos en el ciclo diario, aunque numéricamente puedan parecer alejados si utilizamos el campo *datetime* sin transformar.

Posteriormente, se ha llevado a cabo una limpieza inicial de *outliers* mediante una comprobación de coherencia física de determinadas variables. Para ello, se han definido límites mínimos y máximos admisibles para variables eléctricas, térmicas y de irradiancia, con el fin de eliminar registros claramente inconsistentes con el funcionamiento real del sistema o atribuibles a errores de medición.

Esta depuración no se ha aplicado de forma específica sobre las variables ambientales externas, ya que estas no describen directamente el funcionamiento del sistema de generación eléctrica, sino las condiciones meteorológicas del entorno. Por este motivo, se ha considerado que su variabilidad forma parte del contexto externo en el que opera la instalación y se ha mantenido en el modelo, asumiendo que estos registros proceden de una fuente de medida válida.

En la tabla que se muestra en la página siguiente, se puede ver un resumen de los límites que han sido establecidos para la detección de *outliers*. Los registros que superan dichos rangos se han marcado mediante una variable auxiliar *has_impossible_value*, sin eliminarlos automáticamente del conjunto completo, con el fin de conservar su trazabilidad y poder analizarlos posteriormente como posibles anomalías o errores de medida.

Por último, se ha tomado la decisión metodológica de filtrar las horas útiles de generación energética. Dado que durante la noche la producción fotovoltaica es nula o muy baja, incluir de forma masiva registros nocturnos podría sesgar el aprendizaje del modelo y reducir su sensibilidad ante anomalías relevantes durante el funcionamiento real del sistema. Por ello, se han conservado únicamente los registros con irradiancia suficiente, definiendo como condición de luz diurna aquellos casos en los que la irradiancia de la célula de referencia (campo "*REC2IR*") superaban los 50 W/m². Esta decisión permite centrar el análisis en los periodos en los que el sistema fotovoltaico debería estar generando energía.

Tabla 6. Rangos considerados como válidos en la detección de outliers

Campo	Descripción	Tipo	Valor Mín.	Valor Máx.
SY2VDC	System #2 Voltage DC Avg.	Eléctrica DC	-5 V	1.000 V
S2S1DC	System 2 String 1 DC current	Eléctrica DC	-1 A	50 A
S2S2DC	System 2 String 2 DC current	Eléctrica DC	-1 A	50 A
S2VACA	System 2 Volts AC average	Eléctrica AC	0 V	400 V
S2WACA	System 2 Power AC Average	Eléctrica AC	-5.000 W	$1 \cdot 10^7$ W
S2PFAV	System 2 Power Factor Average	Eléctrica AC	-1,05	1,05
S2FRQA	System 2 Frequency Average	Eléctrica AC	55 Hz	65 Hz
MODT09	Module Temperature 9 Avg.	Térmica	-100 °C	10.000 °C
MODT10	Module Temperature 10 Avg.	Térmica	-100 °C	10.000 °C
MODT11	Module Temperature 11 Avg.	Térmica	-100 °C	10.000 °C
MODT12	Module Temperature 12 Avg.	Térmica	-100 °C	10.000 °C
MODT13	Module Temperature 13 Avg.	Térmica	-100 °C	10.000 °C
MODT14	Module Temperature 14 Avg.	Térmica	-100 °C	10.000 °C
MODT16	Module Temperature 16 Avg.	Térmica	-100 °C	10.000 °C
REC2IR	Reference cell #2 Irradiance	Irradiancia	-20 W / m ²	1400 W / m ²

Fuente: elaboración propia.

5.3.2. División en conjuntos de Train, Validation y Test

La partición de los datos en submuestras para el entrenamiento, validación y prueba se ha realizado respetando el orden temporal de la serie. En lugar de aplicar una división aleatoria, el *dataset* se ordenó cronológicamente a partir de la variable *datetime* y se separó inicialmente el 85 % de los registros más antiguos para entrenamiento y validación, reservando el 15 % final como conjunto de *test*. Esta estrategia evita la fuga de información temporal y reproduce de forma más realista un escenario de monitorización, en el que el modelo se ajusta con datos históricos y se evalúa sobre periodos posteriores.

A continuación, sobre el conjunto inicial de entrenamiento y validación se eliminaron los registros identificados como *outliers*. Esta depuración se aplicó únicamente antes del ajuste del modelo, con el objetivo de entrenar y validar el *autoencoder* sobre registros representativos del funcionamiento normal del sistema. Posteriormente, el subconjunto

limpio se volvió a dividir respetando el orden temporal, asignando aproximadamente el 75 % inicial al entrenamiento y el 25 % restante a la validación.

Tabla 7. Conjuntos de entrenamiento, validación y test

Subconjunto	Fecha Inicio	Fecha Fin
Train	2015-04-06 11:09:00	2019-10-10 07:29:00
Validación	2019-10-10 07:30:00	2022-08-12 12:04:00
Test	2022-08-12 12:05:00	2023-12-31

Fuente: elaboración propia.

No obstante, además de los subconjuntos limpios utilizados para el entrenamiento y la validación del *autoencoder*, se conservaron también las versiones completas de los datos, incluyendo los registros con valores imposibles. En particular, se reconstruyó un conjunto de validación completo a partir del intervalo temporal correspondiente a la validación limpia. De este modo, podremos calcular el error de reconstrucción posteriormente tanto sobre los datos limpios como sobre los conjuntos completos de entrenamiento, validación y test, permitiéndonos evaluar que tan buenos son los modelos a la hora de detectar *outliers*.

5.3.3. Procesado de los conjuntos de datos

Antes del entrenamiento, las variables se han escalado mediante *RobustScaler*. Esta técnica utiliza estadísticas robustas frente a valores extremos, como la mediana y el rango intercuartílico, por lo que resulta más adecuada que una normalización estándar en un contexto donde se da por hecho la existencia de anomalías dentro del propio *dataset*.

El escalado se ajustó únicamente sobre los datos limpios de entrenamiento y posteriormente se aplicó al resto de subconjuntos, manteniendo así la coherencia metodológica del flujo experimental.

5.3.4. Construcción y entrenamiento del modelo

El modelo seleccionado para este piloto es un *autoencoder* denso, una arquitectura de red neuronal no supervisada cuyo objetivo es reconstruir sus propias entradas. La hipótesis de trabajo es que, si el modelo aprende correctamente los patrones normales de operación del sistema fotovoltaico, será capaz de reconstruir con bajo error los registros normales, mientras que los comportamientos anómalos producirán errores de reconstrucción más elevados.

La arquitectura implementada se ha mantenido equivalente para las dos configuraciones de entrada analizadas, tanto con variables ambientales como sin ellas, variando únicamente el número de neuronas de la capa de entrada y salida en función del número de variables incluidas en cada caso. Como se muestra en la siguiente figura, el modelo está formado por una fase de codificación con capas densas de 128 y 64 neuronas, una capa central o *bottleneck* de 12 neuronas con activación lineal, y una fase de decodificación simétrica con capas densas de 64 y 128 neuronas.

Figura 7. Arquitectura final del autoencoder construido sin variables ambientales

Layer (type)	Output Shape	Param #
input_1 (InputLayer)	[(None, 20)]	0
dense (Dense)	(None, 128)	2688
batch_normalization (Batch Normalization)	(None, 128)	512
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 64)	8256
batch_normalization_1 (Batch Normalization)	(None, 64)	256
dropout_1 (Dropout)	(None, 64)	0
bottleneck (Dense)	(None, 12)	780
dense_2 (Dense)	(None, 64)	832
batch_normalization_2 (Batch Normalization)	(None, 64)	256
dense_3 (Dense)	(None, 128)	8320
batch_normalization_3 (Batch Normalization)	(None, 128)	512
dense_4 (Dense)	(None, 20)	2580
Total params: 24,992		
Trainable params: 24,224		
Non-trainable params: 768		

Fuente: elaboración propia.

En las capas ocultas se ha empleado la función de activación *ELU*, mientras que la capa de salida utiliza activación lineal, al tratarse de un problema de reconstrucción de variables continuas. Además, se ha incorporado regularización *L2*, normalización por lotes y capas de *Dropout* del 10 % en la fase de codificación, con el objetivo de mejorar la generalización del modelo y reducir el riesgo de sobreajuste.

El entrenamiento se ha configurado con el optimizador *Adam*, con una tasa de aprendizaje inicial de $3 \cdot 10^{-4}$. Como función de pérdida se ha utilizado *Huber*, en lugar del error cuadrático

medio, ya que ofrece un comportamiento más robusto frente a errores elevados puntuales, combinando sensibilidad ante desviaciones pequeñas con menor penalización de valores extremos. Esta elección resulta especialmente adecuada en un contexto de detección de anomalías, donde pueden existir registros con errores de reconstrucción muy superiores al comportamiento normal.

Por último, la duración máxima del entrenamiento se ha fijado en 150 épocas, con un tamaño de lote de 256 observaciones. Asimismo, se han incorporado dos mecanismos de control durante el aprendizaje:

1. Early Stopping: Para detener el entrenamiento cuando la pérdida de validación deja de mejorar.
2. ReduceLROnPlateau: Para reducir progresivamente la tasa de aprendizaje si el modelo alcanza una meseta en la validación.

En ambos casos, el objetivo es favorecer una convergencia estable y evitar un ajuste excesivo a los datos de entrenamiento.

5.3.5. Detección de las anomalías

En la detección de anomalías se ha calculado, para cada registro, el error de reconstrucción entre el vector de entrada escalado y el vector reconstruido por el *autoencoder*. Dado que el modelo ha sido entrenado con *función de pérdida Huber*, el error de reconstrucción se ha calculado siguiendo este mismo criterio, obteniendo para cada observación la media del error *Huber* entre las variables originales y reconstruidas.

Al no disponer de etiquetas reales de anomalía, no es posible el cálculo de métricas supervisadas como *accuracy*, *recall* o *F1-score*. Por este motivo, su detección está planteada como un problema no supervisado, en el cual se ha tenido que configurar un umbral de anomalía a partir del cual determinar que un valor se desvía de lo esperado.

Dicho límite se ha definido a partir del error de reconstrucción obtenido en el conjunto de validación limpio, es decir, sin registros previamente identificados como *outliers*. Tras analizar las distribuciones del error en los dos modelos entrenados, los cuales se analizarán en el apartado de resultados, para el caso sin variables ambientales se ha utilizado un criterio más restrictivo, fijando el umbral en el percentil 99.9 del error de validación. En cambio, para otro

caso, se ha empleado el percentil 95, con el objetivo de analizar una configuración más sensible a desviaciones.

Una vez definido el umbral correspondiente a cada configuración, este se ha aplicado tanto a los subconjuntos limpios de entrenamiento y validación como a las versiones completas de entrenamiento, validación y prueba. Los registros cuyo error superan dicho umbral se han clasificado como anomalías.

5.3.6. Clasificación de anomalías

Una vez detectados los registros anómalos a partir del error de reconstrucción del *autoencoder*, se ha implementado una segunda fase con el objetivo de tratar de clasificar las anomalías identificadas. Esta etapa no pretende detectar nuevas anomalías, sino agrupar aquellas ya detectadas en función del tipo de desviación que presentan, dándole un enfoque híbrido a la solución experimental.

Para ello, se ha utilizado el algoritmo K-Means, aplicado sobre los errores de reconstrucción calculados a nivel de variable. De esta forma, en lugar de agrupar los registros a partir de sus valores originales, el modelo trabaja directamente con el patrón de error generado por el *autoencoder*. Esta aproximación permite diferenciar anomalías no solo por su magnitud global, sino también por las variables concretas que contribuyen en mayor medida a la desviación.

En primer lugar, se ha calculado la reconstrucción del *autoencoder* sobre el conjunto completo de entrenamiento, obteniendo el error Huber por variable. Cada variable original queda así representada por una nueva variable de error, permitiendo analizar de forma individual qué dimensiones del sistema han sido peor reconstruidas. Posteriormente, se han seleccionado únicamente los registros clasificados previamente como anómalos.

Antes de aplicar *K-Means*, los errores por variable se han transformado mediante una función logarítmica *log1p*. Esta transformación permite reducir el efecto de errores extremadamente elevados, evitando que unos pocos registros con desviaciones muy grandes dominen la formación de los clústeres. A continuación, los datos se han estandarizado mediante *StandardScaler*, con el fin de que todas las variables de error contribuyan de forma comparable al cálculo de distancias utilizado por *K-Means*.

En ambos modelos (con y sin variables ambientales), se ha fijado el número de clústeres en cuatro. Para seleccionar este valor, se ha aplicado el método del codo, analizando la evolución de la inercia para distintos valores de “k”. Los detalles de dicho análisis se comentarán en el apartado de resultados. Esta elección nos ha permitido obtener una segmentación suficientemente detallada de las anomalías, manteniendo al mismo tiempo una interpretación manejable de los resultados. Cada clúster representa un grupo de registros anómalos con un patrón similar de errores de reconstrucción por variable.

Una vez entrenado *K-Means* sobre las anomalías del conjunto de entrenamiento, el mismo procedimiento se ha aplicado al subconjunto formado por validación y test. En primer lugar, se ha calculado de nuevo el error Huber por variable entre los datos escalados y la reconstrucción generada por el *autoencoder*. Posteriormente, se han seleccionado únicamente los registros previamente clasificados como anómalos.

Para garantizar la coherencia metodológica, en esta fase no se ha vuelto a ajustar ni el escalador ni el modelo *K-Means*. En su lugar, se ha utilizado el *StandardScaler* previamente entrenado con las anomalías del conjunto de entrenamiento y, a continuación, se ha aplicado el modelo *K-Means* ya ajustado para asignar cada anomalía de validación y *test* a uno de los cuatro clústeres definidos.

De este modo, las anomalías de validación y test se han clasificado en función de los patrones aprendidos en el conjunto de entrenamiento, permitiendo evaluar si los perfiles de anomalía identificados en los datos históricos se mantienen en periodos posteriores.

6. Discusión y análisis de resultados

En este apartado se analizan y comparan los resultados obtenidos a partir de los tres enfoques principales desarrollados en el proyecto para la detección de anomalías en un sistema de generación fotovoltaica: modelos estadísticos, modelos semisupervisados y *autoencoder*.

6.1 RESULTADOS DE LOS MODELOS ESTADÍSTICOS

6.1.1. Isolation Forest


El umbral del Isolation Forest se estableció sobre el conjunto de validación usando el percentil 0.970 del *score* de anomalía. Por lo que los valores obtenidos fueron los siguientes:

- Umbral Isolation Forest: -0.007651
- Porcentaje de anomalías en el conjunto de test: 3.30%

Sin embargo, al aplicar las reglas físicas definidas anteriormente, se ha reducido dicha cantidad a un total de 940 anomalías, lo que equivale al 0.93% del conjunto de test.

En la gráfica siguiente de la distribución del *score* de anomalía, el umbral aparece situado en la cola derecha de la distribución. Esto refleja que solo se consideran anómalos los registros con mayor *score* de rareza, es decir, aquellos más alejados del comportamiento mayoritario del sistema. La mayor parte de las observaciones quedan por debajo del umbral y son clasificadas como normales.


Figura 8. Distribución del *score* de anomalía por el modelo Isolation Forest



Fuente: elaboración propia.

En cuanto a la relación irradiancia-potencia, las anomalías finales se concentran principalmente en zonas donde la potencia “S2WACA” es baja en relación con la irradiancia disponible. Se observan muchos puntos anómalos con potencia cercana a cero, visiblemente inferior al patrón normal para valores de “GHRADA” medios y altos. Se puede apreciar un patrón de comportamiento de subproducción del sistema fotovoltaico.


Figura 9. Relación irradiancia-potencia por el modelo Isolation Forest



Fuente: elaboración propia.

Ahora bien, en el score de anomalía frente a irradiancia, las anomalías aparecen sobre todo en valores de irradiancia bajos-medios y también en algunos casos de irradiancia alta. El modelo no marca únicamente puntos extremos de irradiancia, sino combinaciones anómalas entre irradiancia, potencia, eficiencia relativa y las variables temporales que se han definido anteriormente.


Figura 10. Potencia por irradiancia por el modelo Isolation Forest



Fuente: elaboración propia.

Por otro lado, en la gráfica “S2WACA/GHRADA” frente a irradiancia, las anomalías se sitúan principalmente en zonas de baja eficiencia relativa, es decir, registros donde la potencia generada por unidad de irradiancia es inferior al comportamiento habitual del sistema. Esto muestra que el modelo está capturando casos de bajo rendimiento relativo, no solo valores absolutos bajos de potencia.

Figura 11. Score de anomalía frente a irradiancia en Isolation Forest



Fuente: elaboración propia.

Tabla 8. Resultados por tipo de anomalía del modelo Isolation Forest con reglas físicas

Métrica	Nº anomalías	Porcentaje
Anomalía Isolation Forest	3328	3.3%
Potencia casi nula con sol suficiente	770	0.76%
Irradiancia alta y potencia muy baja	72	0.07%
Irradiancia media y potencia baja	5638	5.58%
Baja eficiencia relativa	182	0.18%
Irradiancia alta con potencia baja	209	0.21%
Fallo claro final	821	0.81%
Subproducción moderada	342	0.33%
Anomalía final	940	0.93%

Fuente: elaboración propia.

Por lo tanto, podemos destacar que esta estrategia identifica 940 anomalías finales sobre 101013 registros de test. La tasa final de anomalías es 0.9306 %. Las anomalías detectadas se concentran visualmente en regiones de subproducción, especialmente cuando existe irradiancia suficiente pero la potencia “S2WACA” es baja. Además, la combinación de *score* no supervisado y reglas físicas reduce la salida directa del Isolation Forest desde 3.2946 % hasta una valoración final más selectiva de 0.9306 %.

6.1.2. Random Forest Regressor modelo base

Anteriormente se ha comentado que se ha probado el modelo base y uno más optimizado al incluir más variables ambientales. Por lo tanto, se va a analizar los resultados obtenidos para ambos.

En el conjunto de validación, el modelo obtuvo un *MAE* de 116.33, un *RMSE* de 158.42 y un R^2 de 0.9532. En el de *test*, obtuvo un *MAE* de 115.67, un *RMSE* de 157.83 y un R^2 de 0.9502. Especialmente la última métrica demuestra que se explica bien la variabilidad de la potencia.

Por otro lado, una vez entrenado el modelo y obtenida la potencia estimada para cada registro, se calculó el error de predicción con el objetivo de identificar desviaciones significativas respecto al comportamiento esperado del sistema. A partir de este residuo se calcularon dos métricas de error. La primera fue el error absoluto, que mide la magnitud de la desviación sin tener en cuenta el signo del error. La segunda fue el error relativo, que normaliza el error absoluto respecto a la potencia esperada, evitando que una misma desviación tenga la misma importancia en situaciones de baja y alta producción.

Los umbrales de anomalía se estimaron sobre el conjunto de validación. En concreto, se empleó el cuantil 0.996 de la distribución del error absoluto y del error relativo en validación obteniendo los siguientes valores.

- Umbral absoluto del residuo: 726.24
- Umbral relativo del error: 1.10


A partir de estos umbrales se definieron tres criterios de detección. El primero, *anomaly_abs_residual*, marca como anómalas las observaciones cuyo error absoluto supera el umbral absoluto. En este caso representa el 0.36% del conjunto de *test*. El segundo, *anomaly_rf_residual*, es más restrictivo, ya que exige que se superen simultáneamente el umbral absoluto y el umbral relativo, con un porcentaje de 0.03%. El tercero, *anomaly_rf_soft*,

es más sensible, puesto que marca como anomalía aquellos registros que superan al menos uno de los dos umbrales, es decir, el 0.9%.

En la siguiente gráfica se observa que la mayoría de puntos se sitúan por debajo del umbral absoluto, lo que indica que gran parte de las predicciones presentan errores moderados.

Los puntos marcados como anomalías aparecen principalmente por encima de la línea horizontal del umbral. Sin embargo, se observan diferencias claras que pueden representar días nublados (cambios bruscos en general), en donde el residuo supera el umbral definido...


Figura 12. Modelo base. Error absoluto frente a potencia esperada



Fuente: elaboración propia.

Además, si nos fijamos en la gráfica de la relación entre la irradiancia y la potencia, podemos apreciar que hay una clara tendencia o agrupación. En concreto, a mayor “GHRADA”, mayor “S2WACA”. Las anomalías han sido detectadas en puntos con potencia muy baja para irradiancia medias-altas, y puntos con potencia elevada en condiciones de baja irradiancia. Las anomalías marcadas aparecen en zonas donde la potencia se aleja del comportamiento mayoritario. Estos pueden representar lecturas inconsistentes o comportamientos no normales.

Figura 13. Modelo base. Relación irradiancia-potencia




Fuente: elaboración propia.

Por otro lado, se ha visualizado la gráfica de la distribución de residuos del modelo. En condiciones ideales, los puntos deberían distribuirse alrededor de la línea horizontal de residuo cero. En la gráfica se observa precisamente una concentración importante alrededor de esa línea, lo que indica que el modelo tiene un comportamiento predictivo estable.

Los valores negativos del residuo son especialmente relevantes para detección de anomalías fotovoltaicas, porque significan que la potencia real es menor que la potencia esperada. Es decir, el sistema está produciendo menos de lo que el modelo estima como normal bajo esas condiciones. Este tipo de desviación puede asociarse a subproducción, suciedad, sombreado, o pérdida de rendimiento en sí.

Figura 14. Modelo base. Distribución de residuos del modelo




Fuente: elaboración propia.

La gráfica del residuo frente a la potencia esperada permite analizar cómo se distribuyen los errores del modelo en función del nivel de potencia que el modelo estima para cada instante.

Por tanto, los valores cercanos a cero indican que la predicción del modelo se aproxima a la potencia real medida. Los residuos positivos representan casos en los que la potencia real fue superior a la estimada, mientras que los residuos negativos representan casos en los que la potencia real fue inferior a la esperada.

En la gráfica se observa que la mayoría de los puntos se concentra alrededor de la línea horizontal de residuo cero. Esto indica que, para gran parte de los registros del conjunto de *test*, el modelo predice la potencia con un error moderado.

Figura 15. Modelo base. Distribución del residuo frente a la potencia esperada




Fuente: elaboración propia.

La gráfica de importancia de variables muestra que el modelo depende principalmente de variables relacionadas con la irradiancia. La variable más importante es “*GHRADA*”, con una importancia de 0.5200, seguida de “*DIRRAA*”, con 0.2504.

La potencia generada por un sistema fotovoltaico depende principalmente de la irradiancia disponible. La temperatura, humedad, viento y variables temporales aportan información adicional, pero en este caso su influencia es secundaria frente a la radiación solar.

La importancia de variables confirma que el modelo ha aprendido una relación físicamente razonable: la predicción de “*S2WACA*” está dominada por la irradiancia global y directa, no por variables irrelevantes.

Figura 16. Modelo base. Importancia de las variables del modelo Random Forest Regressor



Fuente: elaboración propia.

El modelo tiene un buen comportamiento como modelo predictivo de potencia, ya que los residuos se concentran alrededor de cero y la relación irradiancia-potencia sigue un patrón coherente. No obstante, también muestran que la detección de anomalías es bastante conservadora. Los umbrales son elevados y solo se identifican como anomalías los casos con errores muy extremos. Esto explica que la anomalía combinada detecte únicamente el 0.03% del test, mientras que la anomalía *soft* alcanza el 0.90%.

6.1.3. Random Forest Regressor modelo optimizado con variables ambientales

Al repetir el proceso, pero incluyendo las variables ambientales y de sensores previamente descritas, podemos analizar si se obtienen unos mejores resultados. En especial en el caso de subproducción.

En este caso, el conjunto de entrenamiento ha constado de 612460 registros. En validación, el modelo obtiene un ajuste muy alto, con $R^2 = 0.989$, $MAE = 57.26$ y $RMSE = 76.61$. En test, el rendimiento disminuye, pero sigue siendo elevado, con $R^2 = 0.9721$, $MAE = 88.55$ y $RMSE = 118.14$.

Por otro lado, se observa que el MAE es similar al del modelo base, pero el $RMSE$ baja de 143.87 a 129.23 y el R^2 sube de 0.9588 a 0.9643, por lo que el ajuste general es más robusto.

Además, el umbral absoluto también baja bastante, de 705W a 313W, haciendo que el modelo sea más sensible a desviaciones relevantes.


Los umbrales de anomalía se calcularon exclusivamente sobre el conjunto de validación. En concreto, se empleó el cuantil 0.995 de las distribuciones de error en validación, de forma que los umbrales representan valores extremos, pero todavía observados dentro de un periodo independiente al entrenamiento. Los valores obtenidos han sido los siguientes.

- Umbral absoluto sensible: 224.47
- Umbral relativo sensible: 0.59
- Umbral de subproducción sensible: 217.58

El umbral absoluto establece que una observación se considera candidata a anomalía cuando la diferencia entre potencia real y potencia predicha supera aproximadamente 224W. El umbral relativo complementa esta medida, ya que permite detectar desviaciones proporcionalmente elevadas respecto a la potencia esperada. Por último, el umbral de subproducción identifica casos en los que la potencia real queda por debajo de la predicción en más de 217 W.

En la siguiente gráfica que relaciona la irradiancia y la potencia, las anomalías se distribuyen principalmente en los bordes de la nube, es decir, en puntos con potencia inferior a la esperada para irradiancia altas, en puntos con potencia alta para irradiancia relativamente baja y también en algunos errores aislados extremos. En ella, se observa una tendencia a la subproducción.


Figura 17. Modelo optimizado. Relación irradiancia-potencia



Fuente: elaboración propia.

Al mirar en detalle la gráfica del error absoluto frente a la potencia esperada, se observa como la mayoría de puntos queda por debajo del umbral de 224.47W. Las anomalías se concentran por encima de esa línea y se observan sobre todo en niveles medios (casi altos) de potencia esperada. Al obtener un umbral más bajo que anteriormente, se pueden detectar más desviaciones.


Figura 18. Modelo optimizado. Error absoluto frente a potencia esperada



Fuente: elaboración propia.

También cabe recalcar que la distribución de residuos del modelo optimizado es más estrecha que la del modelo anterior. La mayor parte de los residuos se concentra cerca de cero y los umbrales están mucho más próximos al centro, lo que confirma que el error típico se ha reducido, en comparación con el modelo base. Se muestra que los registros etiquetados como anómalos corresponden a errores situados en zonas poco frecuentes de la distribución.

Figura 19. Modelo optimizado. Distribución de residuos del modelo




Fuente: elaboración propia.

La gráfica de residuo frente a potencia esperada muestra que la mayoría de los registros se agrupan alrededor de la línea de residuo cero. Esto indica que, en general, la potencia predicha y la potencia real son similares.

Los puntos anómalos aparecen mayoritariamente con residuos negativos, lo que significa que la “S2WACA” real es menor que la predicha. Por tanto, las anomalías detectadas corresponden principalmente a casos donde el sistema produce menos de lo esperado. Esto es especialmente relevante porque el modelo no se limita a detectar errores grandes, sino que prioriza los errores asociados a pérdidas de producción.


Figura 20. Modelo optimizado. Distribución del residuo frente a la potencia esperada



Fuente: elaboración propia.

Por otro lado, la gráfica de importancia de variables muestra que el modelo basa sus predicciones principalmente en variables relacionadas con la irradiancia y la respuesta física del sistema. La variable más importante es “POAIR1”, con una importancia de 0.4224, seguida de “GHRADA”, con 0.2637, y “DIRRAA”, con 0.1544. Es decir, la potencia generada depende principalmente de la radiación disponible y de las condiciones físicas del sistema.

Figura 21. Modelo optimizado. Importancia de las variables del modelo Random Forest Regressor



Fuente: elaboración propia.

En conclusión, se observa que este modelo ajusta correctamente la relación entre condiciones ambientales y potencia generada. La mayor parte de los residuos se concentra cerca de cero, las anomalías aparecen en zonas de error elevado y, especialmente, en regiones donde la potencia real es inferior a la esperada.

6.2. RESULTADOS DEL APRENDIZAJE SEMISUPERVISADO

En este apartado se presentan los resultados obtenidos mediante el enfoque de aprendizaje semisupervisado descrito en el capítulo 5. Las métricas proceden de dos fuentes: la validación del modelo de potencia esperada y el recuento de candidatos generados por los criterios de residuo e Isolation Forest.

6.2.1. Métricas del modelo de potencia esperada

El componente regresivo del enfoque se evaluó con las métricas *MAE*, *RMSE* y R^2 . Estas métricas se calcularon sobre el conjunto de validación utilizado para comprobar la capacidad del modelo de reproducir el comportamiento normal antes de aplicar la detección de anomalías.

Tabla 9. Métricas del modelo semisupervisado de potencia esperada


Métrica	Valor	Procedencia
Filas cargadas	3155040	Registros 2018-2023 integrados
Filas diurnas evaluadas	1338626	Registros con irradiancia suficiente
Candidatos para entrenamiento	304193	Filas limpias para aprender comportamiento normal
Filas de entrenamiento	200000	Muestra usada por el regresor
Filas de validación	50000	Muestra independiente para evaluar el ajuste
MAE	24.02 W	Error absoluto medio de potencia esperada
RMSE	35.97 W	Error cuadrático medio
R²	0.9966	Variabilidad explicada por el modelo
Umbral baja generación	-878.19 W	Residuo absoluto usado para candidatos

Fuente: elaboración propia.

El pipeline experimental se ejecutó sobre 3155040 registros correspondientes al periodo 2018-2023. De este conjunto, 1338626 observaciones fueron diurnas y, por tanto, susceptibles de ser evaluadas por el sistema de detección. La muestra empleada para el aprendizaje del comportamiento normal quedó formada por 304193 registros candidatos, de los cuales se utilizaron 200000 para entrenamiento y 50000 para validación.

El modelo de potencia esperada alcanzó un ajuste elevado sobre el conjunto limpio y diurno, con un coeficiente de determinación de 0.9966, un error absoluto medio de 24.02 W y un error cuadrático medio de 35.97 W.

Tabla 10. Distribución del modelo semisupervisado



Fuente: elaboración propia.

6.2.2. Resultados de detección de anomalías

La detección se organizó en dos salidas principales. La primera corresponde a candidatos de baja generación, definidos por una potencia real claramente inferior a la esperada con irradiancia suficiente. La segunda corresponde a observaciones de consistencia eléctrica anómala identificadas mediante *Isolation Forest* sobre el subconjunto de normales seguros.


Tabla 11. Resultados de detección del aprendizaje semisupervisado

Resultado	Cantidad	Porcentaje	Criterio
Candidato baja generación	3078	0.23 %	Potencia real muy inferior a la esperada con irradiancia suficiente
Anomalía consistencia eléctrica	95979	7.17 %	Isolation Forest sobre normales seguros y variables eléctricas
Días con baja generación	20	-	Días con al menos un candidato de baja generación
Días con tasa diaria > 10 %	13	-	Días con concentración relevante de candidatos

Fuente: elaboración propia.

En el conjunto de observaciones diurnas, el criterio de baja generación identificó 3078 registros candidatos, equivalentes al 0.23 % del total evaluado. El detector complementario de consistencia eléctrica marcó 95979 registros, lo que supone un 7.17 % del total diurno. Los candidatos a baja generación aparecieron en 20 días del periodo analizado y 13 de esos días superaron una tasa diaria del 10 %.

Figura 22. Tasa de detección por criterio sobre los registros diurnos




Fuente: elaboración propia.

6.2.3. Relación entre potencia esperada, potencia real y residuo

En la representación de potencia real frente a potencia esperada, la mayor parte de las observaciones diurnas se distribuyen alrededor de la diagonal, lo que indica concordancia entre ambas magnitudes.


Los candidatos a baja generación aparecen concentrados en la zona inferior de la gráfica, con potencia real nula o muy reducida pese a existir una potencia esperada positiva.

Figura 23. Relación entre potencia esperada y potencia real en el enfoque semisupervisado



Fuente: elaboración propia.

Figura 24. Residuo frente a potencia esperada y umbral de baja generación



Fuente: elaboración propia.

6.2.4. Concentración temporal de los candidatos

La distribución temporal de los candidatos no fue homogénea. La mayor concentración se produjo en septiembre de 2018, con varios días consecutivos en los que la tasa diaria de candidatos a baja generación superó el 10 %. La tabla siguiente recoge las jornadas con mayor concentración.


Tabla 12. Días con mayor tasa de candidatos a baja generación

Fecha	Registros diurnos	Candidatos	Tasa diaria (%)	Potencia esperada mediana (W)	Potencia real mediana (W)
2018-09-17	657	434	66.06	1408.63	0.00
2018-09-18	650	426	65.54	1523.01	0.00
2018-09-14	649	370	57.01	1284.01	0.00
2018-09-16	643	326	50.70	917.98	0.00
2018-09-15	652	291	44.63	952.73	0.00
2018-09-11	635	247	38.90	981.70	0.00
2018-09-08	637	235	36.89	982.14	0.00
2018-09-09	652	206	31.60	778.78	0.00

Fuente: elaboración propia.

En particular, los días 17 y 18 de septiembre presentaron tasas diarias superiores al 65 %, mientras que los días 14, 15 y 16 también mostraron porcentajes muy elevados de registros marcados. En estas jornadas, la potencia mediana real se situó en torno a 0 W pese a que la potencia esperada calculada por el modelo era claramente positiva.

Figura 25. Evolución diaria de la tasa de candidatos a baja generación



Fuente: elaboración propia.

6.2.5. Calidad de los datos usados en el experimento

Como complemento a las métricas del modelo, se resume la calidad de las variables con mayor porcentaje de valores no utilizables tras aplicar la depuración. Esta información permite contextualizar la selección de variables usada durante el entrenamiento semisupervisado.

Tabla 13. Variables con mayor porcentaje de información no utilizable

Variable	No utilizable (%)	Utilizable (%)
REC2TE	47.55	52.45
MODT15	42.95	57.05
MODT10	27.16	72.84
TMPCAV	21.79	78.21
MODT09	19.84	80.16
RHPCTA	13.57	86.43

Fuente: elaboración propia.

La depuración previa mostró que la calidad del dato no era homogénea. Las mayores pérdidas de información se concentraron en variables como “REC2TE”, “MODT15”, “MODT10” y “TMPCAV” que no llegan a utilizarse el 80 % de la información que proporcionan, lo que confirmó la necesidad de aplicar una selección cuidadosa de variables antes del entrenamiento.

6.3. RESULTADOS DEL AUTOENCODER

En este apartado se presentan los resultados obtenidos mediante la aplicación de modelos de *autoencoder*.

Tal y como se ha descrito al comentar el proceso, se han desarrollado dos configuraciones distintas:

1. Una primera que incorpora tanto las variables eléctricas como las variables ambientales procedentes del fichero *FSEC_Regional_Test_Ambient_data.csv*.
2. Una segunda en la que dichas variables ambientales no se incluyen.

El análisis de resultados se aborda de forma progresiva, comenzando por la evolución del entrenamiento, continuando con la distribución del error de reconstrucción y la predicción de anomalías sobre los distintos conjuntos de datos, y finalizando con una interpretación de los patrones detectados mediante K-Means sobre las anomalías identificadas.


6.3.1. Entrenamiento de los modelos

Sin Variables Ambientales

En conjunto, la evolución de ambas curvas en el modelo entrenado sin variables ambientales muestra un entrenamiento estable y sin signos claros de sobreajuste severo.

Durante las primeras épocas se observa una reducción pronunciada del error de reconstrucción, especialmente en el conjunto de entrenamiento, lo que indica que el *autoencoder* aprende rápidamente los patrones principales del funcionamiento normal del sistema fotovoltaico. A partir de las épocas intermedias, la pérdida de entrenamiento continúa disminuyendo de forma más progresiva, mientras que la pérdida de validación se mantiene en valores bajos, con ligeras oscilaciones.

Figura 26. Evolución del entrenamiento del autoencoder en modelo sin variables ambientales




Fuente: elaboración propia.

El modelo final se selecciona en la época 10, momento en el que se alcanza un equilibrio adecuado entre la reducción del error y la estabilidad del entrenamiento. A partir de ese punto, la pérdida de validación no mejora de forma consistente y presenta ligeros aumentos puntuales, lo que sugiere que continuar el entrenamiento no aporta una mejora relevante y podría incrementar el riesgo de *overfitting*.

Con Variables Ambientales

En el modelo entrenado con variables ambientales se observa que la pérdida de entrenamiento presenta una evolución estable, con un descenso progresivo desde las primeras épocas hasta situarse en valores próximos a 3.5. Esta curva no muestra oscilaciones relevantes, lo que indica que el modelo aprende de forma continua los patrones presentes en el conjunto de entrenamiento.

Figura 27. Evolución del entrenamiento del autoencoder en modelo con variables ambientales



Fuente: elaboración propia.

La principal diferencia respecto al modelo sin variables ambientales aparece en la curva de validación. En este caso, la pérdida de validación parte de valores considerablemente más elevados y desciende de forma marcada durante las primeras épocas, hasta alcanzar su mínimo en la época 11, seleccionada como modelo final mediante *Early Stopping*. A partir de ese punto, la pérdida de validación presenta oscilaciones y no mantiene una mejora sostenida, con incrementos y descensos puntuales en las épocas posteriores.


Este comportamiento contrasta con el modelo sin variables ambientales, donde las curvas de entrenamiento y validación eran más próximas y mostraban una evolución más suave. La incorporación de variables ambientales parece introducir una mayor variabilidad en el proceso de aprendizaje, aumentando la complejidad y dispersión de los patrones que el *autoencoder* debe reconstruir.

6.3.2. Error de Reconstrucción

Sin Variables Ambientales

En la distribución del error de reconstrucción del modelo sin variables ambientales se observa que la mayor parte de las muestras de entrenamiento y validación se concentran en valores bajos de error, principalmente en el entorno de 10^{-3} y 10^{-2} . Esto indica que el *autoencoder* reconstruye adecuadamente la mayoría de los registros utilizados para el aprendizaje y la validación del modelo, lo que resulta coherente con un comportamiento general estable del sistema.

Figura 28. Distribución del error de reconstrucción en modelo sin variables ambientales



Fuente: elaboración propia.


Además, ambas distribuciones presentan una zona amplia de solapamiento, lo que sugiere que el modelo ha aprendido patrones representativos del funcionamiento habitual del sistema fotovoltaico. No obstante, la distribución de validación muestra una cola derecha algo más prolongada, con algunos registros que presentan errores superiores, reflejando situaciones menos frecuentes o más difíciles de reconstruir.

Por este motivo, tal y como se ha comentado en el apartado de procedimiento, se ha seleccionado el percentil 99.9 como umbral de anomalía, ya que permite adoptar un criterio conservador, centrado en identificar únicamente los registros con errores de reconstrucción claramente extremos dentro del conjunto de validación.

Con Variables Ambientales

En la distribución del error de reconstrucción del modelo con variables ambientales se observa que los errores se desplazan hacia valores superiores respecto al modelo sin variables ambientales. En este caso, la mayor parte de las muestras de entrenamiento y validación se concentran aproximadamente entre 0.1 y 1, aunque aparecen también algunos grupos de registros con errores más elevados. Esto indica que la reconstrucción resulta más compleja al incorporar información ambiental al conjunto de entrada, ya que estas variables introducen una mayor variabilidad en los patrones que el *autoencoder* debe aprender.

Figura 29. Distribución del error de reconstrucción en modelo con variables ambientales



Fuente: elaboración propia.


Aunque las distribuciones de entrenamiento y validación presentan cierto solapamiento, también se aprecian varios picos diferenciados y valores aislados en la cola derecha de la distribución. Estos registros reflejan observaciones más difíciles de reconstruir, presentando una distribución de errores más dispersa y menos concentrada que el modelo sin variables ambientales.

6.3.3. Detección de Anomalías sobre el Conjunto

Sin Variables Ambientales

En primer lugar, se aplica el modelo sin variables ambientales sobre el conjunto formado por entrenamiento y validación depurados, junto con el conjunto de *test* con *outliers*.

Figura 30. Detección de anomalías en modelo sin ambientales mediante autoencoder - Train + Val. (sin Outliers) + Test



Fuente: elaboración propia.

En esta representación se observa que la mayor parte de las observaciones normales se mantienen por debajo del umbral de anomalía, lo que indica que el *autoencoder* reconstruye correctamente el comportamiento habitual aprendido durante el entrenamiento.

Las anomalías detectadas aparecen de forma puntual en los periodos de *train* y *validation*, lo cual no resulta contradictorio, ya que la eliminación previa de *outliers* solo retira valores físicamente incoherentes, pero no impide que existan registros con un error de reconstrucción elevado. No obstante, las anomalías se concentran principalmente en el periodo de *test*, donde aparecen numerosos registros con errores muy superiores al umbral. Este comportamiento es coherente con el planteamiento del experimento, ya que el modelo ha sido entrenado y validado sobre datos depurados, mientras que el conjunto de *test* se mantiene completo para evaluar su capacidad de detección sobre observaciones no filtradas.

Al aplicar el mismo modelo sobre el conjunto completo de *train*, *validation* y *test* con *outliers*, el número de anomalías detectadas aumenta de forma considerable.

Figura 31. Detección de anomalías en modelo sin ambientales mediante autoencoder - Train + Val. (con Outliers) + Test



Fuente: elaboración propia.

En este caso, aparecen registros anómalos no solo en test, sino también a lo largo de los periodos de entrenamiento y validación. La presencia de estos puntos con errores elevados confirma que los conjuntos originales contenían observaciones claramente alejadas del patrón normal del sistema.


Además, se observan algunos intervalos con errores muy altos y relativamente agrupados en el tiempo, lo que sugiere que no se trata únicamente de desviaciones aisladas, sino de posibles periodos con comportamientos anómalos persistentes.

Con Variables Ambientales

En el modelo con variables ambientales, al aplicar el *autoencoder* sobre el conjunto de entrenamiento y validación sin *outliers* junto con el conjunto completo de *test*, se observa que la mayoría de las observaciones normales quedan por debajo del umbral de anomalía.

Sin embargo, tal y como se ve en la imagen, el umbral definido inicialmente resulta muy elevado, por lo que solo se clasifican como anómalos los registros con errores de reconstrucción extremadamente altos, concentrados principalmente en el periodo de *test*.

Figura 32. Detección de anomalías en modelo con ambientales mediante autoencoder - Train + Val. (sin Outliers) + Test



Fuente: elaboración propia.

Este comportamiento indica que el criterio inicial de detección es demasiado conservador. Aunque permite identificar los casos más extremos, deja fuera otros registros con errores de reconstrucción elevados que también podrían representar comportamientos anómalos o desviaciones relevantes del patrón normal.

Al igual que en el modelo sin variables ambientales, cuando el modelo se aplica sobre el conjunto completo de *train*, *validation* y *test*, aparecen anomalías distribuidas a lo largo de los tres periodos, siendo los casos nuevos los *outliers* retirados durante el entrenamiento. Por este motivo, tal y como se comenta en el apartado de desarrollo, se decidió reducir el umbral al percentil 95.


Figura 33. Detección de anomalías en modelo con ambientales mediante autoencoder - Train + Val. (con Outliers) + Test



Fuente: elaboración propia.

Con este nuevo criterio, el modelo incrementa su sensibilidad y detecta un mayor número de observaciones anómalas, incluyendo registros con desviaciones menos extremas, pero igualmente diferenciadas del patrón normal.

Figura 34. Detección de anomalías con umbral ajustado al percentil 95



Fuente: elaboración propia.


A partir de este punto, los resultados del modelo con variables ambientales se interpretan considerando el umbral definido mediante el percentil 95.

6.3.4. Caracterización de anomalías mediante K-Means

Sin Variables Ambientales

A continuación, se muestra la gráfica obtenida tras aplicar el método del codo sobre el conjunto de anomalías en el *dataset* de entrenamiento. La curva muestra una reducción clara de la inercia hasta $k = 3$ y una mejora adicional al pasar a $k = 4$. A partir de ese punto, la disminución es mucho menor.

Figura 35. Método del codo sobre modelo sin variables ambientales



Fuente: elaboración propia.

Finalmente, se seleccionó $k = 4$ como una opción equilibrada, ya que permite diferenciar con mayor detalle los perfiles de anomalía detectados sin generar una segmentación excesivamente compleja. Aunque la solución con tres clústeres resulta más simple, tiende a agrupar en un mismo grupo anomalías de naturaleza más heterogénea. Por ello, se consideró que cuatro clústeres ofrecían una mejor interpretación técnica de los distintos patrones de desviación identificados. A continuación, se muestra para cada uno de los grupos las variables con el error medio más elevado:

Tabla 14. Clúster 0 de modelo sin variables ambientales

Clúster 0	
Campo	Error
MODT10	533.840932
SY2VDC	194.769041
MODT12	120.061097
hour_sin	79.100481
MODT09	75.329098
REC2IR	58.951761
hour_cos	49.225272
S2FRQA	41.199021
doy_cos	35.106294
REC2TE	34.783696

Fuente: elaboración propia.

Tabla 15. Clúster 1 de modelo sin variables ambientales

Clúster 1	
Campo	Error
S2FRQA	1.260835e+06
SY2VDC	4.097558e+05
MODT10	1.540172e+05
S2PFAV	1.295127e+05
S2S1DC	1.260375e+05
S2S2DC	5.523479e+04
MODT12	4.702799e+04
MODT14	4.338580e+04
S2WACA	3.237717e+04
hour_cos	3.022569e+04

Fuente: elaboración propia.

Tabla 16. Clúster 2 de modelo sin variables ambientales

Clúster 2	
Campo	Error
MODT11	1405.154546
MODT13	1344.861236
MODT14	1343.395863
MODT16	995.495100
SY2VDC	927.075528
REC2TE	923.376053
MODT10	787.011852
MODT12	503.733844
doy_sin	311.785987
S2VACA	208.696862

Fuente: elaboración propia.

Tabla 17. Clúster 3 de modelo sin variables ambientales

Clúster 3	
Campo	Error
MODT12	467.064536
MODT09	282.613639
SY2VDC	121.648682
S2FRQA	97.998519
S2PFAV	89.140361
MODT10	81.112762
MODT11	69.580219
MODT13	65.863025
MODT14	63.248218
S2S1DC	60.341966

Fuente: elaboración propia.


El *clúster 1* es el que presenta los errores de reconstrucción más elevados, con una diferencia de varios órdenes de magnitud respecto al resto de grupos. Las variables con mayor error medio son principalmente “S2FRQA”, “SY2VDC”, “S2PFAV”, “S2S1DC”, “S2S2DC” y “S2WACA”, junto con algunas variables de temperatura de módulo. Esto indica que este grupo recoge las anomalías más severas, *outliers* asociados a desviaciones importantes en variables eléctricas del sistema.

El *clúster 2* está dominado principalmente por errores en variables de temperatura de los módulos, como “MODT11”, “MODT13”, “MODT14” y “MODT16”, además de “SY2VDC” y “REC2TE”. Este patrón sugiere anomalías en las que el componente térmico del sistema tiene un peso importante en la desviación detectada. A diferencia del *clúster 1*, no se trata únicamente de errores eléctricos extremos, sino de registros en los que el modelo tiene dificultad para reconstruir adecuadamente determinadas condiciones térmicas asociadas al funcionamiento del sistema fotovoltaico.

Por otro lado, los *clústeres 0 y 3* presentan errores medios más moderados. En ambos casos aparecen variables como “MODT10”, “MODT12”, “MODT09”, “SY2VDC”, “S2FRQA” y variables temporales como “hour_sin”, “hour_cos” o “day_cos”. Estos dos grupos recogen anomalías menos extremas, pero caracterizadas por una combinación de desviaciones térmicas, eléctricas y temporales. El *clúster 0* parece recoger situaciones mixtas en las que destaca el módulo térmico 10, mientras que el *clúster 3* muestra un patrón similar, aunque con mayor peso del módulo térmico 12.


En las gráficas siguientes se puede visualizar la *clusterización* de las anomalías al aplicar K-Means sobre el conjunto de entrenamiento y de *validación + test*.

Figura 36. Clusterización de anomalías en modelo sin ambientales aplicado sobre dataset de train



Fuente: elaboración propia.

Figura 37. Clusterización de anomalías en modelo sin ambientales aplicado sobre dataset de validación + test



Fuente: elaboración propia.


Visualmente, el *clúster 1* destaca por concentrar los errores de reconstrucción más elevados en ambos conjuntos, lo que coincide con su interpretación como grupo de anomalías más severas. Este patrón se mantiene tanto en el conjunto de entrenamiento como en el de validación y test, lo que sugiere que el perfil aprendido por K-Means es consistente al aplicarse sobre datos posteriores.

Por su parte, los *clústeres 0 y 3* se sitúan en rangos de error más moderados, aunque todavía por encima del umbral de anomalía, por lo que representan desviaciones menos extremas, pero claramente diferenciadas del comportamiento normal. Finalmente, el *clúster 2* aparece con menor frecuencia y ocupa una posición intermedia entre las anomalías más severas del *clúster 1* y los patrones más moderados de los *clústeres 0 y 3*.

Para complementar la evaluación del modelo, se ha analizado la relación entre la potencia generada y el comportamiento medio de las variables térmicas.


En las siguientes gráficas se puede ver la relación entre la potencia generada y el valor medio de las variables térmicas en la escala utilizada por el modelo, así como su error de reconstrucción.

Figura 38. Relación entre potencia generada y valor medio de las variables térmicas (modelo sin variables ambientales)



Fuente: elaboración propia.

Figura 39. Relación entre potencia generada y error medio de reconstrucción térmica (modelo sin variables ambientales)



Fuente: elaboración propia.

En estas representaciones se observa que las observaciones normales presentan errores de reconstrucción térmica reducidos y se concentran en una zona más estable de la relación entre potencia generada y comportamiento medio de los sensores térmicos. Por el contrario, las

anomalías detectadas se alejan de esta nube principal y muestran errores térmicos notablemente superiores, lo que indica que el *autoencoder* presenta mayores dificultades para reconstruir registros con patrones térmicos atípicos.


Por otro lado, la distribución por clústeres permite diferenciar distintos perfiles de anomalía. Tal y como se ha venido comentando previamente, el *clúster 1* recoge los casos más extremos, mientras que el *clúster 2* parece estar especialmente asociado a desviaciones térmicas relevantes y negativas. Los *clústeres 0 y 3* agrupan anomalías de menor magnitud o de carácter más mixto, aunque igualmente diferenciadas del comportamiento normal.

Finalmente, se ha realizado un análisis individual de los sensores térmicos frente a la potencia generada, con el objetivo de comprobar si los patrones observados en la media térmica se mantienen a nivel de variable.

En general, las gráficas muestran que las observaciones normales se concentran en la zona principal de funcionamiento, no respondiendo únicamente a un único patrón global, sino permitiendo distinguir desviaciones asociadas a sensores térmicos concretos.

A continuación, se han seleccionado las dos gráficas de dispersión más representativas, los diagramas de dispersión de “*MODT09*” y “*MODT10*”.

Figura 40. Relación entre potencia generada y valor de las variables *MODT09* y *MODT10* (modelo sin variables ambientales)



Fuente: elaboración propia.

En ellas se observa que el *clúster 3* parece recoger de forma más clara las anomalías asociadas a “*MODT09*”, mientras que el *clúster 0* muestra una asociación más evidente con “*MODT10*”. Esto sugiere que ambos clústeres no representan exactamente el mismo tipo de desviación térmica, sino que pueden estar relacionados con sensores o patrones de error distintos.


Por su parte, el *clúster 2* se concentra mayoritariamente en valores térmicos bajos o negativos en la escala del modelo, reforzando su interpretación como un grupo de anomalías con componente térmico claramente diferenciado.

Con Variables Ambientales

A continuación, se muestra la gráfica obtenida tras aplicar el método del codo sobre el conjunto de anomalías detectadas por el modelo con variables ambientales en el *dataset* de entrenamiento.

La curva presenta una reducción muy pronunciada de la inercia al pasar de $k = 1$ a $k = 2$ y continúa descendiendo de forma relevante hasta $k = 3$. A partir de este punto, la disminución de la inercia es mucho más gradual, aunque todavía se observa una mejora adicional al pasar a $k = 4$.

Figura 41. Método del codo sobre modelo con variables ambientales



Fuente: elaboración propia.

Al igual que en el modelo sin variables ambientales, se optó por $k = 4$ como una opción equilibrada entre ajuste e interpretabilidad. Pese a que el punto de codo se sitúa principalmente en torno a $k = 3$, la solución con cuatro clústeres permite diferenciar con mayor detalle los perfiles de anomalía detectados. Por ello, se consideró que $k = 4$ ofrecía una interpretación técnica más completa de los distintos patrones asociados a las anomalías.

A continuación, al igual que se hizo en el modelo sin variables ambientales, se muestran para cada uno de los grupos las variables con el error medio más elevado.

Tabla 18. Clúster 0 de modelo con variables ambientales

Clúster 0	
Campo	Error
WSMEAN	1.734916e+06
S2FRQA	1.612140e+06
PMBARA	9.163091e+05
TMPCAV	8.877249e+05
RHPCTA	3.761101e+05
S2PFAV	9.491097e+04
WDIREA	7.376686e+04
S2S2DC	3.659444e+04
hour_cos	1.868135e+04
doy_cos	1.200361e+04

Fuente: elaboración propia.

Tabla 19. Clúster 1 de modelo con variables ambientales

Clúster 1	
Campo	Error
MODT12	1437.276286
MODT09	326.683848
WDIREA	199.048880
MODT10	146.104122
WSMEAN	136.845650
S2FRQA	112.096619
PMBARA	67.687891
TMPCAV	66.204344
DIRRAA	54.144220
RHPCTA	44.088188

Fuente: elaboración propia.

Tabla 20. Clúster 2 de modelo con variables ambientales

Clúster 2	
Campo	Error
MODT11	1870.119117
MODT14	1824.333666
MODT16	1779.960891
MODT13	1743.913210
MODT10	1726.355322
MODT12	1702.453025
WDIREA	1055.562419
MODT09	1006.048938
DIRRAA	516.160834
SY2VDC	278.431822

Fuente: elaboración propia.

Tabla 21. Clúster 3 de modelo con variables ambientales

Clúster 3	
Campo	Error
MODT10	1379.649138
WSMEAN	234.139737
RHPCTA	127.774794
TMPCAV	121.823850
PMBARA	103.142987
WDIREA	101.520205
DIRRAA	19.908629
SY2VDC	4.359772
S2FRQA	3.279361
S2PFAV	2.391411

Fuente: elaboración propia.

El *clúster 0* es el que presenta los errores de reconstrucción más elevados, con una diferencia muy marcada respecto al resto de grupos. En este caso, las variables con mayor error medio son principalmente “WSMEAN”, “S2FRQA”, “PMBARA”, “TMPCAV”, “RHPCTA”, “S2PFAV”, “WDIREA” y “S2S2DC”. Este patrón indica que el grupo recoge las anomalías más severas, pero a diferencia del modelo sin variables ambientales, estas no están asociadas únicamente a variables eléctricas, sino también a variables meteorológicas. Por tanto, este clúster parece representar *outliers* en los que se altera de forma conjunta la relación entre condiciones ambientales y respuesta eléctrica del sistema.


El *clúster 2* está dominado principalmente por errores en variables de temperatura de módulo, como “MODT11”, “MODT14”, “MODT16”, “MODT13”, “MODT10” y “MODT12”, junto con algunas variables ambientales como “WDIREA” y “DIRRAA”. Este comportamiento sugiere, al igual que en el modelo anterior, un grupo de anomalías con un componente térmico muy claro, en el que el modelo tiene dificultad para reconstruir de forma coherente el comportamiento de los sensores de temperatura en relación con las condiciones ambientales y eléctricas del sistema.

Por su parte, los *clústeres 1 y 3* presentan errores más moderados y perfiles más específicos. El primero muestra un mayor peso de “MODT12” y “MODT09”, acompañado de variables ambientales como “WDIREA”, “WSMEAN”, “PMBARA”, “TMPCAV” y “RHPCTA”. Esto sugiere anomalías térmicas de menor magnitud, vinculadas a determinados sensores y a condiciones ambientales concretas. El *clúster 3*, en cambio, está especialmente marcado por “MODT10” y

por variables ambientales como “WSMEAN”, “RHPCTA”, “TMPCAV”, “PMBARA” y “WDIREA”, por lo que puede interpretarse como un grupo de desviaciones mixtas, con influencia tanto térmica como meteorológica.


En las gráficas siguientes se visualiza la *clusterización* de las anomalías al aplicar K-Means sobre el conjunto de entrenamiento y sobre el conjunto de validación + test del modelo con variables ambientales.

Figura 42. Clusterización de anomalías en modelo con ambientales aplicado sobre dataset de train



Fuente: elaboración propia.

Figura 43. Clusterización de anomalías en modelo con ambientales aplicado sobre dataset de validación + test



Fuente: elaboración propia.

El *clúster 0* destaca por concentrar los errores de reconstrucción más elevados en ambos conjuntos, coincidiendo con su interpretación como el grupo de anomalías más severas u *outliers*.

Por otro lado, el *clúster 2* también aparece en rangos elevados de error, aunque por debajo del *clúster 0*, y se presenta de forma más puntual y agrupada en determinados periodos. Esto resulta coherente con su interpretación como un grupo de anomalías con un componente térmico relevante.

Por su parte, el *clúster 1* se sitúa principalmente en una banda intermedia de error, claramente por encima del umbral, pero sin alcanzar los valores extremos del *clúster 0*.


Finalmente, el *clúster 3* aparece mayoritariamente próximo al umbral de anomalía, por lo que representa desviaciones menos severas, aunque diferenciadas del comportamiento normal.

A continuación, se analiza la relación entre la potencia generada y tres variables agregadas, el valor medio de las variables térmicas, ambientales y la combinación de ambas. El objetivo de estas representaciones es comprobar si la *clusterización* permite diferenciar anomalías asociadas principalmente a desviaciones térmicas o ambientales.

En la gráfica correspondiente a las variables térmicas se observa que las observaciones normales se concentran en una zona principal de funcionamiento, mientras que las anomalías se sitúan en regiones alejadas o en bandas diferenciadas. Sin embargo, los *clústeres 1 y 3* no muestran una separación completamente limpia por componente térmico, distribuyéndose por zonas más amplias y compartiendo regiones con distintos rangos de potencia y temperatura media.

En la representación de las variables ambientales ocurre algo similar. Aunque algunas anomalías se sitúan en zonas claramente alejadas de la nube normal, especialmente las más extremas, ningún *clúster* se separa de forma exclusiva según el componente ambiental.


Figura 44. Relación entre potencia generada y valor medio de variables térmicas y ambientales por separado



Fuente: elaboración propia.

Por último, la tercera gráfica, que combina el valor medio térmico y ambiental, refuerza esta interpretación, ya que los *clústeres* aparecen más relacionados con patrones globales de desviación que debido a una única tipología de variable.

Figura 45. Relación entre potencia generada y valor medio de variables térmicas y ambientales en conjunto



Fuente: elaboración propia.

En conjunto, estos resultados indican que el modelo con variables ambientales aporta una visión más completa del comportamiento del sistema, pero también más compleja de interpretar.

6.4 DISCUSIÓN DE LOS RESULTADOS

En base a los resultados obtenidos en los distintos experimentos, se ha podido interpretar y observar que los modelos presentan comportamientos complementarios a la hora de detectar anomalías.

En la tabla que se puede observar a continuación, se resumen los distintos modelos construidos a lo largo del proyecto. En los siguientes párrafos, se desarrollará una interpretación comparativa de dichos resultados.

Tabla 22. Tabla comparativa de los modelos construidos

Modelo	Enfoque y aportación	Ventaja Principal	Limitación Principal
Isolation Forest	Exploración de observaciones atípicas implícitas en el conjunto de datos	Útil como una primera exploración, no requiere variable objetivo ni etiquetas	Puede generar falsos positivos si no se combina con reglas físicas
Random Forest Regressor base	Estimación de la potencia esperada a partir de variables principales	Modelo interpretable mediante análisis de residuos	Presenta una buena capacidad predictiva pero muy mejorable
Random Forest Regressor optimizado	Ídem modelo base incorporando variables ambientales y de sensores	Alta capacidad predictiva, residuos físicamente interpretables y permite detectar desviaciones más sutiles	Depende de la calidad de las variables ambientales y de los sensores, junto con un tratamiento de datos cuidadoso
Enfoque semisupervisado	Generación de potencia esperada frente a real con condiciones ambientales en series temporales	Diferenciación entre distintos tipos de subproducción anómala	Dependiente de umbrales aplicados a variables exógenas
Autoencoder + K-Means sin variables ambientales	Detección y clasificación multivariante de anomalías sin contexto ambiental	Permite caracterizar anomalías causadas por múltiples variables de forma no supervisada. Detección de <i>outliers</i> .	Interpretación más compleja que en los modelos anteriores
Autoencoder + K-Means con variables ambientales	Detección y clasificación multivariante de anomalías con contexto ambiental	Intenta aportar una visión más completa del comportamiento del sistema. Detección de <i>outliers</i> .	Clústeres más difíciles de interpretar y menos separables por tipología

Fuente: elaboración propia.

En primer lugar, los modelos basados en regresión, especialmente el Random Forest optimizado y el enfoque semisupervisado, presentan una elevada capacidad para reproducir la potencia esperada del sistema. Esto se refleja en valores altos de R^2 y errores reducidos, lo que permite identificar como anómalos aquellos registros en los que la potencia real se aleja de forma significativa de la potencia predicha.

Una conclusión común en estos modelos es que muchas de las anomalías detectadas corresponden a situaciones de subproducción. Es decir, registros en los que existe irradiancia suficiente o una potencia esperada positiva, pero la potencia real generada es muy baja o

incluso nula. Este patrón aparece tanto en Isolation Forest tras aplicar reglas físicas, como en Random Forest y en el enfoque semisupervisado. Por tanto, los resultados son coherentes desde el punto de vista físico, ya que las anomalías no se concentran de forma aleatoria, sino en zonas donde la relación entre irradiancia y potencia generada se rompe.

El modelo Isolation Forest permite detectar observaciones atípicas de forma no supervisada, pero sus resultados requieren una depuración posterior mediante reglas físicas para reducir el número de anomalías y centrarse en casos realmente interpretables. Esto se observa en la reducción desde una tasa inicial de anomalías del 3.30 % hasta el 0.93 % tras aplicar criterios físicos para realizar un filtrado inicial. Por tanto, este enfoque resulta útil como primera aproximación exploratoria, aunque menos preciso si se utiliza de forma aislada.

En el caso del Random Forest, la comparación entre el modelo base y el modelo optimizado muestra que la incorporación de variables ambientales y de sensores mejora la capacidad predictiva y reduce los umbrales de detección. Esto permite identificar desviaciones más sutiles respecto al comportamiento esperado del sistema. Además, el análisis de residuos muestra que muchas anomalías presentan residuos negativos, lo que confirma que el problema detectado está relacionado principalmente con pérdidas de producción.

El enfoque semisupervisado refuerza esta interpretación, ya que identifica candidatos de baja generación concentrados en días concretos, especialmente en septiembre de 2018, cuando la potencia real mediana se situó en torno a 0 W mientras que la potencia esperada era claramente positiva. Además, presenta una diferenciación dentro de los datos de baja producción, presenta un tipo de anomalía por baja producción con potencia esperada positiva de valor medio a una potencia esperada positiva de alto valor cuantitativo.

Por su parte, el *autoencoder* aporta una visión diferente, ya que no predice únicamente la potencia esperada, sino que aprende a reconstruir el comportamiento multivariante del sistema. Esto permite detectar registros anómalos a partir del error de reconstrucción global y, posteriormente, analizar qué variables contribuyen en mayor medida a dicho error.

En el modelo sin variables ambientales, los clústeres obtenidos mediante *K-Means* permiten diferenciar perfiles relativamente interpretables, asociados a anomalías eléctricas severas, desviaciones térmicas y patrones mixtos.

Sin embargo, al incorporar variables ambientales en el *autoencoder*, la interpretación se vuelve más compleja. La distribución del error de reconstrucción se desplaza hacia valores más elevados y los clústeres no separan de forma limpia anomalías térmicas y ambientales, sino que agrupan patrones mixtos. Esto indica que las variables ambientales aportan información relevante sobre el contexto de operación, pero también introducen mayor variabilidad y dificultan una clasificación directa por tipología de anomalía.

En conjunto, los resultados sugieren que los modelos supervisados o semisupervisados basados en potencia esperada son especialmente adecuados para detectar anomalías de subproducción, ya que ofrecen una interpretación física directa mediante el análisis de residuos. En cambio, el *autoencoder* resulta más útil como herramienta exploratoria y de caracterización multivariante, al permitir identificar perfiles de anomalía más amplios y analizar qué variables participan en cada desviación. Por ello, tal y como se ha mencionado previamente, no puede afirmarse que un único modelo sea superior en todos los aspectos, sino que cada enfoque aporta información distinta sobre el comportamiento anómalo del sistema.

Finalmente, la ausencia de etiquetas reales de fallo limita la comparación mediante métricas supervisadas clásicas. Por este motivo, la evaluación debe basarse en criterios indirectos, como la coherencia física de las anomalías detectadas, su distribución temporal, la relación irradiancia-potencia, el análisis de residuos y la interpretabilidad de los grupos obtenidos. Desde esta perspectiva, los resultados son consistentes, ya que los métodos coinciden en identificar desviaciones relevantes en la generación eléctrica, especialmente episodios de subproducción y registros alejados del comportamiento normal esperado.

Por último, la tabla siguiente resume el papel de cada modelo dentro del análisis realizado. Su objetivo no es establecer una comparación directa de rendimiento, ya que los modelos utilizan criterios de detección distintos y no se disponen de etiquetas reales de fallo, sino sintetizar qué tipo de anomalías identifica mejor cada enfoque y cuál sería su uso más adecuado.

Tabla 23. Comparación cualitativa de anomalías detectadas y uso recomendado

Enfoque	Anomalías detectadas	Uso recomendado
Isolation Forest	Registros alejados del comportamiento normal. Casos de baja generación o incoherencias operativas	Primer cribado
Random Forest Regressor base	Desviaciones entre potencia real y potencia predicha	Modelo base para comparar mejoras. Primera toma de contacto
Random Forest Regressor optimizado	Anomalías de subproducción	Detección principal de anomalías y pérdidas de producción
Enfoque semisupervisado	Episodios de baja generación o generación nula, en especial en días concretos	Detección de episodios de subproducción y análisis temporal de anomalías
Autoencoder + K-Means sin variables ambientales	Anomalías eléctricas, térmicas y patrones mixtos	Caracterización multivariante de anomalías y análisis exploratorio de fallos. Detección de <i>outliers</i> .
Autoencoder + K-Means con variables ambientales	Patrones anómalos multivariantes compuestos por variables térmicas y eléctricas y ambientales	Análisis global del comportamiento del sistema y detección de patrones complejos. Detección de <i>outliers</i> .

Fuente: elaboración propia.

En resumen, como se ha venido comentando, los distintos enfoques desempeñan funciones complementarias dentro del análisis. Isolation Forest se utiliza como método exploratorio para realizar un primer cribado de registros alejados del comportamiento normal, mientras que el Random Forest Regressor base sirve como referencia inicial para identificar desviaciones entre la potencia real y la estimada.

Tras su optimización, este modelo se orienta principalmente a la detección de situaciones de subproducción y posibles pérdidas de generación. El enfoque semisupervisado aporta un beneficio similar, permitiendo localizar episodios concretos de generación baja o nula y analizando su evolución temporal.

Por último, los modelos basados en *autoencoders* y K-Means amplían el análisis hacia patrones multivariantes. Al evitar usar variables ambientales, se facilita la identificación de anomalías eléctricas, térmicas y mixtas. Por el contrario, al incorporar dichas variables, se ofrece una visión más global del funcionamiento de la instalación y permiten detectar patrones anómalos más complejos, pese a dificultar su caracterización con K-Means.

7. Conclusiones y trabajo futuro

7.1. Conclusiones

El presente trabajo ha abordado el problema de la detección de anomalías en un sistema de generación fotovoltaica a partir de datos históricos de operación, teniendo como principal dificultad la ausencia de etiquetas reales de fallo. Por ese motivo, el problema se ha tratado mediante enfoques no supervisados y semisupervisados, tomando como referencia el comportamiento normal del sistema.

Para ello, se han aplicado y comparado distintos modelos:

1. Modelos estadísticos y basados en predicción de potencia esperada
2. Enfoque semisupervisado
3. *Autoencoders*

Esta comparación ha permitido estudiar las anomalías desde distintas perspectivas. Los modelos basados en potencia esperada han facilitado una interpretación física directa mediante el análisis de residuos, mientras que el *autoencoder* ha permitido estudiar el comportamiento multivariante del sistema a partir del error de reconstrucción.

Los resultados muestran que muchas de las anomalías detectadas están relacionadas con situaciones de subproducción, es decir, momentos en los que la potencia real generada es inferior a la esperada para las condiciones de irradiancia y operación existentes. Este patrón aparece de forma consistente en varios modelos, lo que refuerza la coherencia física de los resultados obtenidos.

Entre los modelos predictivos, el Random Forest optimizado con variables ambientales ha mostrado un mejor comportamiento que el modelo base, ya que permite estimar la potencia esperada con mayor precisión y definir umbrales de anomalía más exigentes. El enfoque semisupervisado también ha resultado útil, especialmente para identificar episodios temporales concretos de baja generación, en los que la potencia real era prácticamente nula pese a existir una potencia esperada positiva.

Por su parte, el *autoencoder* ha aportado una visión complementaria, ya que no se centra únicamente en la potencia, sino en el comportamiento conjunto de las variables del sistema. En el modelo sin variables ambientales, la *clusterización* de las anomalías ha permitido

diferenciar perfiles asociados a desviaciones eléctricas, térmicas y mixtas. En cambio, al incorporar variables ambientales, la interpretación se vuelve más compleja, ya que los clústeres agrupan patrones combinados y no separan de forma clara anomalías térmicas y ambientales.

En conjunto, puede concluirse que los objetivos del trabajo se han alcanzado de forma satisfactoria. Se ha desarrollado un flujo completo de análisis, desde la preparación de los datos hasta la comparación de distintos modelos, y se han identificado patrones anómalos coherentes con el funcionamiento físico del sistema fotovoltaico.

La principal aportación del trabajo es mostrar que no existe un único modelo óptimo para todos los casos. Los modelos basados en potencia esperada resultan más adecuados para detectar subproducción de forma operativa, mientras que el autoencoder es más útil para explorar y caracterizar perfiles anómalos multivariantes.

Como principal limitación, destaca la ausencia de etiquetas reales de fallo, lo que impide validar los resultados mediante métricas supervisadas clásicas. Por ello, la evaluación se ha basado en la coherencia física, la distribución temporal de las anomalías y la interpretabilidad de los resultados.

7.2. Líneas de trabajo futuro

Como líneas futuras, sería interesante ampliar el trabajo mediante la incorporación de datos etiquetados de fallos reales del sistema fotovoltaico. Esto permitiría validar con mayor precisión las anomalías detectadas por los distintos modelos y evaluar su rendimiento mediante métricas supervisadas, como *accuracy*, *recall* o *F1-score*. Además, facilitaría la diferenciación entre tipos de fallo concretos, como subproducción por sombreado, suciedad, degradación de módulos, fallos de sensores o problemas asociados al inversor.

También, sería relevante replicar los experimentos sobre otros *datasets* similares de plantas fotovoltaicas, con diferentes ubicaciones, condiciones climáticas, tecnologías de paneles o configuraciones de sensores. Esto permitiría comprobar si los patrones detectados en este trabajo, especialmente los episodios de subproducción y los perfiles de anomalía identificados mediante *clusterización*, se mantienen en otros contextos. Además, ayudaría a evaluar la

capacidad de generalización de los modelos y a determinar qué enfoques son más robustos cuando se aplican a sistemas distintos al empleado en este estudio.

Otra línea de mejora sería profundizar en el análisis temporal de las anomalías. En este trabajo se han identificado registros y periodos anómalos, pero sería útil incorporar modelos capaces de capturar dependencias secuenciales, como las redes neuronales LSTM. Esto permitiría detectar no solo observaciones aisladas, sino también patrones anómalos progresivos.

Finalmente, la metodología propuesta podría aplicarse a otros sistemas de generación renovable, como parques eólicos, instalaciones híbridas o plantas solares con distintas configuraciones técnicas. En estos casos, los modelos podrían adaptarse a las variables propias de cada sistema, como velocidad del viento, potencia generada, temperatura, irradiancia o estado operativo de los equipos.

En conclusión, siguiendo las líneas de investigación comentadas, el proyecto abriría las puertas a la adaptación de los modelos generados a entornos reales de supervisión energética, mantenimiento predictivo y optimización del rendimiento de las instalaciones renovables.

Referencias bibliográficas

- Aghazadeh Ardebili, A., Hasidi, Oussama, Bendaouia, Ahmed, Khalil, Adem, Khalil, Sabri, Luceri, Dalila, . . . Ficarella, Antonio. (2024). Enhancing resilience in complex energy systems through real-time anomaly detection: a systematic literature review. *Energy Informatics*, 96.
- Arcila, J. (s. f.). *Armónicos en sistemas eléctricos*. Ingeniería Especializada S.A. (IEB S.A.). Obtenido de https://ingenieros.es/files/proyectos/Armonicos_en_sistemas_electricos.pdf
- Atencia De la Ossa, J. M. (2021). *Sistema de localización de fallas basado en tecnologías de la información y comunicación TICs para el mejoramiento de la calidad del servicio de energía eléctrica del Departamento del Atlántico*. Barranquilla: Universidad del Norte.
- Bezdek, J. C. (1981). *Pattern Recognition with Fuzzy Objective Function Algorithms*. Plenum Press.
- Carlos Levi Cartagena Lobos, & David Ernesto Cortez Pérez. (2024). *Diseño de sistema para el monitoreo del desbalance de tensión y corriente entre las fases A, B y C de generadores eléctricos utilizando una red de sensores de voltaje y corriente con registro de datos en la nube: aplicación en ITCA-FEPADE Centro Regional S*. ITCA Editores. Obtenido de https://www.itca.edu.sv/wp-content/uploads/2024/11/06-Informe-final-Santa-Ana-el%C3%A9ctrica-2023-ISBN-E-Book_compressed.pdf
- Chen, X., Li, B., Braid, J., Byford, B., Colvin, D., Glaws, A., . . . Jain, A. (octubre de 2025). Open data sets for assessing photovoltaic system reliability. *Applied Energy*, 126132.
- Deng, D. (2020). DBSCAN Clustering Algorithm Based on Density. *2020 7th International Forum on Electrical Engineering and Automation (IFEEA)* (págs. 949–953). IEEE.
- Díaz Andrade, C., & Hernández, J. (2011). Smart Grid: Las TICs y la modernización de las redes de energía eléctrica – Estado del Arte. *Sistemas & Telemática*, 53-81.
- Diego García, R. I. (2006). *Análisis wavelet aplicado a la medida de armónicos, interarmónicos y subarmónicos en redes de distribución de energía eléctrica*. Universidad de Cantabria. Obtenido de

<https://repositorio.unican.es/xmlui/bitstream/handle/10902/1547/TesisRDG.pdf?sequence=1&isAllowed=y>

- Hirth, L. (2018). What caused the drop in European electricity prices? A factor decomposition analysis. *The Energy Journal*, 39(1). Obtenido de <https://doi.org/10.5547/01956574.39.1.lhir>
- IEEE. (2009). *IEEE Std 1159-2009: IEEE recommended practice for monitoring electric power quality*. New York: Institute of Electrical and Electronics Engineers. Obtenido de <http://rfc.nop.hu/ieee2/IEEE%20Std%201159.pdf>
- Iglesias, A. (2019). *Caracterización de anomalías en calidad de potencia en redes eléctricas*. Facultad de Ingeniería. Obtenido de https://um.edu.ar/wp-content/uploads/UM-FI-DI_Alfredo-Iglesias_compressed.pdf
- Jalal, M., Khalil, I., & Ul-Haq, A. (2024). Deep learning approaches for visual faults diagnosis of photovoltaic systems: State-of-the-Art review. *Results in Engineering*, 102622.
- Lazzaretti, A. E., Costa, C. H., Rodrigues, M. P., Yamada, G. D., Lexinoski, G., Moritz, G. L., . . . Omori, J. (agosto de 2020). A Monitoring System for Online Fault Detection and Classification in Photovoltaic Plants. *Sensors*, 4688.
- Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. *2008 Eighth IEEE International Conference on Data Mining* (págs. 413–422). IEEE.
- Liu, Y., Duran, E., Bruce, A., Yildiz, B., Mendonca Severiano, B., Anwar Ibrahim, I., . . . Rougieux, F. (1 de diciembre de 2025). A methodological review of cost-effective data-driven fault detection and diagnosis in distributed photovoltaic systems. *Applied Energy*, 401, 126636.
- Miraftebzadeh, S. M., Longo, M., Leva, S., & Matera, N. (2025). Data anomaly detection in photovoltaic power time-series via unsupervised deep learning with insufficient information. *Sustainable Energy, Grids and Networks*, 101769.
- Moneda, F. N.-R. (1 de mayo de 2026). *Smart Grids*. Obtenido de FNMT: <https://www.fnmt.es/innovacion/smart-grids>

- Ng, A., Jordan, M., & Weiss, Y. (2002). On spectral clustering: Analysis and an algorithm. En *Advances in Neural Information Processing Systems 14* (págs. 849-856). Cambridge, MA: MIT Press.
- PythonAfroz. (s. f.). *PV plant in normal and shading faults conditions* . Obtenido de Kaggle: <https://www.kaggle.com/datasets/pythonafroz/pv-plant-in-normal-and-shading-faults-conditions>
- Rashed, A. E.-D. (2022). Obtenido de Fault Detection Dataset in Photovoltaic Farms: <https://www.kaggle.com/datasets/amrezzeldinrashed/fault-detection-dataset-in-photovoltaic-farms>
- Real Academia Española. (s. f.). *Potencia*. Recuperado el 22 de abril de 2026, de Diccionario de la lengua española: <https://dle.rae.es/potencia>
- Red Eléctrica. (18 de junio de 2025). *Red Eléctrica presenta su informe del incidente del 28 de abril y propone recomendaciones*. Obtenido de Red Eléctrica: <https://www.ree.es/es/sala-de-prensa/actualidad/nota-de-prensa/2025/06/red-electrica-presenta-su-informe-del-incidente-del-28-de-abril-y-propone-recomendaciones>
- Sánchez, Á., & Castelló Llantada, C. (28 de abril de 2025). *Un apagón eléctrico masivo en España y Portugal desata el caos*. Obtenido de El País: <https://elpais.com/economia/2025-04-28/apagon-electrico-masivo-en-espana.html>
- Saha, S., Saleem, M., & Roy, T. (2023). Impact of high penetration of renewable energy sources on grid frequency behaviour. *International Journal of Electrical Power and Energy Systems*, 145, 108701. Obtenido de <https://doi.org/10.1016/j.ijepes.2022.108701>
- Sedaghati, R., Mehdizadeh Afroozi, N., Nemati, Y., Rohani, A., Toorani, A., Javidtash, N., . . . Sedaghati, H. (2013). A survey of voltage sags and voltage swells phenomena in power quality problems. *International Journal of Scientific Research and Management*, 1(9), 458-462. Obtenido de <https://www.ijrm.net/index.php/ijrm/article/view/195/166>
- Syamsuddin, A., Adhi, A., Kusumawardhani, A., Prahasto, T., & Widodo, A. (diciembre de 2024). Predictive maintenance based on anomaly detection in photovoltaic system using SCADA data and machine learning. *Results in Engineering*, 103589.

- Taghezouit, B., Harrou, F., Sun, Y., & Merrouche, W. (marzo de 2024). Model-based fault detection in photovoltaic systems: A comprehensive review and avenues for enhancement. *Results in Engineering*, 101835.
- Terzija, V., Valverde, G., Cai, D., Regulski, P., Madani, V., Fitch, J., . . . Phadke, A. (2011). Wide-area monitoring, protection, and control of future electric power networks. *Proceedings of the IEEE*, 99(1), 80-93. Obtenido de <https://doi.org/10.1109/JPROC.2010.2060450>
- Ullah, K., Ahsan, M., Hasanat, S., Haris, M., Yousaf, H., Raza, S., . . . Ullah, Z. (2024). Short-term load forecasting: A comprehensive review and simulation study with CNN-LSTM hybrids approach. *IEEE Access*, 12, 111858-111881. Obtenido de <https://doi.org/10.1109/ACCESS.2024.3440631>
- University of Central Florida - Florida Solar Energy Center. (1 de julio de 2022). *High-resolution floating solar PV data*. Obtenido de Data.gov: <https://catalog.data.gov/dataset/high-resolution-floating-solar-pv-data>
- Valls, J., Ramírez, M., Delgado, M., & Romeral, L. (2025). Recent progress of anomaly detection in energy applications: A systematic literature review. En M. Delgado-Prieto, *Anomaly Detection - Methods, Complexities and Applications*. IntechOpen.
- Van Der Post, H., & Smith, M. (2023). *Unsupervised Machine Learning: with Python*. Reactive Publishing.
- Ziya. (2023). *Smart Meter Electricity Consumption Dataset*. Obtenido de Kaggle: <https://www.kaggle.com/datasets/ziya07/smart-meter-electricity-consumption-dataset>
- Ziya. (2024). *Smart Grid Real-Time Load Monitoring Dataset*. Obtenido de Kaggle: <https://www.kaggle.com/datasets/ziya07/smart-grid-real-time-load-monitoring-dataset>

Anexo A: Descripción de los campos del conjunto de datos

El presente anexo recoge la descripción de las variables incluidas en el conjunto de datos utilizado para el desarrollo experimental del trabajo. Su objetivo es facilitar la interpretación de los datos empleados en los distintos enfoques del proyecto.

Conviene señalar que únicamente se va a hacer referencia a los datos contenidos en los siguientes archivos CSV:

Archivo CSV	Inicio de Registro	Fin de Registro	Resolución	Modelo de módulo fotovoltaico
FSEC_Regional_Test_Ambient	01-01-2014	15-03-2024	1 min / registro	-
FSEC_Regional_Test_BaseLine	01-01-2014	15-03-2024	1 min / registro	Suniva OPT 265-60-4-1B0

Toda la información indicada en el anexo se ha extraído del fichero FPV_metafile_mm.xlsx, disponible en el mismo repositorio donde se encuentran los conjuntos de datos.

El conjunto de datos está formado por series temporales multivariantes procedentes de la monitorización de un sistema fotovoltaico. Las variables disponibles recogen información temporal, magnitudes eléctricas del sistema, condiciones ambientales y variables auxiliares relacionadas con la operación de la instalación. Estas variables constituyen la base sobre la que se realiza el análisis exploratorio, la limpieza del dato, la construcción de características y el entrenamiento de los modelos.

La descripción de los campos se organiza en forma de diccionario de variables, indicando para cada una de ellas su nombre original en el *dataset*, su descripción, el tipo de información que representa y la unidad de medida.

Campo	Descripción	Tipo de Campo	Unidad de Medida
GHRADA	Irradiancia horizontal global media	Irradiancia	W/m ²
DIRRAA	Irradiancia solar directa media	Irradiancia	W/m ²

DIFRAA	Irradiancia solar difusa media	Irradiancia	W/m ²
PMBARA	Presión atmosférica media	Variable Meteorológica	mbar
WSMEAN	Velocidad media del viento	Variable Meteorológica	m/s
WDIREA	Dirección media del viento	Variable Meteorológica	°
WDIRST	Desviación estándar media de la dirección del viento	Variable Meteorológica	°
WSMSST	Desviación estándar media de la velocidad del viento	Variable Meteorológica	m/s
WS3SMA	Velocidad máxima del viento en 3 segundos	Variable Meteorológica	m/s
WDDSMM	Dirección del viento SMM	Variable Meteorológica	°
TMPCAV	Temperatura ambiente media	Variable Meteorológica	°C
RHPCTA	Humedad relativa media	Variable Meteorológica	%
PTMPCA	Temperatura media del panel	Variable Térmica	°C
BATTVA	Tensión media de la batería	Variable Eléctrica	V
ANOM1M	Máximo de variable anónima 1	Variable no identificada	max
GMVAVE	Milivoltios medios globales	Variable Eléctrica	mV
RMMTOT	Precipitación total	Variable Meteorológica	mm
RMMDAY	Precipitación diaria	Variable Meteorológica	mm
TMPCM2	Temperatura media del sensor CMP22	Variable Térmica	°C
SY1VDC	Tensión media en corriente continua del sistema 1	Variable Eléctrica	V
S1S1DC	Corriente continua media del string 1 del sistema 1	Variable Eléctrica	A

S1S2DC	Corriente continua media del string 2 del sistema 1	Variable Eléctrica	A
SY1VAC	Tensión media en corriente alterna del sistema 1	Variable Eléctrica	V
SY1IAC	Corriente media en corriente alterna del sistema 1	Variable Eléctrica	A
SY1WAC	Potencia activa media en corriente alterna del sistema 1	Variable Eléctrica	W
SY1VAR	Potencia aparente media del sistema 1	Variable Eléctrica	VA
SYS1PF	Factor de potencia del sistema 1	Variable Eléctrica	Factor de Potencia
SYS1FQ	Frecuencia del sistema 1	Variable Eléctrica	Hz
MODT01	Temperatura media del módulo 1 (Sistema 1)	Variable Térmica	°C
MODT02	Temperatura media del módulo 2 (Sistema 1)	Variable Térmica	°C
MODT03	Temperatura media del módulo 3 (Sistema 1)	Variable Térmica	°C
MODT04	Temperatura media del módulo 4 (Sistema 1)	Variable Térmica	°C
MODT05	Temperatura media del módulo 5 (Sistema 1)	Variable Térmica	°C
MODT06	Temperatura media del módulo 6 (Sistema 1)	Variable Térmica	°C
MODT07	Temperatura media del módulo 7 (Sistema 1)	Variable Térmica	°C
MODT08	Temperatura media del módulo 8 (Sistema 1)	Variable Térmica	°C
SY2VDC	Tensión media en corriente continua del sistema 2	Variable Eléctrica	V

S2S1DC	Corriente continua del string 1 del sistema 2	Variable Eléctrica	A
S2S2DC	Corriente continua del string 2 del sistema 2	Variable Eléctrica	A
S2VACA	Tensión media en corriente alterna del sistema 2	Variable Eléctrica	V
S2IACA	Corriente media en corriente alterna del sistema 2	Variable Eléctrica	A
S2WACA	Potencia activa media en corriente alterna del sistema 2	Variable Eléctrica	W
S2VARA	Potencia aparente media del sistema 2	Variable Eléctrica	VA
S2PFAV	Factor de potencia medio del sistema 2	Variable Eléctrica	Factor de Potencia
S2FRQA	Frecuencia media del sistema 2	Variable Eléctrica	Hz
MODT09	Temperatura media del módulo 9 (Sistema 2)	Variable Térmica	°C
MODT10	Temperatura media del módulo 10 (Sistema 2)	Variable Térmica	°C
MODT11	Temperatura media del módulo 11 (Sistema 2)	Variable Térmica	°C
MODT12	Temperatura media del módulo 12 (Sistema 2)	Variable Térmica	°C
MODT13	Temperatura media del módulo 13 (Sistema 2)	Variable Térmica	°C
MODT14	Temperatura media del módulo 14 (Sistema 2)	Variable Térmica	°C
MODT15	Temperatura media del módulo 15 (Sistema 2)	Variable Térmica	°C
MODT16	Temperatura media del módulo 16 (Sistema 2)	Variable Térmica	°C

REC1IR	Irradiancia medida por la celda de referencia 1	Irradiancia	W/m ²
REC1TE	Temperatura de la celda de referencia 1	Variable Térmica	°C
REC1RE	Señal R-Current de la celda de referencia 1	Variable Eléctrica	mV
REC2IR	Irradiancia medida por la celda de referencia 2	Irradiancia	W/m ²
REC2TE	Temperatura de la celda de referencia 2 (°C)	Variable Térmica	°C
REC2RE	Señal R-Current de la celda de referencia 2 (mV)	Variable Eléctrica	mV
LAMBT	Temperatura ambiente local media (°C)	Variable Meteorológica	°C
POAIR1	Irradiancia media en el plano del generador fotovoltaico (W/m ²)	Irradiancia	W/m ²
ICP1JT	Temperatura media de unión 1 (°C)	Variable Térmica	°C
ICP2JT	Temperatura media de unión 2 (°C)	Variable Térmica	°C
ICP3JT	Temperatura media de unión 3 (°C)	Variable Térmica	°C
ICP4JT	Temperatura media de unión 4 (°C)	Variable Térmica	°C
ICP5JT	Temperatura media de unión 5 (°C)	Variable Térmica	°C
ICP6JT	Temperatura media de unión 6 (°C)	Variable Térmica	°C
ICP7JT	Temperatura media de unión 7 (°C)	Variable Térmica	°C

Anexo B: Uso responsable de la Inteligencia Artificial

A lo largo del desarrollo del presente TFE se ha utilizado la inteligencia artificial como herramienta de apoyo para facilitar la comprensión, el análisis y la resolución de determinados aspectos técnicos relacionados con el desarrollo de modelos predictivos y de detección de anomalías en sistemas de generación fotovoltaica.

En primer lugar, se ha empleado principalmente *ChatGPT* como apoyo para la comprensión y análisis de bibliografía científica relacionada con las distintas metodologías estudiadas. La interacción con la herramienta ha permitido aclarar conceptos asociados al funcionamiento, las características y la aplicabilidad de diferentes modelos de inteligencia artificial y aprendizaje automático, facilitando así la interpretación de determinados enfoques descritos en la literatura.

Asimismo, la inteligencia artificial se ha utilizado como soporte durante las fases de programación, especialmente para comprender y resolver errores de ejecución complejos. Su uso ha resultado útil para identificar problemas relacionados con formatos de entrada de datos, incompatibilidades entre estructuras y determinadas transformaciones que han sido implementadas en *Python*. También se ha recurrido a ella para aclarar el funcionamiento de funciones concretas, como *crosstab*, así como para comprender mejor el efecto de determinadas operaciones de preprocesamiento y transformación de los datos.

La IA también ha servido como herramienta de orientación ante algunas decisiones metodológicas, permitiendo explorar diferentes alternativas de análisis y comprender las ventajas y limitaciones de determinados modelos. No obstante, las propuestas obtenidas mediante estas herramientas se han analizado de forma crítica y se han contrastado con la bibliografía consultada, los resultados experimentales y el conocimiento adquirido durante el desarrollo del proyecto.

Por tanto, el uso de la inteligencia artificial ha tenido un carácter principalmente asistencial, orientado a la resolución de dudas conceptuales y técnicas y a facilitar el proceso de aprendizaje y desarrollo. La selección de las metodologías, el tratamiento de los datos, la implementación de los modelos, el análisis de los resultados y las conclusiones finales han sido realizadas y evaluadas por los autores del trabajo, manteniendo en todo momento un criterio propio sobre las decisiones adoptadas.

Anexo C: Referencia al repositorio del proyecto

El código correspondiente a la experimentación se puede encontrar en el siguiente repositorio de GitHub: <https://github.com/pablocarcia/deteccion-anomalias-generacion-electrica>